

Pregunta 01 (10 puntos)

Contexto:

Una cadena nacional de supermercados (como Tottus, Metro o Plaza Vea) tiene 15 años de transacciones de millones de clientes. El equipo de datos quiere responder preguntas como:

- ¿Qué productos se compran juntos habitualmente?
- ¿Puedo predecir qué compraría un cliente si veo su carrito?
- ¿Cómo optimizo promociones y descuentos?

1. Técnica de minería de datos aplicada por la empresa

La empresa utilizó reglas de asociación como técnica principal de minería de datos. Según clase 5, es un tipo de minería descriptiva que descubre relaciones frecuentes entre elementos.

Ejemplo práctico: Analizando millones de transacciones, descubrieron que clientes comprando pañales y fórmula infantil también adquieren productos de limpieza con 75% de confianza.

`SI (pañales AND fórmula) ENTONCES (productos limpieza) - confianza: 75%`

Valor empresarial:

- Promociones cruzadas basadas en patrones reales
- Bundles de productos que aumentan ticket promedio
- Colocación estratégica en tienda
- Ofertas personalizadas relevantes

Otras técnicas complementarias:

El equipo también usó **clasificación** y **clustering** para segmentar clientes por frecuencia, ticket promedio y preferencias, permitiendo agrupar comportamientos similares y hacer predicciones.

2. Cuatro problemas de calidad de datos detectados

Preparación de datos:

a. Registros duplicados

- Clientes o ventas repetidas por entradas múltiples en el sistema
- Impacto: Inflan frecuencias, distorsionan patrones de asociación, KPIs incorrectos

b. Nombres inconsistentes de productos

- Mismo producto con etiquetas distintas por sucursal (ej: "Leche Entera" vs "LECHE INTEGRAL")
- Impacto: Fragmentación de análisis, imposibilidad de agrupar categorías, reglas de asociación inválidas

c. Formatos de fecha inconsistentes

- Fechas en DD/MM/YYYY, MM/DD/YYYY o YYYY-MM-DD según sucursal
- Impacto: Imposibilita análisis temporal, invalidar comparaciones entre tiendas

d. Montos atípicos por errores de digitación

- Ventas con valores imposibles (ej: \$999,999 por producto de \$10)
- Impacto: Sesgan promedios, generan outliers que invalidan análisis estadístico

Soluciones aplicadas:

Limpieza automática, estandarización de nombres, formato ISO de fechas, validación de rangos lógicos.

Pregunta 02 (10 puntos)

Contexto:

Una red privada de clínicas (como Clínica Delgado, Arzobispo Loayza) tiene dataset de 3000 pacientes con variables clínicas: edad, peso, presión arterial, glucosa, antecedentes, diagnósticos, etc.

El problema:

- 30% de registros tienen peso faltante (pacientes en emergencia, sin protocolo completo)
- 25% tienen presión arterial faltante
- Muchos antecedentes están en blanco

Lo que la actividad pregunta:

1. ¿Cómo reemplazas esos faltantes sin sesgar el dataset?
2. ¿Cómo normalizas variables que están en escalas completamente diferentes?

Paso 1: Identificación

Variables con faltantes: peso, presión arterial, antecedentes familiares.

Paso 2: Evaluación del patrón

- MCAR (Missing Completely At Random): Faltante sin relación con otras variables → seguro imputar
- MAR (Missing At Random): Faltante depende de variables observadas → requiere cuidado
- MNAR (Missing Not At Random): Faltante relacionado con el valor mismo → riesgo de sesgo

En clínica, muchos faltantes en peso son MAR (pacientes en emergencia sin protocolo completo).

Paso 3: Selección de estrategia según tipo

Tipo de Variable	Método	Ejemplo
Númerica (peso)	Media/Mediana	Si media=75kg, reemplazar con 75kg
Categorica (antecedentes)	Moda	Si "hipertensión" es más frecuente, usarla
Correlacionada	Regresión/KNN	Predecir peso basado en edad, talla, IMC

Paso 4: Validación

Documentar qué faltantes fueron imputados, verificar que no introduzca sesgo.

Ventaja en medicina:

Preserva historias clínicas valiosas y permite modelos predictivos más potentes.

Técnica de normalización que utiliza media y desviación estándar

Normalización Z-score, también llamada estandarización.

Fórmula:

$$z = (x - \text{media}) / \text{desviación estándar}$$

Donde:

- 'x' = valor original
- 'μ' = media
- 'σ' = desviación estándar
- Resultado: variable con media=0 y σ=1

Ejemplo:

Variable	Rango	Media	σ	Valor Original	Z-Score
Peso (kg)	40–150	75	15	90 kg	$(90-75)/15 = 1.0$
Presión Sistólica (mmHg)	90–180	120	20	140 mmHg	$(140-120)/20 = 1.0$
Glucosa (mg/dL)	70–400	100	30	130 mg/dL	$(130-100)/30 = 1.0$

Todos los valores originales distintos ahora tienen $Z=1.0$, significando "1 desviación estándar arriba de la media".