

Proyecto Integrador: El Efecto del Seniority y el Trabajo Remoto en el Mercado Laboral de Ingenieros de Software en EE.UU.

Curso: Análisis Estadístico y Data Mining (ISIL, 2026-1)

Alumno: Carlos Gil Carrillo

Email: 42834069@mail.isil.pe

1. ¿Qué problema queremos resolver?

El mercado laboral de ingenieros de software en Estados Unidos ha cambiado mucho. La pandemia aceleró el trabajo remoto, los niveles de experiencia se han multiplicado y las diferencias salariales son cada vez más importantes.

Tres problemas clave:

- **No se sabe cuánto gana cada nivel.** No hay datos claros sobre cuánto gana un Junior vs un Senior, ni cómo cambia el salario si trabajas remoto o presencial.
- **Las decisiones se toman por intuición.** Los profesionales eligen entre remoto y presencial sin evidencia de cuál paga mejor.
- **Las empresas no tienen benchmark.** Definen rangos salariales sin conocer el mercado real.

Dato importante: El salario mediano de un ingeniero de software en EE.UU. supera los \$130,000 anuales según la Bureau of Labor Statistics.

Pregunta guía del proyecto

¿Cómo se relacionan el nivel de seniority (Junior → Principal) y la modalidad de trabajo (remoto vs presencial) con el salario y la calidad percibida de las empresas que contratan ingenieros de software en EE.UU.?

2. ¿Qué datos usamos?

Usamos un dataset real de **58,433 ofertas laborales** de ingenieros de software publicadas en Indeed, recolectadas mediante web scraping.

Característica	Descripción
Total de registros	58,433 ofertas
Registros con salario	~18,103 (31%)
Variables	29 (numéricas, categóricas, booleanas)
Fuente	Indeed / ZenRows

Variables principales del dataset

Variable	Tipo	Ejemplo
title	Texto	Senior Software Engineer
salary	Texto	\$100,000 - \$150,000 a year
rating	Numérica	4.0
remote_work_model	Categórica	REMOTE_ALWAYS
location	Categórica	San Francisco, CA
seniority	Derivada	Junior, Mid, Senior, Lead, Staff, Principal
salary_annual	Derivada	Salario anualizado en USD

3. ¿Cómo preparamos los datos?

3.1 Extracción de seniority desde el título

El campo title contiene el nivel de experiencia como texto libre. Usamos reglas de búsqueda por palabras clave:

Palabras clave detectadas	Seniority asignado
principal, distinguished, fellow	Principal
staff	Staff
lead, manager, director	Lead
senior, sr.	Senior
junior, jr., entry	Junior
intern	Intern
(ninguna)	Mid

3.2 Conversión del salario a número

El campo salary viene en múltiples formatos. Lo convertimos todo a salario anual:

Formato original	Conversión
"\$45,000 - \$55,000 a year"	\$50,000 (promedio)
"\$15 - \$20 an hour"	\$36,400 (× 2,080 horas)
"\$3,000 a week"	\$156,000 (× 52 semanas)
"From \$100,000 a year"	\$100,000

3.3 Limpieza de outliers

Usamos el método IQR (Rango Inter - cuartílico) para eliminar valores atípicos:

- **Límite inferior:** \$30,000 (mínimo razonable para ingeniero)
- **Límite superior:** \$350,000 (máximo antes de errores de parsing)
- **Outliers detectados:** 847 registros (4.7%)
- **Reemplazo:** Mediana del grupo de seniority correspondiente


4. Resultados del análisis

4.1 ¿Cuánto gana cada nivel de seniority?

Seniority	Cantidad	Salario mediano (USD)
Mid	28,920	\$114,360
Senior	18,182	\$130,000
Lead	6,136	\$121,500
Staff	2,255	\$162,000
Principal	2,005	\$137,000
Junior	918	\$60,000

Hallazgo clave: El nivel Staff tiene el salario mediano MÁS ALTO (\$162,000), superando incluso a Principal (\$137,000).


Figura 1: Salario mediano por nivel de seniority



Salario mediano por nivel de seniority

El gráfico muestra cómo varía el salario según el nivel de experiencia. Staff lidera con \$162,000, seguido por Principal y Senior.

Figura 2: Distribución salarial por seniority (boxplot)



Boxplot de salario por seniority


El boxplot revela la mediana, los cuartiles y los valores atípicos para cada nivel. Staff tiene la mediana más alta y Principal la dispersión más amplia.

4.2 ¿Cómo afecta el trabajo remoto al salario?

Modalidad	Salario mediano (USD)	Cantidad de ofertas
REMOTE_ALWAYS	\$132,500	17,556
REMOTE_COVID_TEMPORARY	\$122,500	5,248
Presencial	—	~35,629

Hallazgo clave: Los puestos permanentemente remotos pagan **\$10,000 más** en mediana que los temporalmente remotos.


Figura 3: Salario por modalidad de trabajo remoto



Comparación salarial entre modalidades remotas

El gráfico compara los salarios entre remoto permanente y temporal. La barra verde (remoto permanente) es visiblemente más alta.

Figura 4: Interacción seniority × modalidad remoto



Interacción seniority y modalidad remoto


Este gráfico cruza seniority con modalidad remoto. Para cada nivel, compara el salario entre remoto permanente y temporal. La brecha es mayor en niveles altos.

4.3 ¿Dónde están las ofertas?

Ubicación	Cantidad
Remote	6,730
New York, NY	2,529
San Francisco, CA	1,996
Austin, TX	1,971
Boston, MA	1,300

Hallazgo clave: “Remote” como ubicación supera a todas las ciudades individuales.

Figura 5: Top 10 ubicaciones con más ofertas



Top 10 ubicaciones


El gráfico de barras horizontales muestra las 10 ubicaciones con más ofertas. Remote lidera con más de 6,700 ofertas.

4.4 ¿Las mejores empresas contratan perfiles más senior?

Seniority	Rating promedio
Staff	3.48
Principal	3.32
Lead	2.75
Senior	2.48
Mid	2.47
Junior	2.06

Hallazgo clave: Los puestos Staff y Principal están en empresas con rating significativamente más alto.

Figura 6: Rating promedio por seniority



Rating de empresa por seniority

El gráfico muestra una relación positiva entre seniority y rating de empresa. Staff y Principal tienen ratings superiores a 3.3.

4.5 ¿Quiénes contratan urgentemente?

Seniority	% Urgentemente hiring
Senior	14.9%
Lead	13.8%
Junior	13.0%
Mid	12.8%
Principal	5.6%
Staff	3.3%

Figura 7: Urgencia de contratación por seniority



Urgencia de contratación

Senior y Lead lideran con ~14%, confirmando que las empresas necesitan urgentemente ingenieros con experiencia media-alta.

5. Minería de datos

5.1 Segmentación del mercado con K-Means


Usamos el algoritmo K-Means para agrupar las ofertas en segmentos homogéneos.

Variables de entrada: - Salario anual - Rating de la empresa - Nivel de seniority - Modalidad remoto

Determinación del número de clusters (K):

Usamos el método del codo y el coeficiente de Silhouette para elegir K=4.

Figura 8: Método del codo y análisis de Silhouette



Método del codo y Silhouette

El gráfico izquierdo muestra la inercia para diferentes valores de K. El “codo” se observa en K=4. El gráfico derecho confirma que K=4 tiene el mejor Silhouette Score (0.42).

Resultado: 4 segmentos de mercado

Segmento	Perfil	Acción sugerida
Tier Premium	Senior/Staff, remoto, empresa top rating, salario > \$150K	Meta para perfiles con experiencia
Tier Enterprise	Senior/Lead, presencial, empresa grande, salario \$120-150K	Opción para quienes buscan estabilidad
Tier Growth	Mid-level, modalidad mixta, salario \$90-120K	Zona de crecimiento
Tier Entry	Junior/Mid, empresa nueva, salario < \$90K	Punto de inicio

Figura 9: Segmentación de clusters



Scatter plot de clusters

El gráfico de dispersión muestra los 4 segmentos identificados. Cada color representa un cluster con características distintas.

5.2 Predicción del nivel salarial con Árbol de Decisión

Entrenamos un modelo para predecir si el salario de una oferta es Bajo, Medio o Alto.


Variable objetivo: salary_tier (terciles del salario anualizado)

Variables predictoras: seniority, modalidad remoto, rating, ubicación, tamaño de empresa

Resultados del modelo:

Métrica	Resultado	Meta
Accuracy	~62%	> 60%
Precision	~65%	> 65%
Recall	~62%	> 60%


Figura 10: Árbol de decisión



Árbol de decisión

El árbol muestra las reglas que el modelo aprendió. Seniority aparece en la raíz, confirmando que es la variable más importante.

Figura 11: Importancia de variables



Importancia de variables

Seniority domina con más del 50% de importancia, seguido por rating y modalidad remoto.

6. Hallazgos contra-intuitivos

¿Por qué Staff gana más que Principal?

Una de las preguntas más interesantes es por qué el salario mediano de Staff (\$162,000) supera al de Principal (\$137,000).

Dimensión	Staff	Principal	Conclusión
Rating promedio	3.48	3.32	Staff en empresas con rating 4.8% mayor
Tamaño empresa (reviews)	10,476	9,234	Staff en empresas más grandes (+13%)
% Urgentemente hiring	3.3%	5.6%	Principal menos demandado
Desviación estándar salarial	\$42,000	\$48,000	Principal más variable

Conclusión: Staff es un rol **más especializado en empresas tech grandes y de alto rating**, mientras que Principal es más genérico y se presenta en contextos diversos.

7. Validación estadística

Prueba T: ¿El remoto permanente paga significativamente más?

Métrica	Valor
T-statistic	3.847
P-valor	0.000127
Conclusión	RECHAZAR H_0
Tamaño del efecto	Cohen's d = 0.28 (efecto pequeño a medio)

Conclusión: La diferencia de ~\$10K entre remoto permanente y temporal es **estadísticamente significativa** ($p < 0.05$).

8. Conclusiones y recomendaciones

Para profesionales Junior

- Enfocarse en obtener 2-3 años de experiencia antes de buscar remoto
- Priorizar empresas con buen rating para construir CV sólido
- El salario inicial (~\$60K) crece significativamente al alcanzar Mid

Para profesionales Mid-level

- El salto de Mid a Senior ofrece el mayor incremento salarial
- El remoto permanente ya tiene prima salarial en este nivel
- Buscar empresas con rating >3.0

Para profesionales Senior

- El mercado tiene alta urgencia de contratación (14.9%)
- El remoto permanente paga significativamente más
- Considerar roles Staff para maximizar salario (\$162K mediano)

Para empresas

- Los puestos Staff son los más costosos pero atraen talento top
- La urgencia de contratación es mayor para Senior/Lead
- El remoto permanente es la modalidad dominante del mercado

9. Limitaciones del análisis

Limitación	Impacto	Cómo mitigar
Solo 31% de registros con salario	Sesgo hacia empresas transparentes	Propensity weighting
No incluye benefits/equity	Subestima compensación total ~\$20-40K	Agregar datos de Levels.fyi
Solo Indeed (no LinkedIn)	Sesgo hacia grandes empresas	Integrar múltiples plataformas
Extracción seniority por regex	~5-10% de errores	Usar NLP para clasificación

Fuentes

#	Fuente	Tipo	URL
1	Indeed — Software Engineer Job Listings	Dataset	https://www.indeed.com/
2	ZenRows. Web Scraping for Job Market Data	Herramienta	https://www.zenrows.com/
3	U.S. Bureau of Labor Statistics	Oficial	https://www.bls.gov/ooh/computer-and-information-technology/software-developers.htm

