

## + TEMA 01

# ESTADÍSTICA DESCRIPTIVA

- Medidas de tendencia central: media, mediana, moda
- Medidas de dispersión: varianza, desviación estándar
- Representación gráfica: histogramas, diagramas de caja
- Tipos de datos: nominales, ordinales, continuos
- Distribución de datos: normal, sesgada, kurtosis





# + INTRODUCCIÓN **DE LA SESIÓN**

- + La estadística descriptiva es la base fundamental del análisis de datos, puesto que permite organizar, resumir e interpretar la información obtenida de observaciones y/o encuestas. Su objetivo principal es transformar los datos en información comprensible para la toma de decisiones.
- + En un entorno empresarial, las herramientas de la estadística descriptiva permiten analizar ventas, ingresos, costos o comportamientos de consumidores, proporcionando una visión clara del rendimiento y las tendencias del negocio.
- + A través de indicadores y gráficos estadísticos, se facilita la interpretación visual y cuantitativa de los datos. Estas técnicas ayudan a identificar patrones, valores extremos y distribuciones relevantes.
- + La estadística descriptiva es esencial para todo profesional, ya que constituye el primer paso para aplicar luego métodos analíticos más avanzados como la inferencia estadística o el data mining.



+

MEDIDAS DE

**TENDENCIA CENTRAL:**  
**MEDIA, MEDIANA, MODA**

## ¿QUÉ SON LAS MEDIDAS DE TENDENCIA CENTRAL?

- Son valores numéricos que representan el centro o punto típico de un conjunto de datos. Indican hacia dónde tienden a agruparse los valores observados y resumen el comportamiento general de la variable analizada.
- Su propósito es describir un valor representativo del conjunto total de observaciones.



## MEDIA (PROMEDIO ARITMÉTICO)

- La media es el valor que se obtiene al sumar todos los datos y dividir entre el número total de datos.
- Es la medida más común, de fácil entendimiento y útil cuando los datos son numéricos y no presentan valores extremos (outliers).

### Fórmula:

$$\bar{X} = \frac{\sum Xi}{n}$$

Donde:

$\bar{X}$  = media

$\sum xi$  = suma de todos los datos

$n$  = número total de datos




## MEDIA (PROMEDIO ARITMÉTICO)

### Ejemplo:

En una empresa, la media de ventas semanales de cinco vendedores (en miles de soles: 10, 12, 9, 11, 8) sería:

$$\bar{X} = \frac{10 + 12 + 9 + 11 + 8}{5} = 10$$

La media indica que, en promedio, cada vendedor genera, por concepto de ventas, 10 mil soles semanales.







## MEDIANA

- La mediana es el valor central de un conjunto de datos ordenados, que divide la distribución en dos partes iguales: el 50% inferior y el 50% superior.
- No se ve afectada por valores extremos, por lo que es más representativa en datos asimétricos.

### Cálculo:

- Ordenar los datos de menor a mayor.
- Si el número de datos es impar, la mediana es el valor central.
- Si es par, la mediana es el promedio de los dos valores centrales.



## MEDIANA

### Ejemplo:

En una empresa, los sueldos (en soles) de 5 trabajadores son:  
1000, 1200, 1300, 5000, 6000.

La mediana es 1300 porque está en el centro del conjunto ordenado.

Esto muestra que, aunque algunos ganen mucho más, la mitad (el 50% inferior) de los trabajadores gana 1300 soles o menos.

## MODA

- La moda es la medida de tendencia central que indica el dato u observación que más se repite dentro de una distribución o conjunto de datos.
- Puede existir una sola moda (unimodal), varias modas (multimodal) o ninguna (si todos los datos registran la misma frecuencia).

### Cálculo:

- Se identifica observando qué valor aparece con mayor frecuencia en el conjunto de datos.



## MODA

### Ejemplo:

Una empresa registra el monto de ventas (en miles de soles) obtenidas durante 8 semanas:

15, 18, 15, 22, 15, 15, 20, 18

En este caso, el valor 15 se repite cuatro veces, por lo que la distribución es unimodal y la moda es 15.

Esto significa que el nivel de venta más frecuente en las 8 semanas fue de 15 mil soles, reflejando el monto en el que la empresa más suele ubicarse.

+

MEDIDAS DE DISPERSIÓN:

**VARIANZA,  
DESVIACIÓN ESTÁNDAR**

## ¿QUÉ SON LAS MEDIDAS DE DISPERSIÓN?

- Las **medidas de dispersión** cuantifican cuánto se alejan los datos respecto a la media. Es decir, indican el grado de variabilidad o estabilidad que existe en un conjunto de observaciones.
- Cuando la dispersión es baja, los datos están concentrados cerca del promedio; cuando es alta, los valores se encuentran más dispersos o alejados entre sí.
- Estas medidas son esenciales para evaluar la consistencia de los resultados, el riesgo o la heterogeneidad de comportamientos dentro de una población o muestra.



## ALGUNAS APLICACIONES EN CONTEXTOS EMPRESARIALES

Miden el riesgo o volatilidad de una inversión. Una baja desviación estándar en los rendimientos significa menor riesgo; una alta, mayor incertidumbre.

### FINANZAS

Indican si las ventas o preferencias de los clientes son homogéneas o variables. También mide la variabilidad en la respuesta de los clientes a una campaña.

### MARKETING

Muestran estabilidad o variación en la productividad, costos o tiempos de servicio.

### ADMINISTRACIÓN

Se usa para estandarizar variables antes de aplicar modelos predictivos y asegurar comparabilidad entre diferentes escalas.

### CIENCIA DE DATOS

## VARIANZA

La varianza mide el promedio de las desviaciones cuadráticas de cada dato respecto a la media. Es decir, cuánto se alejan en promedio los datos del valor central, considerando las diferencias al cuadrado (para evitar signos negativos).

### Fórmula:

$$S^2 = \frac{\sum (X_i - \bar{X})^2}{n - 1}$$


Donde:

$S^2$  = varianza muestral

$\bar{X}$  = media del conjunto de datos

$X_i$  = cada valor observado

$n$  = número total de datos





## VARIANZA

**Ejemplo:** las ventas semanales (en miles de soles) de una tienda fueron:

10, 12, 8, 10, 10

Si aplicamos la fórmula, la varianza sería 2. Este resultado significa que:

Las ventas semanales tienen una variación moderada alrededor del promedio de 10 mil soles.

No todas las semanas se vende lo mismo, pero las diferencias no son muy grandes.

Aunque la varianza se expresa en unidades al cuadrado (por eso no es tan intuitiva), su valor ayuda a calcular la desviación estándar, que sí se interpreta directamente en miles de soles.

## DESVIACIÓN ESTÁNDAR

- La desviación estándar es la raíz cuadrada de la varianza, lo que permite expresar la dispersión en las mismas unidades originales de los datos.
- Es la medida más utilizada para evaluar la variabilidad real de los valores respecto a la media.


### Fórmula:

$$SX = \sqrt{s^2}$$

Donde:

$SX$  = desviación estándar

$s^2$  = varianza muestral



## DESVIACIÓN ESTÁNDAR

A partir del ejemplo anterior:

$$SX = \sqrt{2} = 1.41$$

Este resultado significa que:

La desviación estándar es 1.41, lo que significa que las ventas semanales se desvían, en promedio, 1.41 miles de soles respecto al promedio de 10.

En términos prácticos, indica que las ventas son bastante estables, ya que las variaciones semanales son pequeñas.

+

REPRESENTACIÓN GRÁFICA:  
**HISTOGRAMAS,**  
**DIAGRAMAS DE CAJA**

## REPRESENTACIÓN GRÁFICA DE DATOS

- Es una herramienta fundamental en estadística descriptiva, ya que permite visualizar y comunicar la información de manera clara, rápida y comprensible.
- A través de los gráficos, podemos identificar tendencias, patrones, valores extremos y comportamientos inusuales que no siempre se perciben solo con números.
- En el contexto profesional, las gráficas facilitan la toma de decisiones basada en datos, la comunicación de resultados a equipos no técnicos y la presentación de conclusiones ante directivos o clientes.



## IMPORTANCIA EN DISTINTOS ÁMBITOS PROFESIONALES

**Permite comparar ventas por región, identificar temporadas altas o bajas, y evaluar el desempeño de productos.**

**NEGOCIOS**

**Ayuda a visualizar la distribución de pacientes por edad o evolución de enfermedades.**

**SALUD**

**Permite detectar variaciones en procesos de producción y controlar la calidad.**

**INGENIERÍA**

**Paso importante para descubrir patrones y relaciones antes de aplicar modelos predictivos.**

**DATA MINING Y ANÁLISIS DE DATOS**

## HISTOGRAMA

- Es una representación gráfica de la frecuencia de los datos numéricos continuos agrupados en intervalos.
- Cada barra representa un rango de valores y su altura indica cuántas observaciones caen dentro de ese rango.



## EJEMPLO

Una empresa de servicios desea evaluar su eficiencia en la atención al cliente. Durante una semana, registró el tiempo (en minutos) que tardó cada uno de los 40 clientes en ser atendido. El analista desea responder:


- ¿Cómo se distribuyen los tiempos de atención?
- ¿Existen muchos clientes que esperan demasiado?
- ¿El proceso es uniforme o hay variaciones importantes?

*(Los datos recolectados se muestran en la tabla adjunta)*

| Cliente | Tiempo | Cliente | Tiempo |
|---------|--------|---------|--------|
| 1       | 5      | 21      | 8      |
| 2       | 6      | 22      | 12     |
| 3       | 4      | 23      | 10     |
| 4       | 7      | 24      | 14     |
| 5       | 5      | 25      | 11     |
| 6       | 9      | 26      | 6      |
| 7       | 8      | 27      | 7      |
| 8       | 10     | 28      | 13     |
| 9       | 11     | 29      | 9      |
| 10      | 7      | 30      | 15     |
| 11      | 6      | 31      | 10     |
| 12      | 5      | 32      | 8      |
| 13      | 8      | 33      | 7      |
| 14      | 12     | 34      | 5      |
| 15      | 10     | 35      | 6      |
| 16      | 14     | 36      | 9      |
| 17      | 9      | 37      | 11     |
| 18      | 7      | 38      | 13     |
| 19      | 8      | 39      | 10     |
| 20      | 6      | 40      | 12     |




## HISTOGRAMA



- ✓ El histograma muestra que la mayor parte de los clientes fue atendida entre 4 y 10 minutos, con pocas atenciones que van desde los 13 minutos.
- ✓ El proceso de atención es bastante consistente, aunque existen algunos casos de espera prolongada que podrían revisarse para mejorar la experiencia del cliente.

## DIAGRAMA DE CAJA (BOXPLOT)

- El diagrama de caja y bigotes (o boxplot) resume la distribución de una variable numérica a través de cinco valores clave:
  - Mínimo
  - Primer cuartil
  - Mediana
  - Tercer cuartil
  - Máximo.
- Además, identifica visualmente los valores atípicos (outliers).
- Permite comparar distribuciones entre grupos, detectar asimetrías y conocer la variabilidad de los datos de manera compacta.




## EJEMPLO

- El área de Recursos Humanos de una empresa busca identificar diferencias salariales entre tres departamentos: Ventas, Producción y Finanzas.
- Desean saber si los sueldos son homogéneos o si existen valores atípicos (outliers) que podrían afectar la equidad salarial o requerir revisión.
- ✓ Base de datos de la tabla adjunta muestra los sueldos mensuales (en soles) de los tres departamentos.

| Empleado | Ventas | Producción | Finanzas |
|----------|--------|------------|----------|
| 1        | 2500   | 2300       | 2600     |
| 2        | 2700   | 2400       | 2800     |
| 3        | 2600   | 2500       | 2700     |
| 4        | 2800   | 2600       | 2900     |
| 5        | 3100   | 2700       | 3000     |
| 6        | 2900   | 2800       | 3100     |
| 7        | 2700   | 2600       | 2900     |
| 8        | 2600   | 2500       | 2700     |
| 9        | 3000   | 2700       | 2800     |
| 10       | 4000   | 2500       | 3200     |

*Observación: en el departamento de Ventas hay un salario de S/4000, que es un valor atípico respecto al resto.*

# DIAGRAMA DE CAJA (BOXPLOT)



Al analizar el gráfico, se observa los siguientes aspectos:

1. **Mediana** (línea dentro de la caja): indica el sueldo central de cada departamento.
  - Ventas  $\approx$  S/2750
  - Producción  $\approx$  S/2600
  - Finanzas  $\approx$  S/2850
2. **Rango intercuartílico** (altura de la caja): muestra la variabilidad de los sueldos.
  - Producción presenta una menor dispersión (más homogénea).
  - Ventas tiene una mayor variabilidad, influenciada por el valor alto de S/4000.
3. **Bigotes** (líneas superiores e inferiores): indican los sueldos más bajos y más altos dentro del rango esperado.
4. **Valor atípico** (punto fuera de la caja):
  - El sueldo de S/4000 en Ventas aparece como un outlier, lo que podría indicar una bonificación especial o cargo superior.

## COMPARACIÓN ENTRE EL HISTOGRAMA Y EL DIAGRAMA DE CAJA

| ASPECTO      | HISTOGRAMA                             | DIAGRAMA DE CAJA                                  |
|--------------|----------------------------------------|---------------------------------------------------|
| Tipo de dato | Numérico continuo                      | Numérico (discreto o continuo)                    |
| Objetivo     | Mostrar la forma de la distribución    | Resumir la distribución y detectar outliers       |
| Ventaja      | Visualiza la densidad y forma general  | Resume información clave y facilita comparaciones |
| Limitación   | No muestra valores exactos ni outliers | No muestra la forma de la distribución completa   |

+

TIPO DE DATOS:

**NOMINALES, ORDINALES,  
CONTINUOS**

## DATOS EN ESTADÍSTICA

En estadística, los datos son el punto de partida de cualquier análisis. Sin embargo, no todos son iguales: algunos describen características o categorías, mientras que otros representan cantidades numéricas. Conocer el tipo de dato es esencial para:




Elegir las medidas adecuadas (media, mediana, moda, varianza, etc.).



Seleccionar los gráficos correctos (barras, histogramas, boxplots, etc.).



Aplicar las técnicas de análisis apropiadas (análisis descriptivo, inferencial o minería de datos).





## CLASIFICACIÓN DE LOS TIPOS DE DATOS



## DATOS CATEGÓRICOS O CUALITATIVOS

- Son aquellos que expresan una cualidad o característica, no una cantidad. Se utilizan para clasificar o agrupar observaciones.
- En este tipo de datos no se pueden realizar operaciones matemáticas como sumas o promedios.

Subtipos:

- Categóricos **ordinales**.
- Categóricos **nominales**.





## NOMINALES

- No tienen orden lógico ni jerarquía.
- Solo permiten identificar categorías diferentes.
- Ejemplos: **tipo de producto** (bebidas, alimentos, limpieza), **género** (masculino, femenino, otro), **área laboral** (marketing, contabilidad, producción).



## ORDINALES

- Tienen categorías que pueden ordenarse o jerarquizarse, aunque la diferencia entre ellas no sea cuantificable.
- Ejemplos: **nivel de satisfacción** (bajo, medio, alto), **nivel educativo** (secundaria, técnico, universitario, posgrado), **evaluación de desempeño** (insatisfactorio, aceptable, excelente).

## DATOS NUMÉRICOS O CUANTITATIVOS

- Son aquellos que expresan cantidades medibles y permiten realizar operaciones aritméticas.
- Se utilizan para calcular promedios, dispersiones, correlaciones, modelos predictivos, etc.

Subtipos:

- Numéricos **discretos**.
- Numéricos **continuos**.



## DISCRETOS

- Son números enteros que resultan de contar.
- No pueden tener valores decimales.
- Ejemplos: número de clientes atendidos en un día, cantidad de errores en un proceso, número de cursos aprobados por un alumno.

## CONTINUOS

- Pueden tomar valores decimales dentro de un rango.
- Se obtienen por medición, no por conteo.
- Ejemplos: peso de un producto (1.25 kg), tiempo de atención (7.3 minutos), temperatura (22.8 °C), ingreso mensual (\$/3452.75).



**Conocer los tipos de datos es el primer paso en cualquier proyecto de análisis estadístico o de minería de datos.**

**Identificar correctamente la naturaleza de las variables permite:**

- ✓ Evitar errores metodológicos.
- ✓ Escoger las herramientas estadísticas adecuadas.
- ✓ Comunicar los resultados de manera clara y profesional.

+

DISTRIBUCIÓN DE DATOS:  
**NORMAL, SESGADA,  
KURTOSIS**

## IMPORTANCIA DEL ANÁLISIS DE LA DISTRIBUCIÓN DE DATOS

- La distribución de datos describe cómo se comportan los valores de una variable dentro de un conjunto de datos.
- Analizar la distribución nos permite observar si los datos se concentran alrededor de un valor central, si están dispersos, si hay valores extremos o si presentan algún tipo de sesgo.





## IMPORTANCIA DEL ANÁLISIS DE LA DISTRIBUCIÓN DE DATOS

- Comprender la distribución es fundamental antes de aplicar cualquier análisis porque las conclusiones estadísticas dependen de la forma en que los datos están distribuidos.





+

En data mining y análisis predictivo, este paso es conocido como análisis exploratorio de datos (EDA). Además, es esencial para limpiar, transformar y modelar correctamente la información.

## DISTRIBUCIÓN NORMAL O SIMÉTRICA

La distribución normal, también llamada **campana de Gauss**, es una curva simétrica donde la mayoría de los valores se concentran alrededor de la media y las frecuencias disminuyen progresivamente hacia los extremos.

- La **media, mediana y moda** coinciden.
- Se caracteriza por su forma de **campana suave y equilibrada**.




## DISTRIBUCIÓN NORMAL O SIMÉTRICA

Una distribución normal permite aplicar métodos estadísticos clásicos, como intervalos de confianza, pruebas t o ANOVA, que suponen este tipo de comportamiento.

### Ejemplo:

- En una evaluación de 100 alumnos, la media fue 14, con la mayoría concentrada entre 12 y 16.
- Entonces, tendríamos una distribución aproximadamente normal y un desempeño académico homogéneo.



## DISTRIBUCIÓN SESGADA (ASIMÉTRICA)

Una distribución es sesgada cuando los datos no son simétricos respecto a la media. Existen dos tipos de sesgo:

| Tipos de sesgo                  | Descripción                                                                  | Ejemplo típico                                                            |
|---------------------------------|------------------------------------------------------------------------------|---------------------------------------------------------------------------|
| Sesgo positivo (a la derecha)   | La cola se extiende hacia valores mayores. La media es mayor que la mediana. | Ingresos mensuales: la mayoría gana poco, pero hay pocos que ganan mucho. |
| Sesgo negativo (a la izquierda) | La cola se extiende hacia valores menores. La media es menor que la mediana. | Calificaciones en un examen fácil: la mayoría obtiene notas altas.        |


## DISTRIBUCIÓN SESGADA (ASIMÉTRICA)

Identificar el sesgo ayuda a elegir la medida más representativa:

- En **sesgo positivo**: la mediana refleja mejor el comportamiento típico.
- En **sesgo negativo**: también se prefiere la mediana o los cuartiles en lugar de la media.

### Ejemplo:

En una encuesta sobre ingresos mensuales, la media fue S/3000, pero la mediana fue S/2200. Esto indica un sesgo positivo, con pocos empleados que ganan mucho más que el promedio.





## KURTOSIS O FORMA DE LA CONCENTRACIÓN


La kurtosis (o curtosis) mide el grado de concentración o dispersión de los valores alrededor de la media; es decir, qué tan “picuda” o “aplanada” es la distribución.

| Tipo de distribución | Descripción                             | Interpretación práctica                                                    |
|----------------------|-----------------------------------------|----------------------------------------------------------------------------|
| Mesocúrtica          | Distribución normal (campana estándar). | Los datos tienen variabilidad media.                                       |
| Leptocúrtica         | Pico muy alto y angosto.                | Los datos están muy concentrados alrededor de la media. Baja variabilidad. |
| Platicúrtica         | Pico bajo y ancho.                      | Los datos están más dispersos. Alta variabilidad.                          |

## Ejemplos:

- En calidad industrial, una **distribución leptocúrtica** indica que la mayoría de productos cumple las especificaciones (baja variación).
- En educación, una **distribución platicúrtica** en notas muestra diferencias grandes entre estudiantes.
- En análisis financiero, una **leptocúrtica** puede indicar un mercado estable; una platicúrtica, alta volatilidad
- Si en una prueba estandarizada los puntajes de los alumnos presentan una **distribución leptocúrtica**, indica que existe baja dispersión y posible homogeneidad en el aprendizaje.



A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

# + **CONCLUSIONES**



- + La estadística descriptiva constituye una herramienta esencial para sintetizar grandes volúmenes de información, permitiendo identificar patrones, comportamientos y variaciones en los datos. A través de sus medidas y gráficos, los analistas pueden obtener una comprensión clara del fenómeno estudiado.
- + En contextos empresariales, su aplicación facilita la toma de decisiones basadas en evidencia. Comprender las medidas de tendencia, dispersión y la forma de distribución de los datos es indispensable para interpretar resultados y desarrollar estrategias fundamentadas en información cuantitativa confiable.





x



x



+

# BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Mesa Guerrero, J. A., & Caicedo Zambrano, S. J. (2020). *Introducción a la estadística descriptiva*. Universidad de Nariño.
- + Pedroza-Escobar, D., Castillo-Maldonado, I., & Serrano-Gallardo, L. B. (2020). *Estadística Descriptiva: Introducción y Prácticas*. Editorial Académica Española.
- + Larios Ramírez, O. S., & Fiestas Elías, F. J. (2023). *Estadística descriptiva con Excel*. Universidad César Vallejo.



**ISIL+**