

+ TEMA 03

ANÁLISIS EXPLORATORIO DE DATOS

- Identificación de patrones: tendencias, ciclos
- Detección de anomalías: valores atípicos, errores
- Correlaciones: Pearson, Spearman, análisis bivariado
- Visualizaciones: gráficos de dispersión, heatmaps
- Herramientas para EDA: software estadístico, bibliotecas





+ INTRODUCCIÓN **DE LA SESIÓN**

- + El análisis exploratorio de datos (EDA) permite comprender la estructura, comportamiento y calidad de los datos antes de aplicar modelos o técnicas avanzadas.
- + Mediante el EDA se identifican relaciones, patrones y características relevantes que influyen en la toma de decisiones. Su correcta ejecución garantiza mayor precisión en los resultados y disminuye riesgos en la interpretación de los datos.
- + El EDA no busca probar hipótesis estrictas, sino abrir la exploración para descubrir comportamientos inesperados y detectar problemas que podrían afectar la calidad del análisis. Aquí se combinan técnicas gráficas, estadísticas y computacionales para obtener una visión integral del dataset.



+

IDENTIFICACIÓN DE

PATRONES:

TENDENCIAS Y CICLOS

RELACIONES DE DATOS EN EDA

- La identificación de patrones es una etapa esencial del **análisis exploratorio de datos (EDA)** y consiste en reconocer comportamientos sistemáticos dentro de un conjunto de datos, especialmente cuando estos están organizados en el tiempo.
- Las relaciones de datos, o las conexiones entre variables, son cruciales para comprender la dinámica de causa y efecto. Identificar estas relaciones facilita el desarrollo de tácticas y soluciones específicas.



PATRONES EN LOS DATOS

- Los patrones son estructuras o secuencias recurrentes presentes en los datos. Son patrones o similitudes discernibles que pueden descubrirse mediante herramientas de análisis de datos.
- Reconocer patrones permite a los analistas obtener un conocimiento básico de los datos, lo que facilita el modelado predictivo y la identificación de anomalías.
- Según la naturaleza de los datos, los patrones pueden adoptar diferentes formas y las más comunes son: **tendencia** (trend) y **ciclos o estacionalidad**.



PATRONES EN LOS DATOS

- Según la naturaleza de los datos, los patrones pueden adoptar diferentes formas y las más comunes son las siguientes:

▶ **TENDENCIA (TREND)**

▶ **CICLOS O ESTACIONALIDAD**



TENDENCIA (TREND)

- La **tendencia** describe un comportamiento de largo plazo de una variable que puede ser creciente, decreciente o estable.
- Representa la dirección general que sigue una serie de datos, aun cuando existan fluctuaciones intermedias.
- Según Montgomery, Jennings y Kulahci (2020), la identificación de tendencias es vital para comprender la evolución de un proceso y para realizar proyecciones razonables.



MÉTODOS PARA IDENTIFICAR TENDENCIAS

+ 01.

Visualización de series temporales

- Se grafican los datos en función del tiempo para observar su dirección general.
- Los gráficos más comunes son los de líneas, que conectan puntos de datos a lo largo del tiempo, pero también se pueden usar gráficos de dispersión (gráficas de retardo) y de columnas.
- Estas visualizaciones son cruciales para entender el comportamiento pasado y predecir valores futuros.




MÉTODOS PARA IDENTIFICAR TENDENCIAS

+ 02.

Promedios móviles

- Son una técnica estadística que consiste en calcular el promedio de un conjunto de datos dentro de una ventana que se mueve a lo largo del tiempo.
- Su objetivo principal es suavizar las fluctuaciones de una serie de datos y facilitar la identificación de tendencias.
- Por ejemplo, es de utilidad para detectar el comportamiento real de ventas mensuales sin las fluctuaciones diarias y evaluar el desempeño de campañas




MÉTODOS PARA IDENTIFICAR TENDENCIAS

+ 02.

Promedios móviles

¿Para qué se usan?

- Identificar tendencias (crecientes, decrecientes o estables).
- Reducir el “ruido” o variabilidad aleatoria de los datos.
- Hacer pronósticos simples.
- Observar patrones estacionales.
- Mejorar la interpretación gráfica en series de tiempo.



MÉTODOS PARA IDENTIFICAR TENDENCIAS

+ 03.

Ajuste de regresión lineal

Es un método que consiste en encontrar una línea recta que mejor se ajuste a un conjunto de datos, de manera que describa cómo cambia una variable (por ejemplo, ventas, producción, tráfico web) conforme avanza el tiempo. La línea se conoce como recta de tendencia.


Modelo matemático:

$$Y = \beta_0 + \beta_1 X$$

Si $\beta_1 > 0$: tendencia creciente

Si $\beta_1 < 0$: tendencia decreciente

Si $\beta_1 = 0$: no hay tendencia




MÉTODOS PARA IDENTIFICAR TENDENCIAS

+ 03.

Ajuste de regresión lineal

La regresión lineal:

- Suaviza la serie y permite ver una tendencia clara.
- Permite cuantificar el cambio promedio por periodo.
- Facilita predicciones simples.
- Ayuda a evaluar el impacto de políticas, campañas o estacionalidad.
- Es base para técnicas más avanzadas (ARIMA, suavizamiento exponencial, machine learning).



EJEMPLO: TENDENCIA (VENTAS DE UNA EMPRESA DE E-COMMERCE)

Durante los últimos 5 años, una empresa de comercio electrónico ha registrado sus ventas trimestrales. Al graficar los datos, se observa que, aunque existen pequeñas subidas y bajadas, la línea general muestra un crecimiento constante.



Incluso en trimestres con promociones o bajas temporales, la tendencia mantiene una dirección ascendente. Esto indica que la empresa está ampliando su mercado y consolidando su presencia digital.

EJEMPLO: TENDENCIA (VENTAS DE UNA EMPRESA DE E-COMMERCE)


El análisis de la tendencia se complementa aplicando un promedio móvil de 4 trimestres, que suaviza las fluctuaciones y permite observar con mayor claridad el crecimiento real de las ventas.



Para cuantificar esta tendencia, se utiliza un modelo de regresión lineal, en que el tiempo predice el nivel de ventas; la pendiente del modelo indica cuánto aumentan las ventas en promedio por periodo.

Este análisis permite a la empresa estimar cuántos clientes podría tener el siguiente año, planificar inventario y prever necesidades logísticas.

EJEMPLO: TENDENCIA (VENTAS DE UNA EMPRESA DE E-COMMERCE)



La tendencia nos permite ver la dirección general de una variable a lo largo del tiempo. Aunque existan fluctuaciones, la tendencia revela si estamos creciendo, disminuyendo o manteniéndonos estables. Es esencial para planificar y tomar decisiones estratégicas.

CICLOS O ESTACIONALIDAD

- Los **ciclos** representan fluctuaciones que ocurren de manera periódica debido a factores como estacionalidad, variables económicas o comportamientos del consumidor.
- A diferencia de la tendencia, los ciclos tienen movimientos repetitivos alrededor de un valor medio.
- Gujarati y Porter (2021) señalan que los ciclos suelen ser característicos de actividades económicas y comerciales.



MÉTODOS PARA IDENTIFICAR CICLOS

+ 01.

Descomposición de series temporales

Proceso que separa una serie de datos en sus componentes principales:

- Tendencia (dirección general).
- Estacionalidad (patrones que se repiten).
- Ciclo (fluctuaciones más largas).
- Ruido (variación aleatoria).



MÉTODOS PARA IDENTIFICAR CICLOS

+ 02.

Índices estacionales

Miden variaciones típicas por periodo (meses, trimestres).

+ 03.

Promedios móviles centrados

Utilizados para suavizar la serie y detectar repeticiones estructurales



EJEMPLO: IDENTIFICACIÓN DE UN CICLO EN EL CONSUMO ENERGÉTICO ANUAL

- En una empresa industrial se registró el consumo energético mensual para analizar si existen patrones cíclicos que se repiten cada año.
- Los valores observados muestran incrementos progresivos durante los meses cálidos (debido a mayor uso de sistemas de refrigeración) y disminuciones en meses fríos (por menor actividad operativa).
- Este comportamiento permite identificar un ciclo anual, útil para planificar presupuestos energéticos y ajustar estrategias de eficiencia.

Mes	Consumo (kWh)
Enero	310
Febrero	300
Marzo	270
Abril	230
Mayo	200
Junio	180
Julio	190
Agosto	210
Septiembre	240
Octubre	280
Noviembre	320
Diciembre	340

EJEMPLO: IDENTIFICACIÓN DE UN CICLO EN EL CONSUMO ENERGÉTICO ANUAL

Descripción del patrón cíclico:

- 01 **Verano (diciembre-marzo):** mayor consumo energético por temperaturas más altas y mayor uso de ventilación y refrigeración.
- 02 **Otoño (marzo-junio):** el consumo disminuye gradualmente al bajar la temperatura y reducirse las necesidades de climatización.
- 03 **Invierno (junio-septiembre):** se observa el punto mínimo de consumo energético.
- 04 **Primavera (septiembre-diciembre):** el consumo vuelve a incrementarse por el aumento de la temperatura, reactivando la demanda energética.

Mes	Consumo (kWh)
Enero	310
Febrero	300
Marzo	270
Abril	230
Mayo	200
Junio	180
Julio	190
Agosto	210
Septiembre	240
Octubre	280
Noviembre	320
Diciembre	340

APLICACIONES E IMPORTANCIA PROFESIONAL

- + **Análisis de tendencias en activos financieros para decisiones de inversión.**
- + **Detectar ciclos estacionales ayuda a optimizar campañas, presupuestos y promociones.**
- + **Observar ciclos cambiarios para gestión de riesgo.**
- + **La identificación de patrones guía la elección de modelos predictivos y reduce errores en pronósticos.**
- + **La identificación de patrones de crecimiento y fases de contracción permite planificar estrategias operativas.**




+

DETECCIÓN DE ANOMALÍAS:
**VALORES ATÍPICOS Y
ERRORES**


¿QUÉ ES UNA ANOMALÍA?

- Una **anomalía** es un dato que no sigue el patrón esperado del resto del conjunto.
- En estadística, se denomina **valor atípico (outlier)** a una observación que se sitúa muy por encima o por debajo del rango habitual de los datos. Detectarlas evita conclusiones equivocadas, ya que pueden distorsionar promedios, varianzas, correlaciones y modelos predictivos



¿QUÉ ES UNA ANOMALÍA?

- La **detección de anomalías** es una etapa fundamental del análisis exploratorio de datos (EDA), ya que permite identificar observaciones que se alejan notablemente del comportamiento general del conjunto de datos.
- Estas anomalías pueden deberse a errores en la captura o registro, cambios inesperados en el proceso, comportamientos excepcionales o situaciones que requieren atención para una correcta interpretación de los análisis posteriores (Montgomery & Runger, 2021).



TIPOS DE ANOMALÍAS

Valores atípicos verdaderos

- Son datos reales que representan una situación poco común, pero correcta.
- Por ejemplo, en un negocio, un cliente puede realizar una compra muy elevada por única vez debido a una promoción especial.

Errores o anomalías por registro

- Son datos incorrectos generados por fallas en el sistema, errores humanos o problemas en los sensores.
- Por ejemplo, registrar S/5,000 de venta cuando debió ser S/500.

MÉTODOS PARA DETECTAR ANOMALÍAS

+ 01.

Método del rango intercuartílico (IQR)

Es uno de los métodos más usados por su simplicidad. Se calcula:

Q1: primer cuartil

Q3: tercer cuartil

$IQR = Q3 - Q1$

Se considera atípico a todo valor que cumpla:

$X < Q1 - 1.5 (IQR)$

$X > Q3 + 1.5 (IQR)$



MÉTODO DEL RANGO INTERCUARTÍLICO (IQR): EJEMPLO

Una tienda registra sus ventas diarias (en unidades): 39, 40, 40, 41, 42, 43, 90.

Realizamos los cálculos:

- $Q1 = 40$
- $Q3 = 43$
- $IQR = Q3 - Q1 = 3$

Los límites serían:

- $\text{Inferior} = 40 - 1.5(3) = 35.5$
- $\text{Superior} = 43 + 1.5(3) = 47.5$

Conclusiones: el valor 90 está muy por encima del límite superior (47.5), por lo que es un valor atípico evidente. Puede deberse a una promoción especial o a un error de registro; debe revisarse antes de continuar con el análisis.

MÉTODOS PARA DETECTAR ANOMALÍAS

+ 02.

Método de Z-score

Mide en cuántas desviaciones estándar se aleja un dato de la media.

$$Z = \frac{x - \bar{X}}{s}$$

Se considera atípico un valor con:

$$|Z| > 3$$



MÉTODO DE Z-SCORE: EJEMPLO

Un área de soporte registra los tiempos de atención (en minutos): 8, 9, 8, 9, 10, 20.

Contamos con los datos:

- Media ($\bar{x}$) = 10.7 minutos
- Desviación estándar (s) = 4.1 minutos
- Para el valor 20:

$$Z = \frac{20 - 10.7}{4.1} = 2.27$$

Se considera atípico un valor con: $|Z| > 3$, entonces:


El Z-score de 2.27 indica un valor inusualmente alto, aunque no es extremo. Se considera una anomalía moderada: puede deberse a un caso complicado o una incidencia especial. El analista debe determinar si se mantiene o se excluye del modelo según el contexto.

MÉTODOS PARA DETECTAR ANOMALÍAS

+ 03.

Métodos visuales

- **Boxplot:** resalta valores extremos mediante los “bigotes”.
- **Histogramas:** muestran frecuencia inusual de una categoría o valor.
- **Gráficos de dispersión:** permiten ver puntos aislados del patrón general.



APLICACIONES E IMPORTANCIA PROFESIONAL

- + Es crucial para detectar fraudes, transacciones irregulares o errores contables.
- + Detectar tiempos de entrega atípicos permite identificar retrasos y errores de despacho, mejorando la eficiencia operativa.
- + Ayuda a identificar consumidores con comportamientos fuera de lo común, útiles para segmentación avanzada.
- + Eliminar o justificar anomalías evita decisiones incorrectas relacionadas con gastos, presupuestos y control interno.
- + Mejora el desempeño de modelos predictivos, evitando que valores extremos afecten la regresión, clustering o árboles de decisión.




+

CORRELACIONES:
**PEARSON, SPEARMAN,
ANÁLISIS BIVARIADO**


¿QUÉ ES LA CORRELACIÓN?

- Es una técnica estadística que nos permite entender si existe una relación entre dos o más variables, ayudando a determinar si una variable se mueve en función de otra.
- Cuando dos variables están asociadas, una de ellas nos da la información de la otra; por el contrario, si no hay asociación entre dos variables, el aumento o disminución de una de ellas no nos dice nada respecto a la otra.



ANÁLISIS BIVARIADO

- Se refiere al estudio conjunto de dos variables para comprender su comportamiento combinado.
- Incluye medidas numéricas (**correlación**), representaciones gráficas (**gráfico de dispersión**) y, en ocasiones, modelos simples (como **regresión lineal preliminar**).
- En entornos profesionales, la correlación permite identificar relaciones clave, como ventas y publicidad, satisfacción y tiempos de espera, costo y producción, o rendimiento y riesgo en finanzas. Este conocimiento ayuda a tomar decisiones basadas en evidencia.



CORRELACIÓN DE PEARSON (R)


Es un indicador que sirve para medir la relación lineal que hay entre dos variables cuantitativas. Se puede decir que mide qué tan cerca están los puntos de la nube de dispersión para formar una línea recta.

Interpretación para “r”:

r = +1 Correlación perfecta positiva: los puntos se alinean en una recta con $m > 0$.

r = 0 No existe correlación (la nube de información es muy heterogénea).

r = -1 Correlación perfecta negativa: los puntos se alinean en una recta con $m < 0$.



+ CÁLCULO EN R

Usando la función base cor()

```
cor(datos, method = "pearson")
```

Con un data frame

```
cor(datos$variable1, datos$variable2, method = "pearson")
```

Matriz de correlaciones

```
cor(datos, method = "pearson")
```

+ CÁLCULO EN PYTHON

Usando NumPy

```
import numpy as np  
np.corrcoef(x, y)[0, 1]
```

Usando Pandas

```
import pandas as pd  
df['variable1'].corr(df['variable2'], method='pearson')
```

Matriz de correlación

```
df.corr(method='pearson')
```

CORRELACIÓN DE PEARSON (R): EJEMPLO

- Una empresa desea analizar si existe una relación lineal entre el monto invertido en publicidad digital y el nivel de ventas mensuales.
- Para ello, se recopila datos de 8 meses y busca determinar si, cuando aumenta la inversión, las ventas también tienden a aumentar de manera proporcional.
- El objetivo es calcular el coeficiente de correlación de Pearson, adecuado para medir relaciones lineales entre dichas variables.

Mes	Publicidad (miles S/)	Ventas (miles S/)
1	5	42
2	7	50
3	6	47
4	8	55
5	10	62
6	9	58
7	11	65
8	12	70

+ EJEMPLO: CÁLCULO DE PEARSON EN R

```
# Datos
publicidad <- c(5, 7, 6, 8, 10, 9, 11, 12)
ventas <- c(42, 50, 47, 55, 62, 58, 65, 70)

# Coeficiente de correlación de Pearson
cor(publicidad, ventas, method = "pearson")

# Prueba estadística
cor.test(publicidad, ventas, method = "pearson")
```


+ EJEMPLO: CÁLCULO DE PEARSON EN PYTHON

```
import numpy as np
from scipy import stats

# Datos
publicidad = np.array([5, 7, 6, 8, 10, 9, 11, 12])
ventas = np.array([42, 50, 47, 55, 62, 58, 65, 70])

# Pearson
r, pvalue = stats.pearsonr(publicidad, ventas)

print("Coeficiente de Pearson:", r)
print("p-value:", pvalue)
```

CORRELACIÓN DE PEARSON (R): RESULTADO DEL EJEMPLO

El coeficiente de correlación de Pearson calculado entre la inversión en publicidad y las ventas mensuales es:


$r = 0.97$
(correlación lineal positiva muy fuerte)

- El valor obtenido indica una relación lineal casi perfecta: cuando la empresa incrementa su inversión en publicidad, las ventas aumentan de manera consistente y proporcional.
- La publicidad digital tiene un impacto directo y altamente efectivo sobre el nivel de ventas, por lo que continuar o ampliar la inversión podría ser una estrategia rentable.



CORRELACIÓN DE SPEARMAN

- Es una medida estadística que evalúa la fuerza y dirección de la relación monotónica entre dos variables; es decir, si ambas suben o bajan consistentemente sin exigir linealidad.
- Usa rangos en lugar de valores originales, por lo que es más robusta frente a valores atípicos y distribuciones no normales.




CORRELACIÓN DE SPEARMAN

A diferencia de la correlación de Pearson, que requiere relaciones lineales y variables cuantitativas continuas, Spearman se basa en rangos y es adecuada para los siguientes datos:

- **Ordinales.**
- **No lineales, pero con tendencia constante creciente o decreciente.**
- **Con outliers porque el ranking reduce su impacto.**
- **Con distribuciones no normales.**

Spearman no mide cuánto cambia una variable respecto a otra, sino si, al aumentar una variable, la otra tiende también a aumentar o disminuir de manera consistente.



CORRELACIÓN DE SPEARMAN

El valor de Spearman va de -1 a 1 , donde:

- $\rho_s \approx 1 \rightarrow$ relación monotónica positiva perfecta.
- $\rho_s \approx -1 \rightarrow$ relación monotónica negativa perfecta.
- $\rho_s \approx 0 \rightarrow$ no existe relación monotónica.

Una relación puede ser curvilínea y tener Pearson = 0, pero Spearman sí detecta la tendencia monotónica.



+ CORRELACIONES: PEARSON, SPEARMAN, ANÁLISIS BIVARIADO

+ CÁLCULO EN R

```
cor(x, y, method = "spearman")
```

+ CÁLCULO EN PYTHON

```
df['x'].corr(df['y'], method='spearman')
```

CORRELACIÓN DE SPEARMAN: EJEMPLO

- Se desea evaluar si existe una relación consistente entre el tiempo que los estudiantes dedican al estudio y el puntaje que obtienen en un examen final. Para ello, se registra las horas de estudio de ocho estudiantes durante la semana previa y se compara estos valores con sus puntajes obtenidos en la prueba.
- El objetivo es determinar si los estudiantes que estudian más tienden a obtener mejores notas en un orden similar.
- Para este análisis, se utilizará el coeficiente de correlación de Spearman, adecuado cuando los datos no siguen una relación necesariamente lineal, pero sí pueden ordenarse de menor a mayor.

Estudiante	Horas (X)	Puntaje (Y)
A	2	55
B	4	70
C	3	80
D	5	75
E	8	95
F	7	90
G	6	85
H	1	50

+ EJEMPLO: CÁLCULO DE SPEARMAN EN R

```
# Datos
x <- c(2, 4, 3, 5, 8, 7, 6, 1)
y <- c(55, 70, 80, 75, 95, 90, 85, 50)

# Correlación Spearman
cor(x, y, method = "spearman")

# Valor p
cor.test(x, y, method = "spearman")
```


+ EJEMPLO: CÁLCULO DE SPEARMAN EN PYTHON

```
import numpy as np
from scipy import stats

# Datos
x = np.array([2, 4, 3, 5, 8, 7, 6, 1])
y = np.array([55, 70, 80, 75, 95, 90, 85, 50])

# Correlación de Spearman
rho, pvalue = stats.spearmanr(x, y)

print("Spearman rho:", rho)
print("p-value:", pvalue)
```

CORRELACIÓN DE SPEARMAN (R): RESULTADO DEL EJEMPLO

El coeficiente de correlación de Spearman calculado entre las horas de estudio y el puntaje del examen es:

$$\rho = 0.93$$

(correlación positiva muy fuerte)

- Esto indica que los estudiantes que estudian más tienden a obtener puntajes más altos, manteniendo un orden muy similar entre ambas variables.
- En otras palabras, a mayor número de horas invertidas en estudio, mayor es el rendimiento esperado en el examen.



+

VISUALIZACIONES:

**GRÁFICOS DE DISPERSIÓN,
HEATMAPS**

¿QUÉ ES LA VISUALIZACIÓN DE DATOS?

- Es una herramienta esencial en el análisis exploratorio de datos (EDA), ya que permite transformar información numérica en representaciones gráficas que facilitan la comprensión de patrones, relaciones y comportamientos en los datos.
- Un gráfico adecuado puede revelar tendencias, agrupamientos, anomalías y correlaciones que no son evidentes mediante tablas o estadísticas descriptivas.




VISUALIZACIONES CLAVE EN EL EDA

- Dentro del EDA, dos de las visualizaciones más importantes son el gráfico de dispersión (**scatterplot**) y el mapa de calor (**heatmap**).
- El **scatterplot** muestra la relación entre dos variables cuantitativas mediante puntos, mientras que el **heatmap** utiliza colores para representar intensidades o valores en matrices, siendo ideal para visualizar matrices de correlación o distribuciones bidimensionales.




GRÁFICO DE DISPERSIÓN (SCATTERPLOT)

- Es una visualización que representa dos variables cuantitativas en un plano cartesiano.
- Cada punto indica la posición de una observación respecto a las dos variables.



HEATMAP (MAPA DE CALOR)

- Es una matriz gráfica donde los valores se representan mediante colores.
- En EDA se usa especialmente para visualizar matrices de correlación, ya que permite identificar rápidamente relaciones fuertes o débiles entre variables.



EJEMPLO: EVALUACIÓN DEL IMPACTO DEL PRESUPUESTO DE MARKETING EN LAS VENTAS

Una empresa de retail desea analizar si el incremento del presupuesto de marketing está generando un impacto real en los resultados comerciales.



Para ello, ha recopilado datos de cinco meses consecutivos, registrando el monto invertido en marketing, las ventas obtenidas, el tráfico al sitio web y el porcentaje de conversión.



El objetivo del análisis es visualizar la relación entre las variables, especialmente entre marketing (USD) y ventas, con el fin de comprobar si existe una asociación positiva que justifique continuar o aumentar la inversión.



Además, se busca evaluar la correlación general entre todas las variables mediante un heatmap, lo que permitirá identificar qué indicadores se mueven conjuntamente.

EJEMPLO: EVALUACIÓN DEL IMPACTO DEL PRESUPUESTO DE MARKETING EN LAS VENTAS

Usaremos las dos visualizaciones fundamentales del EDA: **gráfico de dispersión** para detectar tendencias y relaciones entre dos variables, y **heatmap** para interpretar rápidamente la fuerza de correlación entre múltiples indicadores.

Mes	Marketing (USD)	Ventas	Visitas web	Conversión
1	5,000	120	15,000	3.2
2	7,000	150	18,000	3.5
3	9,000	180	20,000	4.0
4	11,000	210	24,000	4.1
5	13,000	230	26,000	4.3

+ DESARROLLO EN R

```
# Datos
data <- data.frame(
  Marketing_USD = c(5000,7000,9000,11000,13000),
  Ventas = c(120,150,180,210,230),
  VisitasWeb = c(15000,18000,20000,24000,26000),
  Conversion = c(3.2,3.5,4.0,4.1,4.3)
)

# Gráfico de dispersión
plot(data$Marketing_USD, data$Ventas,
  main="Relación entre Marketing y Ventas",
  xlab="Marketing (USD)", ylab="Ventas")

# Matriz de correlación
cor_matrix <- cor(data)
cor_matrix

# Heatmap
heatmap(cor_matrix)
```

+ DESARROLLO EN PYTHON

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Datos
data = pd.DataFrame({
    "Marketing_USD": [5000,7000,9000,11000,13000],
    "Ventas": [120,150,180,210,230],
    "VisitasWeb": [15000,18000,20000,24000,26000],
    "Conversion": [3.2,3.5,4.0,4.1,4.3]
})

# Gráfico de dispersión
plt.scatter(data["Marketing_USD"], data["Ventas"])
plt.title("Relación entre Marketing y Ventas")
plt.xlabel("Marketing (USD)")
plt.ylabel("Ventas")
plt.show()

# Matriz de correlación
cor_matrix = data.corr()
print(cor_matrix)

# Heatmap
sns.heatmap(cor_matrix, annot=True, cmap="coolwarm")
plt.title("Heatmap de Correlaciones")
plt.show()
```

RESULTADOS DE CORRELACIÓN R

Marketing ↔ Ventas

$r \approx 0.99$ (correlación muy fuerte)

Visitas web ↔ Ventas

$r \approx 0.98$ (correlación fuerte)

Marketing ↔ Conversión

$r \approx 0.97$ (correlación moderada-fuerte)


Visitas web ↔ Conversión

$r \approx 0.96$ (correlación moderada)




INTERPRETACIÓN DEL DIAGRAMA DE DISPERSIÓN

- **Patrón claramente ascendente:** a medida que aumenta la inversión en marketing (de 5,000 a 18,000 USD), las ventas crecen de forma sostenida (de 50,000 a 140,000 USD).
- **Relación lineal fuerte:** los puntos se alinean de manera casi recta, indicando una relación directa y proporcional.
- **No se observan valores atípicos:** todos los puntos siguen el mismo patrón, lo cual sugiere consistencia en las campañas publicitarias.
- La dispersión muestra que una mayor inversión publicitaria se asocia a mayores ventas, lo que respalda estratégicamente continuar o aumentar el presupuesto.



INTERPRETACIÓN DEL HEATMAP

- **Bloques de alta correlación (tonos claros):** indican relaciones estrechas entre marketing, ventas y visitas web.
- **Marketing ↔ Ventas es la relación dominante:** esto confirma que las ventas dependen en gran medida de la inversión en campañas.
- **Visitas web también está fuertemente asociada:** más tráfico se traduce en mejores resultados comerciales.
- **La conversión presenta la menor correlación relativa:** aunque influenciada por marketing, la conversión depende también de otros factores (UX, precios, propuestas de valor, tipo de audiencia, etc.).



+

HERRAMIENTAS PARA EDA:
**SOFTWARE ESTADÍSTICO,
BIBLIOTECAS**

HERRAMIENTAS PARA EL ANÁLISIS EXPLORATORIO DE DATOS

- El análisis exploratorio de datos (EDA) requiere herramientas que permitan examinar información de forma eficiente antes de aplicar modelos estadísticos o algoritmos de minería de datos.
- Estas herramientas facilitan procesos como limpieza, organización, visualización, síntesis y detección de patrones. Su objetivo es ayudar al analista a comprender la estructura de los datos y a tomar decisiones fundamentadas.





HERRAMIENTAS PARA EL ANÁLISIS EXPLORATORIO DE DATOS

- En contextos profesionales, el uso de software especializado y bibliotecas de análisis permite trabajar con grandes volúmenes de datos, automatizar cálculos complejos y presentar información de manera clara.
- Esta etapa es crítica porque define la calidad del análisis posterior: si los datos están sucios, mal estructurados o poco entendidos, los resultados de cualquier modelo serán imprecisos o engañosos.



SOFTWARES ESTADÍSTICOS MÁS UTILIZADOS EN EDA



MICROSOFT EXCEL

Excel continúa siendo una de las herramientas más utilizadas en el análisis de datos debido a su accesibilidad y facilidad de uso. Permite lo siguiente:

- Calcular medidas descriptivas (media, mediana, varianza).
- Generar gráficos (histogramas, líneas, barras).
- Crear tablas dinámicas para explorar grandes listados.
- Aplicar filtros y segmentaciones para hallar patrones.






R está diseñado para análisis estadístico avanzado y producción de gráficos de alta calidad. Sus bibliotecas permiten manipular, explorar y visualizar datos de forma eficiente y reproducible.

Bibliotecas comunes en EDA

- **Dplyr:** limpieza y transformación de datos.
- **Ggplot2:** gráficos avanzados.
- **tidyr:** reorganización de datos.
- **summarytools, psych:** estadísticos descriptivos detallados.



PYTHON

Python es ampliamente utilizado en análisis empresarial, ciencia de datos y machine learning. Combina facilidad de programación con potentes bibliotecas para explorar datos estructurados y no estructurados.

- **Bibliotecas claves**
- **Pandas:** manejo de datos tipo tabla.
- **Numpy:** cálculos numéricos.
- **Matplotlib y Seaborn:** visualización.
- **Scipy:** análisis estadístico.



¿POR QUÉ ESTAS HERRAMIENTAS SON ESENCIALES EN EDA?

Facilitan la comprensión de los datos

- Permiten obtener descripciones rápidas: medias, rangos, valores extremos, correlaciones, distribuciones.
- Sin estas herramientas, el analista tendría que hacerlo manualmente, lo que sería ineficiente y propenso a errores.

Permiten visualizar patrones y comportamientos

- Los gráficos ayudan a detectar tendencias, ciclos, estacionalidad, clusters o relaciones no evidentes solo con una tabla.


¿POR QUÉ ESTAS HERRAMIENTAS SON ESENCIALES EN EDA?

Mejora la calidad del análisis y la toma de decisiones

- Un EDA bien hecho asegura que los modelos posteriores tengan una base sólida y que las decisiones estén sustentadas en evidencia.

Facilitan la reproducibilidad del análisis

- Especialmente en R y Python, cada paso del proceso queda registrado en el código, lo que permite replicar el análisis en futuras evaluaciones o auditorías.

A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**



x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

+ BIBLIOGRAFÍA

- + Bruce, P., Bruce, A., & Gedeck, P. (2022). *Estadística práctica para ciencia de datos con R y Python* (2.ª ed.). Marcombo.
- + Fernández-Avilés, G., & Montero, J. M. (Eds.). (2024). *Fundamentos de ciencia de datos con R*. [Editorial].
- + Toalombo Montero, M. P., Toalombo Montero, O. W., Ballesteros Torres, F. A., Hernández Dávila, C. A., & Ruiz Sarzosa, J. P. (2024). *Visualización de datos educativos y sociales con Python: Herramientas para decisiones informadas*. Editorial SciELa.



ISIL+