

+ TEMA 06

PREPARACIÓN DE DATOS

- Limpieza: eliminación de ruido, corrección de errores
- Transformación: codificación, escalado de variables
- Manejo de datos faltantes: imputación, eliminación
- Normalización: z-score, min-max scaling
- Estandarización: formatos consistentes de datos





+ INTRODUCCIÓN **DE LA SESIÓN**

- + La preparación de datos es una de las etapas más importantes dentro del análisis estadístico y el data mining, ya que la calidad de los resultados depende directamente de la calidad de los datos utilizados. Aquellos mal preparados pueden conducir a conclusiones erróneas y decisiones poco confiables.
- + Los datos suelen provenir de múltiples fuentes, con errores, valores incompletos o formatos inconsistentes. Por ello, antes de aplicar cualquier técnica estadística o modelo analítico, es indispensable realizar un proceso riguroso de preparación.
- + Este proceso incluye actividades como la limpieza, transformación, manejo de datos faltantes, normalización y estandarización. Cada una de estas tareas cumple una función clave para asegurar que los datos sean comparables, coherentes y adecuados para el análisis.



+

LIMPIEZA:

**ELIMINACIÓN DE RUIDO,
CORRECCIÓN DE ERRORES**

¿QUÉ ES LA LIMPIEZA DE DATOS?

- Es el proceso mediante el **cual se identifican, corrigen o eliminan valores incorrectos, inconsistentes o irrelevantes** dentro de un conjunto de datos.
- Su objetivo es asegurar que la información represente de manera fiel la realidad que se desea analizar.



CALIDAD DE DATOS: RUIDO Y CORRECCIÓN DE ERRORES

Ruido

El ruido corresponde a datos que distorsionan el análisis como los siguientes:

- Valores extremos injustificados.
- Registros duplicados.
- Errores de digitación.


Corrección de errores

La corrección de errores implica ajustar lo siguiente:

- Valores mal ingresados.
- Inconsistencias lógicas.
- Formatos incorrectos que afectan la calidad del análisis estadístico.

IMPORTANCIA DE LA LIMPIEZA DE DATOS

- En análisis estadístico y data mining, esta etapa es esencial porque los modelos analíticos no distinguen entre datos correctos e incorrectos: **procesan todo lo disponible.**
- Esto puede generar resultados engañosos si los datos no han sido depurados adecuadamente.



IMPORTANCIA DE LA LIMPIEZA DE DATOS

- **Por ejemplo:** una empresa analiza las ventas mensuales de sus tiendas. Se detecta un valor de venta de S/500,000 cuando el promedio mensual es de S/15,000.
- Tras revisar el registro, se identifica un error de digitación. Si este valor no se corrige, distorsionará el promedio, la desviación estándar y cualquier modelo de predicción.



PROCESO DE LIMPIEZA DE DATOS

IDENTIFICACIÓN DE ERRORES Y RUIDO

- Valores fuera de rango (edad negativa, ventas excesivas).
- Registros duplicados.
- Inconsistencias entre variables.

DETECCIÓN DE VALORES ATÍPICOS (OUTLIERS)

- Uso de estadísticas descriptivas.
- Gráficos como boxplots o histogramas.

CORRECCIÓN DE ERRORES

- Ajuste manual basado en reglas del negocio.
- Reemplazo por valores válidos o estimados.

ELIMINACIÓN DE REGISTROS NO CONFIABLES

- Cuando el error no puede corregirse de forma razonable.

CASO APLICADO: LIMPIEZA DE DATOS DE VENTAS MENSUALES

- Una empresa comercial del sector retail analiza las ventas mensuales (expresadas en miles de soles) de una de sus sucursales con el propósito de evaluar su desempeño y elaborar reportes para la gerencia. **Los datos registrados corresponden a un periodo de 10 meses** y se muestran a continuación:

Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8	Mes 9	Mes 10
15	16	14	15	95	16	15	14	15	16

- Durante la revisión preliminar de la información, el analista de datos identifica un valor que se aleja significativamente del comportamiento habitual de las ventas mensuales de la sucursal. Este valor genera dudas sobre su confiabilidad y podría estar asociado a un error de digitación o registro.
- Antes de realizar cálculos estadísticos, proyecciones o análisis comparativos, vamos a realizar un proceso de limpieza de datos que permita evaluar la validez del registro.

+ DESARROLLO DEL CASO EN R

```
# Datos de ventas
ventas <- c(15, 16, 14, 15, 95, 16, 15, 14, 15, 16)
# Resumen estadístico
summary(ventas)
# Visualización para detectar outliers
boxplot(ventas, main="Detección de valores atípicos")
# Identificación de outliers usando IQR
Q1 <- quantile(ventas, 0.25)
Q3 <- quantile(ventas, 0.75)
IQR <- Q3 - Q1

outliers <- ventas[ventas < (Q1 - 1.5 * IQR) | ventas > (Q3 + 1.5 * IQR)]
outliers

# Eliminación del valor atípico
ventas_limpias <- ventas[ventas <= (Q3 + 1.5 * IQR)]

# Nuevo resumen
summary(ventas_limpias)
```


+ DESARROLLO DEL CASO EN PYTHON

```
import numpy as np
import matplotlib.pyplot as plt

# Datos de ventas
ventas = np.array([15, 16, 14, 15, 95, 16, 15, 14, 15, 16])
# Estadísticos básicos
print("Promedio original:", np.mean(ventas))
# Boxplot para detectar outliers
plt.boxplot(ventas)
plt.title("Detección de valores atípicos")
plt.show()

# Cálculo del IQR
Q1 = np.percentile(ventas, 25)
Q3 = np.percentile(ventas, 75)
IQR = Q3 - Q1
# Eliminación del outlier
ventas_limpias = ventas[ventas <= (Q3 + 1.5 * IQR)]

print("Promedio limpio:", np.mean(ventas_limpias))
```



- Mediante el boxplot **identificamos un valor atípico en las ventas mensuales, el cual no sigue el comportamiento habitual de la sucursal.**
- Si nos enfocamos en el rango normal de los datos, se observa que las ventas son estables y presentan baja variabilidad, lo que facilita una interpretación más precisa del desempeño real del negocio.

+

TRANSFORMACIÓN:
**CODIFICACIÓN,
ESCALADO DE VARIABLES**


¿QUÉ ES LA TRANSFORMACIÓN DE DATOS?

- Es el proceso mediante el cual **las variables originales son modificadas para que puedan ser utilizadas de manera eficiente en el análisis estadístico** y en los modelos de data mining.
- Su finalidad es convertir los datos en una forma adecuada para el procesamiento matemático y computacional.



¿QUÉ ES LA TRANSFORMACIÓN DE DATOS?

- Este proceso es importante porque muchos métodos estadísticos y algoritmos de aprendizaje automático no trabajan directamente con datos cualitativos ni con variables que presentan escalas muy diferentes.
- Por ello, **se requiere aplicar técnicas como la codificación y el escalado de variables.**



PROCESO DE TRANSFORMACIÓN DE DATOS

IDENTIFICACIÓN DEL TIPO DE VARIABLE

- Cualitativa (nominal u ordinal).
- Cuantitativa (discreta o continua).

SELECCIÓN DE LA TÉCNICA ADECUADA

- Codificación: para variables categóricas.
- Escalado: para variables numéricas.

APLICACIÓN DE LA TRANSFORMACIÓN

- Uso de métodos estadísticos (codificación ordinal, codificación dummy, discretización de variables numéricas, escalado min-max, etc.).

VALIDACIÓN DEL RESULTADO

- Verificar coherencia, interpretación y utilidad analítica.


CODIFICACIÓN DE VARIABLES

- Es el proceso mediante el cual las variables cualitativas o categóricas se transforman en valores numéricos, lo que permite su uso en:
 - **Análisis estadísticos.**
 - **Modelos predictivos.**
 - **Técnicas de data mining.**
- Dado que los métodos estadísticos trabajan con números, la codificación se vuelve indispensable para integrar información descriptiva dentro del análisis cuantitativo.



CODIFICACIÓN DE VARIABLES

- En contextos empresariales, muchas variables relevantes son de naturaleza cualitativa, como las siguientes:
 - **Tipo de cliente.**
 - **Nivel de satisfacción.**
 - **Canal de venta.**
 - **Región geográfica.**
- Sin codificación, estas variables no pueden ser procesadas matemáticamente ni utilizadas en modelos analíticos.



IDENTIFICACIÓN DE VARIABLES CUALITATIVAS PARA LA CODIFICACIÓN

- Antes de codificar, **es fundamental identificar el tipo de variable cualitativa**, ya que esto determina el método de codificación adecuado.
- Una codificación incorrecta puede generar interpretaciones erróneas y afectar la validez de los resultados estadísticos.




+ 01.

CODIFICACIÓN ORDINAL

Asigna valores numéricos respetando el orden lógico de las categorías. Este método es apropiado únicamente cuando existe una jerarquía clara entre los niveles de la variable. Por ejemplo:

Nivel de satisfacción	Código
Bajo	1
Medio	2
Alto	3




+ 02.

CODIFICACIÓN DUMMY (ONE-HOT ENCODING)

Se utiliza para variables nominales sin orden. Consiste en crear una variable binaria (0 o 1) para cada categoría, indicando presencia o ausencia. Por ejemplo:

Cliente	Minorista	Mayorista	Corporativo
C1	1	0	0
C2	0	1	0
C3	0	0	1





La codificación de variables es una etapa crítica porque permite integrar información cualitativa y cuantitativa en un mismo modelo analítico. Una correcta codificación mejora la precisión de los resultados y la interpretación de los modelos estadísticos.


ESCALADO DE VARIABLES

- Es el proceso mediante el cual **los valores numéricos de las variables se transforman para que se encuentren en rangos comparables**, sin alterar la información esencial que contienen.
- Este procedimiento es necesario porque, en los conjuntos de datos reales, las variables suelen medirse en unidades y magnitudes muy diferentes.



ESCALADO DE VARIABLES

- Por ejemplo, en un análisis empresarial pueden coexistir variables como ingresos anuales (miles de soles), número de clientes (decenas) y nivel de satisfacción (escala 1-5). **Sin escalado, las variables de mayor magnitud pueden dominar el análisis.**
- Muchos métodos estadísticos y algoritmos de data mining son sensibles a la escala de los datos, especialmente aquellos que se basan en distancias, varianzas o gradientes.



ESCALADO DE VARIABLES

Problemas sin escalado:

- Variables grandes influyen más en el modelo.
- Resultados sesgados o poco interpretables.
- Dificultad para comparar indicadores.

Ámbitos en los que es indispensable:

- Segmentación de clientes (clustering).
- Modelos predictivos.
- Análisis multivariable en finanzas y marketing.



+ 01.

ESCALADO MIN-MAX

Transforma los valores de una variable a un rango específico, normalmente entre 0 y 1.


Fórmula:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Características:

- Conserva la forma de la distribución.
- Facilita la comparación entre variables.
- Sensible a valores atípicos.

Por ejemplo, comparar ventas, ingresos y gastos para analizar el desempeño de distintas sucursales.



+ 01. ESCALADO ESTÁNDAR (Z-SCORE)

También llamado estandarización, transforma los datos para que tengan media cero y desviación estándar uno.

Fórmula:

$$Z = \frac{X - \mu}{\sigma}$$

Características:

- Reduce el efecto de escalas diferentes.
- Útil cuando los datos siguen una distribución aproximadamente normal.
- Facilita la detección de valores atípicos.

Por ejemplo, comparar rendimientos de activos con diferentes unidades o magnitudes.



+

MANEJO DE DATOS

**FALTANTES: IMPUTACIÓN,
ELIMINACIÓN**

DATOS FALTANTES

- Se presentan cuando uno o más valores no están disponibles en un conjunto de datos.
- Esta situación es común en bases de datos reales debido a lo siguiente:
 - Errores de registro.
 - Encuestas incompletas.
 - Fallas en sistemas de información.
 - Ausencia de respuesta por parte de los usuarios.




DATOS FALTANTES

- En el análisis estadístico y la minería de datos, los datos faltantes representan un problema crítico, ya que pueden:
 - **Distorsionar los resultados.**
 - **Reducir la precisión de los modelos.**
 - **Afectar la validez de las conclusiones.**
- Por ello, su identificación y tratamiento adecuado es una etapa clave dentro de la preparación de datos.




TIPOS DE DATOS FALTANTES

Desde un punto de vista estadístico, los datos faltantes pueden clasificarse de manera general en:



Comprender esta clasificación ayuda a elegir el método de tratamiento más adecuado, especialmente en análisis empresariales y financieros.



PROCESO PARA EL MANEJO DE DATOS FALTANTES

- 01 **Identificación de valores faltantes:** detección de celdas vacías, valores nulos o registros incompletos.
- 02 **Análisis del impacto:** evaluar cuántos datos faltan y en qué variables.
- 03 **Selección del método de tratamiento:** eliminación o imputación.
- 04 **Aplicación del método seleccionado:** uso de técnicas estadísticas.
- 05 **Validación del resultado:** verificar coherencia y consistencia del conjunto de datos final.

ELIMINACIÓN DE DATOS FALTANTES

Consiste en descartar registros o variables que contienen valores faltantes. Es un método simple, pero debe aplicarse con precaución. Los tipos son:

- **Eliminación por filas:** se eliminan los registros incompletos.
- **Eliminación por columnas:** se elimina la variable con muchos valores faltantes.

Ventajas y limitaciones:

- **Ventaja:** simplicidad y rapidez.
- **Limitación:** posible pérdida de información y sesgo si los faltantes no son aleatorios.



EJEMPLO DE ELIMINACIÓN POR FILAS

- Una empresa aplica una encuesta de satisfacción a 1,000 clientes. Solo 12 encuestas presentan preguntas sin responder.

Cliente	Edad	Satisfacción
C101	35	Alta
C102	NA	Media
C103	42	Alta

- En este caso, el registro **C102** se elimina del análisis. Esta acción se justifica porque el porcentaje de datos faltantes es muy bajo y su eliminación no afecta significativamente los resultados.
- Este tipo de eliminación se aplica en estudios de mercado, encuestas cortas, reportes descriptivos.

EJEMPLO DE ELIMINACIÓN POR COLUMNAS (ELIMINACIÓN DE VARIABLES)

- Una base de datos de clientes tiene la variable “ingreso secundario”, pero el 70% de los registros está vacío.

Cliente	Ingreso principal	Ingreso secundario
C1	3,000	NA
C2	4,500	NA
C3	5,200	800

- En este caso, se elimina la variable “ingreso secundario” del análisis. Esta acción se justifica porque la gran cantidad de valores faltantes hace que la variable sea poco representativa y difícil de imputar.
- Este tipo de eliminación se aplica en reportes financieros, análisis exploratorios, estudios con múltiples variables.

IMPUTACIÓN DE DATOS FALTANTES

La imputación consiste en reemplazar los valores faltantes por valores estimados, manteniendo el tamaño del conjunto de datos. Los métodos más comunes son:

Para variables numéricas.

Media o mediana

Para variables categóricas.

Moda

Usando promedios por categoría.

Imputación por grupo

Regresión o algoritmos de machine learning.

Imputación basada en modelos

EJEMPLO DE IMPUTACIÓN POR LA MEDIA (VARIABLE NUMÉRICA)

Una empresa analiza el ingreso mensual de sus clientes para segmentarlos según su poder adquisitivo. Algunos registros presentan valores faltantes.

Cliente	Ingreso (\$/)
C1	3000
C2	NA
C3	4500
C4	5000

Se reemplaza el valor faltante por la media de los ingresos disponibles:

$$\bar{X} = \frac{3000 + 4500 + 5000}{3} = 4167$$

Cliente	Ingreso (S/)
C1	3000
C2	4167
C3	4500
C4	5000



- La imputación por la media mantiene el tamaño de la muestra y permite continuar el análisis sin eliminar registros. Es adecuada cuando los datos no presentan valores extremos significativos.
- Este tipo de Imputación se aplica para análisis financiero básico, segmentación de clientes, reportes administrativos, etc.

EJEMPLO DE IMPUTACIÓN POR LA MODA (VARIABLE CATEGÓRICA)

Un área de marketing analiza el canal de compra preferido de los clientes. Algunas encuestas están incompletas.

Cliente	Canal de compra
C1	Online
C2	Tienda
C3	Online
C4	NA

Se reemplaza el valor faltante por la moda, es decir, la categoría más frecuente.

Moda=Online

Cliente	Canal de compra
C1	Online
C2	Tienda
C3	Online
C4	ONLINE



- La imputación por moda conserva la coherencia categórica del conjunto de datos y es adecuada cuando una categoría predomina claramente.
- Este tipo de imputación se aplica a estudios de mercado, análisis de comportamiento del consumidor, evaluación de campañas comerciales, etc.

+

NORMALIZACIÓN: Z-SCORE,
MIN-MAX SCALING

¿QUÉ ES LA NORMALIZACIÓN DE DATOS?

- Es un proceso estadístico que **consiste en transformar los valores numéricos de una o más variables para que se expresen en una escala común**, sin modificar la relación existente entre ellos.
- Su objetivo principal es evitar que variables con magnitudes mayores dominen el análisis o influyan de manera desproporcionada en los resultados



¿QUÉ ES LA NORMALIZACIÓN DE DATOS?

- En el análisis estadístico y en data mining, **la normalización es especialmente importante cuando se trabaja con variables medidas en diferentes unidades**, como ingresos, edades, cantidades vendidas o puntajes.
- Al normalizar, se facilita la comparación y el correcto funcionamiento de modelos analíticos.



PROCESO GENERAL DE NORMALIZACIÓN

IDENTIFICACIÓN DE VARIABLES CON DIFERENTES ESCALAS

Se revisa la base de datos para detectar variables cuyos valores se expresan en magnitudes muy distintas (por ejemplo, ingresos en miles y edades en años).

SELECCIÓN DEL MÉTODO DE NORMALIZACIÓN ADECUADO

Se elige la técnica más conveniente según el objetivo del análisis: el método z-score o el método min-max.

APLICACIÓN DE LA TRANSFORMACIÓN MATEMÁTICA

Se realiza el cálculo correspondiente para transformar los valores originales a la nueva escala, sin alterar la relación entre los datos.


VERIFICACIÓN E INTERPRETACIÓN DE LOS DATOS NORMALIZADOS

Se comprueba que los datos transformados sean coherentes y se interpretan correctamente según el método aplicado.

+ 01.

NORMALIZACIÓN MEDIANTE Z-SCORE (ESTANDARIZACIÓN ESTADÍSTICA)

- La normalización mediante z-score es una técnica estadística que transforma los valores de una variable numérica considerando su media y su desviación estándar.
- El resultado indica qué tan lejos se encuentra un dato respecto al promedio del conjunto.
- Este método no cambia la forma de la distribución de los datos, sino que los reescala, lo que permite compararlos de manera objetiva y detectar comportamientos inusuales dentro de la información analizada.



+ 01.

NORMALIZACIÓN MEDIANTE Z-SCORE (ESTANDARIZACIÓN ESTADÍSTICA)

El objetivo principal es expresar los datos en términos de desviaciones estándar para facilitar el análisis estadístico y la identificación de valores atípicos.

El valor del z-score se interpreta:


- **$Z = 0$:** el dato es igual al promedio.
- **$Z > 0$:** el dato está por encima del promedio.
- **$Z < 0$:** el dato está por debajo del promedio.
- **$|Z| \geq 2$:** el dato puede considerarse atípico o inusual.



+ 01.

NORMALIZACIÓN MEDIANTE Z-SCORE (ESTANDARIZACIÓN ESTADÍSTICA)

- Por ejemplo, una empresa registra ventas mensuales con los siguientes resultados:
 - **Promedio de ventas: $S/10,000$**
 - **Desviación estándar: $S/2,000$**
- Si en un determinado mes las ventas fueron de $S/14,000$, entonces el z-score indica que ese valor está 2 desviaciones estándar por encima del promedio.
- Entonces, podemos afirmar que ese mes se tuvo un desempeño significativamente superior al habitual, que puede deberse a una campaña exitosa, temporada alta o un evento extraordinario.



+ 01.

NORMALIZACIÓN MEDIANTE Z-SCORE (ESTANDARIZACIÓN ESTADÍSTICA)

- Su uso permite comparar datos de forma objetiva, reducir sesgos por escala y tomar decisiones basadas en el comportamiento real de la información.
- La normalización mediante z-score es ampliamente utilizada en:

Aplicaciones

```
graph LR; A[Aplicaciones] --> B[Finanzas: detección de ingresos o costos anormalmente altos o bajos.]; A --> C[Marketing: identificación de clientes con consumo fuera del patrón habitual.]; A --> D[Administración: análisis del desempeño mensual de indicadores clave.]; A --> E[Ciencia de datos: preparación de variables para modelos estadísticos y analíticos.];
```

Finanzas: detección de ingresos o costos anormalmente altos o bajos.

Marketing: identificación de clientes con consumo fuera del patrón habitual.

Administración: análisis del desempeño mensual de indicadores clave.

Ciencia de datos: preparación de variables para modelos estadísticos y analíticos.

+ 02. NORMALIZACIÓN MEDIANTE MIN-MAX SCALING

- Es una técnica que transforma los valores de una variable numérica para que se encuentren dentro de un rango específico, generalmente entre 0 y 1.
- Esta transformación conserva la proporción entre los datos originales, pero ajusta su escala.
- A diferencia del z-score, este método no utiliza la media ni la desviación estándar, sino únicamente los valores mínimo y máximo de la variable.
- El objetivo principal es facilitar la comparación directa entre valores y variables.




+ 02. NORMALIZACIÓN MEDIANTE MIN-MAX SCALING

La interpretación de los valores normalizados es intuitiva:

- **Valor cercano a 0:** desempeño bajo dentro del conjunto de datos.
- **Valor cercano a 1:** desempeño alto dentro del conjunto de datos.
- **Valor intermedio:** desempeño promedio relativo.


Este método permite analizar fácilmente la posición relativa de cada dato sin considerar sus unidades originales.



+ 02.

NORMALIZACIÓN MEDIANTE MIN-MAX SCALING

- Por ejemplo, si la empresa registra ventas mensuales con los siguientes valores:
 - **Venta mínima: S/5,000**
 - **Venta máxima: S/20,000**
- Si en un mes las ventas fueron de S/12,500, al aplicar min-max scaling el valor normalizado se ubica aproximadamente en 0.5.
- Entonces, podemos concluir que ese mes tuvo un desempeño medio en comparación con el mejor y el peor mes registrados, lo que facilita la comparación visual y analítica.



+

ESTANDARIZACIÓN: FORMATOS
CONSISTENTES DE DATOS

¿QUÉ ES LA ESTANDARIZACIÓN DE DATOS?

- Es el **proceso mediante el cual se unifican los formatos, estructuras, unidades de medida, nombres y reglas de registro de los datos**, con el objetivo de que toda la información de una organización siga criterios comunes y coherentes.
- No se refiere solo a “dar formato”, sino a definir normas claras de cómo deben capturarse, almacenarse y usarse los datos.



¿QUÉ ES LA ESTANDARIZACIÓN DE DATOS?

Estandarizar implica responder preguntas como las siguientes:

- + ¿Cómo se escribirán las fechas (dd/mm/aaaa o mm/dd/aaaa)?
- + ¿Qué moneda será la oficial del sistema?
- + ¿Se usarán mayúsculas o minúsculas en nombres?
- + ¿Cómo se codificarán los productos, clientes o países?
- + ¿Qué separador decimal se utilizará (, o .)?

Cuando no existe estandarización, los sistemas no “se entienden” entre sí, surgen errores en reportes y se dificulta la integración de bases de datos.



¿POR QUÉ LA ESTANDARIZACIÓN ES VITAL?



Reduce errores humanos y operativos.



Facilita la integración de información de múltiples áreas.



Permite automatizar reportes y tableros de control.



Mejora la calidad y confiabilidad del análisis estadístico.



Agiliza auditorías y procesos contables.



Evita interpretaciones incorrectas de los datos.



PROCESO GENERAL DE ESTANDARIZACIÓN DE DATOS

Diagnóstico	Definición de estándares	Unificación y corrección	Validación	Documentación y mantenimiento
• Identificar los distintos formatos existentes. • Detectar inconsistencias (fechas, unidades, nombres, duplicidades). • Revisar fuentes: Excel, bases SQL, sistemas transaccionales.	• Elegir formatos oficiales (moneda, fecha, nomenclaturas). • Establecer políticas y manuales de registro. • Definir diccionario de datos.	• Transformar los datos existentes al nuevo estándar. • Convertir unidades (kg → g, dólares → soles, etc.). • Corregir nombres y códigos.	• Verificar coherencia y ausencia de duplicados. • Aplicar reglas de validación automática.	• Crear lineamientos y “buenas prácticas”. • Capacitar al personal que registra información. • Auditar periódicamente los dato.

EJEMPLO:

Comercial Andina SA es una cadena peruana de tiendas que opera en Lima, Arequipa y Trujillo. Cada sede registra sus ventas en hojas Excel diferentes. Al integrar la información para el reporte nacional, la gerencia detecta las siguientes inconsistencias:

1. Formatos distintos de fecha

- Lima: dd/mm/aaaa
- Arequipa: mm-dd-aaaa
- Trujillo: aaaa/mm/dd

2. Moneda diferente

- Lima: soles (S/)
- Arequipa: dólares (USD)
- Trujillo → Soles con separador “,”

3. Codificación desigual de productos

- TV-42", tv_42, TELEVISOR42



Estas inconsistencias provocan en la empresa:

- Errores en reportes de ventas.
- Duplicación de registros.
- Cálculos de KPI incorrectos.
- Retraso en cierres mensuales.

Se sugiere a la empresa implementar un proceso de estandarización enfocado en:

- Formato único de fecha: ISO 8601 (aaaa-mm-dd).
- Moneda oficial: soles, conversión automática desde USD.
- Catálogo estándar de productos: código único alfanumérico.
- Reglas de escritura: mayúsculas sin tildes para textos.
- Validación automática antes de consolidar datos.

Resultado esperado luego de la estandarización:

- Reducción del 35% en errores de integración.
- Generación de reportes en menor tiempo.
- Decisiones comerciales más confiables.
- Base limpia para análisis estadístico y modelos de demanda.



EJEMPLO CON RESOLUCIÓN EN R Y PYTHON

La empresa Comercial Andina SA integra ventas de tres sedes y encuentra inconsistencias en los registros. Los datos son:

1. Fechas con distintos formatos:
 - 03/05/2024
 - 05-03-2024
 - 2024/03/05
2. Montos registrados en diferentes monedas:
 - 1200 en soles S/
 - 350 en USD\$
 - 500 en soles S/
3. Nombres de clientes escritos de forma diferente
 - Juan Pérez
 - JUAN PEREZ
 - J. Perez

Con R y Python vamos a estandarizar estos datos para obtener una base consistente y lista para análisis, aplicando lo siguiente:

- Conversión de fechas a un formato único (aaaa-mm-dd).
- Conversión de montos a una sola moneda (\$/).
- Homogeneización de nombres de clientes para evitar duplicidad.



+ RESOLUCIÓN EN R

```
library(dplyr)
library(stringr)
library(lubridate)
# Base de ejemplo
datos <- data.frame(
  fecha = c("03/05/2024", "05-03-2024", "2024/03/05"),
  monto = c(1200, 350, 500),
  moneda = c("S/", "USD", "S/"),
  cliente = c("Juan Pérez", "JUAN PEREZ", "J. Perez")
)
# Tipo de cambio
tc <- 3.80
# Proceso de estandarización
datos_std <- datos %>%
  mutate(fecha = dmy(fecha) %| |% mdy(fecha) %| |% ymd(fecha),
         fecha = as.Date(fecha)) %>%
  mutate(monto_soles = ifelse(moneda == "USD", monto * tc, monto)) %>%
  mutate(cliente_std = str_to_upper(cliente),
         cliente_std = str_replace_all(cliente_std, "[[:punct:]]", ""),
         cliente_std = str_squish(cliente_std))

print(datos_std)
```


+ RESOLUCIÓN EN PYTHON

```
import pandas as pd
datos = pd.DataFrame({
    "fecha": ["03/05/2024", "05-03-2024", "2024/03/05"],
    "monto": [1200, 350, 500],
    "moneda": ["S/", "USD", "S/"],
    "cliente": ["Juan Pérez", "JUAN PEREZ", "J. Perez"]
})

tc = 3.80 # tipo de cambio
datos["fecha"] = pd.to_datetime(datos["fecha"], dayfirst=True, errors="coerce")
datos["monto_soles"] = datos.apply(
    lambda x: x["monto"] * tc if x["moneda"] == "USD" else x["monto"], axis=1
)
datos["cliente_std"] = (
    datos["cliente"]
    .str.upper()
    .str.replace(r"[^w\s]", "", regex=True)
    .str.replace("\s+", " ", regex=True)
    .str.strip()
)
print(datos)
```




La estandarización no trata solo de “dar formato”, sino de crear reglas consistentes de registro y uso de datos para garantizar que toda la organización hable el mismo idioma informacional.

+ **CONCLUSIONES**



x



x



- + La preparación de datos es una fase crítica en el análisis estadístico y el data mining, ya que asegura que la información utilizada sea precisa, coherente y útil para la toma de decisiones. Sin una adecuada limpieza, transformación y tratamiento de datos, incluso las técnicas más avanzadas pueden generar resultados poco confiables.
- + Una adecuada preparación de datos incrementa significativamente la efectividad de los modelos analíticos y predictivos. Dominar estas técnicas permite a las organizaciones optimizar recursos, mejorar el análisis de indicadores clave y fortalecer estrategias basadas en evidencia. Esto consolida el uso de los datos como un activo estratégico para la competitividad empresarial.





x



x



+ BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Fernández-Avilés, G., & Montero, J. M. (Eds.). (2024). *Fundamentos de ciencia de datos con R* (1.ª ed.). Editorial Independiente.
- + Tavárez, A. (2023). *Ciencia de datos: Una guía práctica* (1.ª ed.). Editorial Académica Española.
- + Paredes Inilupu, D. (2024). *Data Science con R: Análisis de datos y algoritmos de predicción* (2.ª ed.). Editorial Leanpub.



ISIL+