

+ TEMA 07

ALGORITMOS DE MINERÍA DE DATOS


- Clasificación: árboles de decisión, SVM, k-NN
- Clustering básicos: k-means, jerárquico
- Reglas de asociación: Apriori, FP-Growth
- Evaluación de resultados: métricas como precisión, recall, silhouette
- Aplicaciones prácticas: segmentación de clientes
- Implementación: uso de





+ INTRODUCCIÓN **DE LA SESIÓN**

- + La minería de datos permite extraer patrones, tendencias y relaciones ocultas en grandes volúmenes de información, convirtiéndose en una herramienta clave para la toma de decisiones estratégicas en las organizaciones. Gracias a sus algoritmos, es posible transformar datos dispersos en conocimiento útil y accionable para diversas áreas profesionales.
- + Los algoritmos de minería de datos contribuyen al análisis avanzado y fomentan el desarrollo de habilidades analíticas en los profesionales, integrando pensamiento crítico, interpretación de resultados y uso ético de la información.
- + En el ámbito empresarial, estos algoritmos apoyan tareas como la segmentación de clientes, predicción de comportamientos de compra, detección de fraudes, análisis de riesgo y mejora de procesos operativos. Su aplicación fortalece la competitividad y la eficiencia en mercados altamente dinámicos.




+

CLASIFICACIÓN: ÁRBOLES DE
DECISIÓN,
SVM, K-NN

CLASIFICACIÓN EN MINERÍA DE DATOS


- La clasificación es una técnica de minería de datos supervisada que **consiste en asignar una categoría o etiqueta a un nuevo registro, a partir de un modelo entrenado con datos históricos.**
- Su objetivo principal es predecir comportamientos o resultados futuros, basándose en patrones previamente observados.
- Se aplica ampliamente en ámbitos como riesgo crediticio, marketing, salud, comercio electrónico, operaciones y analítica empresarial.



+ 01.

DEFINICIÓN DEL PROBLEMA Y VARIABLES:

- Esta fase es la base del modelo porque determina qué se quiere predecir, para qué y con qué información.
- Un problema de clasificación siempre parte de una variable objetivo (label o clase) que toma categorías como:
 - Sí/no.
 - Aprobado/rechazado.
 - Alto/bajo riesgo.
 - Compra/no compra, etc.



FORMULACIÓN DEL PROBLEMA	IDENTIFICACIÓN Y SELECCIÓN DE VARIABLES PREDICTORAS	EJEMPLO
Implica responder preguntas clave: • ¿Cuál es el objetivo del negocio? Ej.: reducir morosidad, identificar clientes que abandonarán el servicio, detectar fraudes. • ¿Qué decisión apoyará el modelo? Ej.: aprobar créditos, priorizar campañas, asignar límites de riesgo. • ¿Qué tipo de variable queremos predecir? Ej.: binaria, multinomial, segmentaciones. Un problema bien definido conecta objetivo empresarial + métrica + variable objetivo.	Las variables predictoras (features) deben ser relevantes, medibles y disponibles en los datos. Generalmente, provienen de: • Datos demográficos (edad, zona, ocupación). • Historial transaccional (compras, pagos, montos). • Comportamiento digital (interacciones, visitas, clics). • Variables de negocio (plazo, tipo de producto, canal). Criterios de selección de variables • Deben tener relación lógica y estadística con la variable objetivo. • Evitar variables duplicadas o irrelevantes. • Cuidar sesgos o información que no podrá usarse en producción.	Problema: predecir si un cliente caerá en mora en los próximos 3 meses. Variable objetivo: mora (sí/no). Variables predictoras: • Ingresos mensuales. • Historial de pagos. • Nivel de endeudamiento. • Antigüedad del cliente. • Número de créditos activos. El modelo permitirá priorizar acciones preventivas y estrategias de cobranza.

+ 02.

DIVISIÓN DEL CONJUNTO DE DATOS:

- Una vez definidos el problema y las variables, los datos se deben dividir para entrenar el modelo y luego evaluarlo correctamente, evitando que “memorice” los datos.
 - **El conjunto de entrenamiento (training set)** se usa para que el modelo aprenda los patrones.
 - **El conjunto de prueba (testing set)** Se usa para validar desempeño con datos no vistos.
- Esto simula el escenario real donde el modelo se aplicará a nuevos casos.



PROPORCIONES COMUNES DE DIVISIÓN	ESTRATIFICACIÓN EN PROBLEMAS DESBALANCEADOS	EJEMPLO
Las configuraciones más usadas son: • 70% entrenamiento – 30% prueba. • 80% entrenamiento – 20% prueba. • 75% entrenamiento – 25% prueba. La elección depende del tamaño del dataset: • Si hay muchos datos, se puede destinar menos porcentaje al entrenamiento. • Si hay pocos datos, se usan técnicas adicionales como validación cruzada (k-fold).	Cuando una clase aparece mucho más que otra, por ejemplo: 95% clientes que pagan vs. 5% morosos, la división debe ser estratificada; es decir, mantener el mismo porcentaje de clases en ambos conjuntos. Esto evita modelos que aprenden solo de la clase mayoritaria.	Dataset: 10,000 clientes de una institución financiera. Variable objetivo: mora sí/no. División 80/20 • 8,000 registros - entrenamiento. • 2,000 registros - prueba. El modelo se entrena con 8,000 casos y, luego, se evalúa si generaliza bien cuando clasifica los 2,000 registros restantes. Si el rendimiento es alto en entrenamiento, pero bajo en prueba, existe sobreajuste (overfitting) y el modelo debe ajustarse.

+ 03.

ENTRENAMIENTO DEL MODELO:

- El entrenamiento consiste en que el algoritmo aprende patrones a partir del conjunto de datos de entrenamiento.
- Durante esta fase, el modelo ajusta sus parámetros internos para minimizar el error en la predicción de la variable objetivo.
- Aprender para el modelo significa analizar relaciones entre las variables predictoras y la clase objetivo.



+ 04.

VALIDACIÓN Y EVALUACIÓN DEL MODELO:

Una vez entrenado, el modelo debe evaluarse con datos no utilizados en el entrenamiento. Esta fase determina si el modelo es:


- Confiable.
- Útil para decisiones reales.
- Robusto frente a nuevos datos.



+ 05.


IMPLEMENTACIÓN Y USO PRÁCTICO DEL MODELO:

- En la etapa de implementación, el modelo deja de ser un ejercicio y se convierte en una herramienta real para la toma de decisiones.
- Un modelo no es estático y debe monitorearse periódicamente porque los patrones de negocio cambian (concept drift).
- Se revisan indicadores como caída del rendimiento, cambios en comportamiento de clientes y nuevas variables relevantes. Cuando el modelo pierde desempeño, se debe actualizar las variables y datos.



ÁRBOLES DE DECISIÓN

- Son modelos de clasificación supervisada que representan el proceso de decisión mediante una **estructura jerárquica formada por nodos, ramas y hojas**.
- Cada nodo corresponde a una regla de partición sobre una variable predictora, y cada hoja representa una clase final asignada al registro analizado.
- El objetivo del algoritmo es dividir los datos en subconjuntos cada vez más homogéneos, de modo que las observaciones dentro de cada grupo compartan características similares.



PROCESO DE CONSTRUCCIÓN DE UN ÁRBOL DE DECISIÓN

SELECCIÓN DE LA VARIABLE INICIAL

- El algoritmo evalúa todas las variables predictoras y elige aquella que genera la mejor separación entre clases.

DIVISIÓN RECURSIVA DE LOS NODOS

- Cada subconjunto vuelve a dividirse siguiendo el mismo criterio. Este proceso continúa hasta cumplir una condición de parada.

CRITERIOS DE DETENCIÓN


- Profundidad máxima del árbol.
- Número mínimo de registros por nodo.
- Mejora mínima requerida en la pureza.

PODA DEL ÁRBOL (PRUNING)

- Se eliminan ramas que aportan poca mejora para evitar sobreajuste.
- Se busca un equilibrio entre precisión y simplicidad del modelo.


*La poda es esencial para garantizar que el árbol generalice correctamente y no memorice los datos del entrenamiento.

EJEMPLO: ENVÍOS DE MERCADERÍA




SVM - MÁQUINAS DE VECTORES DE SOPORTE

- Las **máquinas de vectores de soporte** (SVM, support vector machines) son algoritmos de clasificación supervisada que buscan encontrar el hiperplano óptimo que separa las clases con la mayor distancia posible entre ellas, conocida como margen máximo.
- La idea central es lograr una frontera de decisión que no solo clasifique correctamente los datos de entrenamiento, sino que también tenga una alta capacidad de generalización para nuevos datos.



SVM - MÁQUINAS DE VECTORES DE SOPORTE

- En términos prácticos, **el modelo identifica los puntos críticos que se encuentran más cerca de la frontera de separación.**
- Estos puntos se denominan vectores de soporte y son los que determinan la posición final del hiperplano.
- Gracias a este principio, **SVM es especialmente robusto frente a ruido y valores atípicos**, lo que lo convierte en una técnica confiable en contextos empresariales y analíticos.



PROCESO GENERAL DE UN MODELO SVM

1

NORMALIZACIÓN Y PREPARACIÓN DE DATOS

Se escalan las variables para evitar que atributos con mayor magnitud dominen el modelo (ejemplo: ingresos vs. número de compras).

2

SELECCIÓN DEL TIPO DE SVM Y DEL KERNEL

- Lineal: los datos se separan con una recta.
- Polinomial: las relaciones entre variables son no lineales.

3

AJUSTE DEL MARGEN (PARÁMETRO C)

- C alto: modelo más estricto, menor tolerancia a errores.
- C bajo: mayor tolerancia al ruido, mayor generalización.

4

ENTRENAMIENTO Y OBTENCIÓN DEL HIPERPLANO ÓPTIMO

El modelo identifica el hiperplano que maximiza la separación entre clases mediante los vectores de soporte.

5

VALIDACIÓN Y EVALUACIÓN

Se miden métricas como precisión, recall y F1-score.

6

IMPLEMENTACIÓN Y USO OPERATIVO


El modelo se aplica sobre nuevos casos para apoyar la toma de decisiones.



SVM es valorado porque funciona bien incluso con pocos datos, pero alta dimensionalidad, algo común en entornos empresariales en que las bases de datos no siempre son masivas, pero sí poseen múltiples variables.


K-NN (K-NEAREST NEIGHBORS)

- El algoritmo k-Nearest Neighbors (k-NN) es una técnica de clasificación supervisada basada en la idea de que **un elemento nuevo tiende a pertenecer a la misma clase que los casos más similares a él dentro del conjunto de datos**.
- No construye un modelo explícito; en lugar de ello, clasifica una observación comparándola con sus k vecinos más cercanos según una medida de distancia, como la euclidiana, Manhattan o coseno.




K-NN (K-NEAREST NEIGHBORS)


- k-NN es considerado un algoritmo intuitivo y de fácil interpretación, ya que reproduce el siguiente razonamiento humano: **“Si algo se parece a un grupo, probablemente pertenezca a ese grupo”**.
- Esto lo convierte en una herramienta útil para escenarios empresariales en los que se requiere clasificación rápida y basada en patrones históricos.



a



b



c

PROCESO GENERAL DEL ALGORITMO K-NN

01 PREPARACIÓN Y NORMALIZACIÓN DE LOS DATOS

Las variables deben estar en escalas comparables, ya que el algoritmo depende de distancias. Ejemplo: ingresos (0–10,000) y número de compras (0–20) deben escalarse.

02 SELECCIÓN DEL VALOR DE K (NÚMERO DE VECINOS)

- k pequeño: modelo sensible al ruido.
- k grande: modelo más estable, pero puede perder precisión local.

Normalmente, se elige k mediante validación cruzada.

03 CÁLCULO DE DISTANCIAS


Para una nueva observación, se calcula la distancia a todos los puntos del dataset y se seleccionan los k más cercanos.

04 ASIGNACIÓN DE CLASE

La clase final se determina por votación mayoritaria (clasificación) o por promedio (en problemas de regresión).

05 EVALUACIÓN DEL DESEMPEÑO

Se miden métricas como precisión, recall, F1-score o MAE según el tipo de problema.




+

CLUSTERING BÁSICOS: K-MEANS,
JERÁRQUICO


¿QUÉ ES EL CLUSTERING?

- Es una técnica de minería de datos no supervisada cuyo objetivo es **agrupar observaciones similares dentro de un conjunto de datos**, de modo que los elementos de un mismo grupo (clúster) sean más parecidos entre sí que respecto a los de otros.
- Esta técnica no utiliza etiquetas previas, sino que **descubre patrones y estructuras ocultas en los datos**, por lo que es fundamental en análisis de clientes, marketing, finanzas, logística y ciencia de datos empresarial.




¿QUÉ ES EL CLUSTERING?

- Desde un enfoque conceptual, el clustering **permite identificar perfiles, comportamientos o segmentos naturales**, lo que facilita la toma de decisiones estratégicas.
- Por ejemplo, en marketing puede ayudar a diferenciar clientes frecuentes, esporádicos y de alto valor; en finanzas permite agrupar tipos de riesgo o perfiles de inversión; y en logística ayuda a clasificar rutas o zonas de distribución según características comunes.



ALGORITMO K-MEANS

- El algoritmo k-means es **una técnica de clustering particional que divide un conjunto de datos en k grupos disjuntos**, buscando que los elementos de cada clúster sean internamente homogéneos y externamente diferentes.
- El criterio matemático que optimiza es la minimización de la suma de distancias cuadradas entre cada punto y su centroide.
- Es ampliamente utilizado en marketing, CRM, análisis de consumo, microsegmentación de clientes y pricing.



PROCESO FORMAL DEL K-MEANS

- 01 SELECCIÓN DEL NÚMERO DE CLÚSTERES K**
Se suele elegir mediante técnicas como elbow, silhouette o criterios de negocio.
- 02 INICIALIZACIÓN DE CENTROIDES**
Se seleccionan k puntos iniciales (al azar o mediante k-means++ para mayor estabilidad).
- 03 ASIGNACIÓN DE OBSERVACIONES**
Para una nueva observación, se calcula la distancia a todos los puntos del dataset y se seleccionan los k más cercanos.
- 04 RECÁLCULO DE CENTROIDES**
El centroide se actualiza como el promedio de los puntos asignados.
- 05 ITERACIÓN Y CONVERGENCIA**
El proceso continúa hasta que los centroides dejan de cambiar o el error total deja de disminuir.



EJEMPLO

Una cadena minorista desea diseñar estrategias diferenciadas de fidelización. Analiza a sus clientes usando dos variables:

- **Frecuencia de compra (visitas al mes).**
- **Monto promedio de gasto (USD por compra).**

El objetivo es identificar segmentos comerciales para personalizar promociones y beneficios. Para ello, se aplicará el modelo del k-means con $k=3$.



Tras ejecutar el modelo, se obtienen tres centroides representativos:

Clúster	Frecuencia	Gasto promedio	Perfil
C1	Baja	Bajo	Clientes ocasionales
C2	Media	Media	Clientes regulares
C3	Alta	Alta	Clientes premium

Se puede interpretar como:

- Los clientes del **clúster 1** (ocasionales) requieren campañas de activación (cupones de bienvenida, descuentos iniciales).
- El **clúster 2** (regulares) es ideal para estrategias de cross-selling y programas de puntos.
- El **clúster 3** (premium) concentra mayor rentabilidad; se recomienda experiencias personalizadas, ofertas exclusivas y retención prioritaria.

En conclusión, el modelo no solo genera grupos matemáticos, sino también segmentos accionables, alineados a decisiones comerciales y de marketing estratégico.

CLUSTERING JERÁRQUICO

- **Construye una estructura de agrupación progresiva representada en un dendrograma**, lo que permite visualizar la relación entre observaciones y cómo se fusionan los clústeres a diferentes niveles.
- No exige fijar el número de grupos previamente, lo que lo hace apropiado para análisis exploratorio y estudios descriptivos complejos.
- Es especialmente valioso cuando se requiere comprender la estructura global de los datos y justificar decisiones de segmentación a nivel estratégico.



TIPOS DE CLUSTERING JERÁRQUICO

+ 01.

AGLOMERATIVO (BOTTOM-UP)

Es el método más utilizado en minería de datos.

- Se inicia considerando cada dato como un clúster individual.
- Luego, en cada paso, el algoritmo fusiona los dos clústeres más similares.
- El proceso continúa hasta formar un solo gran clúster.

Por ejemplo, si tenemos 5 clientes:

- Primero hay 5 clústeres independientes.
- Luego se fusionan los más parecidos (por comportamiento similar).
- Progresivamente, se forman grupos más grandes.



TIPOS DE CLUSTERING JERÁRQUICO

+ 02.


DIVISIVO (TOP-DOWN)

Este método sigue el proceso opuesto al aglomerativo.

- Se inicia con todos los datos dentro de un solo clúster.
- En cada paso, el algoritmo divide el clúster más heterogéneo.
- Continúa dividiendo hasta obtener los subgrupos deseados.

Por ejemplo, un banco agrupa inicialmente todos los clientes en un solo clúster. Luego el algoritmo divide:

- Clientes de alto riesgo vs. bajo riesgo.
- Después subdivide cada grupo en perfiles más específicos.




+

REGLAS DE ASOCIACIÓN:
APRIORI, FP-GROWTH


¿QUÉ SON LAS REGLAS DE ASOCIACIÓN?

- Son una técnica de minería de datos que permite identificar relaciones o patrones de coocurrencia entre elementos dentro de grandes bases de datos, especialmente en transacciones o comportamientos repetitivos.
- Su objetivo es descubrir patrones del tipo: **“Si ocurre A, es probable que también ocurra B”**. Son ampliamente utilizadas en:
 - **Análisis de canastas de compra (retail).**
 - **Ventas cruzadas (cross-selling).**
 - **Recomendación de productos.**
 - **Comportamiento de clientes.**
 - **Detección de patrones en finanzas y marketing.**



MÉTRICAS FUNDAMENTALES

Para evaluar una regla del tipo $A \rightarrow B$, se emplean tres indicadores:



Una regla es útil cuando presenta alto soporte, alta confianza y lift mayor a 1.

ALGORITMO APRIORI

- Busca conjuntos frecuentes de ítems siguiendo el principio: **“Si un conjunto es frecuente, entonces todos sus subconjuntos también lo son”**.
- Esto permite reducir combinaciones innecesarias y analizar únicamente ítems con probabilidad real de formar patrones.



PROCESO DEL ALGORITMO APRIORI

- 01** **CALCULAR EL SOPORTE DE CADA ÍTEM INDIVIDUAL**
Se cuenta en cuántas transacciones aparece cada ítem y se eliminan los que no cumplen el soporte mínimo.
- 02** **GENERAR COMBINACIONES DE ÍTEMS FRECUENTES**
Con los ítems que quedaron, se forman combinaciones de 2 ítems, luego de 3, de 4, etc.
- 03** **EVALUAR SOPORTE EN CADA NIVEL**
Para cada combinación, se vuelve a calcular el soporte y se descartan las que no sean frecuentes (aquí aplica el principio Apriori: si una combinación grande no es frecuente, sus subconjuntos tampoco lo serán).
- 04** **OBTENER LOS CONJUNTOS FRECUENTES FINALES**
El proceso continúa hasta que ya no se puedan formar nuevas combinaciones válidas.
- 05** **GENERACIÓN DE REGLAS DE ASOCIACIÓN**
A partir de los conjuntos frecuentes, se crean reglas del tipo $A \rightarrow B$, y se evalúan con confianza, soporte y lift.



EJEMPLO

Un supermercado desea identificar productos que los clientes suelen comprar juntos para mejorar la disposición en góndolas y promociones combinadas. Al analizar miles de tickets de compra, el resultado del modelo Apriori sería:

Regla obtenida	Interpretación	Recomendación
- Pan + Mantequilla → Mermelada. - Support = 0.18 Confidence = 0.72 Lift = 2.10.	- El 18% de las transacciones incluye los tres productos. - En el 72% de las compras en que hay pan y mantequilla, también se compra mermelada. - El lift mayor a 2 indica que la combinación no es aleatoria, sino un patrón de consumo real.	- Crear combos promocionales. - Colocar productos en zona contigua. - Diseñar campañas de ventas cruzadas.


ALGORITMO FP-GROWTH

- FP-Growth es una **alternativa más eficiente a Apriori cuando se trabaja con grandes volúmenes de datos.**
- En lugar de generar y evaluar combinaciones repetidas, construye una estructura compacta llamada FP-Tree (Frequent Pattern Tree), que almacena patrones frecuentes sin necesidad de revisar todas las transacciones una y otra vez.



PROCESO DEL ALGORITMO FP-GROWTH

- 01** **CÁLCULO DE FRECUENCIAS INICIALES**
Se cuenta cuántas veces aparece cada ítem en todas las transacciones y se eliminan los que no cumplen el soporte mínimo.
- 02** **ORDENAMIENTO DE ÍTEMS POR FRECUENCIA**
En cada transacción, los ítems restantes se reordenan de mayor a menor frecuencia para que los patrones comunes puedan compartirse.
- 03** **CONSTRUCCIÓN DEL FP-TREE**
Las transacciones se insertan en un árbol compacto. Las rutas que comparten ítems frecuentes se superponen, lo que reduce la repetición de datos.
- 04** **BÚSQUEDA DE PATRONES FRECUENTES**
Se exploran las rutas del árbol para identificar combinaciones de ítems que aparecen juntas repetidamente, sin generar todas las combinaciones posibles.
- 05** **GENERACIÓN DE REGLAS DE ASOCIACIÓN**
A partir de los patrones encontrados, se calculan soporte, confianza y lift para obtener reglas útiles para la toma de decisiones.



EJEMPLO

Una plataforma de e-commerce analiza la siguiente secuencia de navegación de los usuarios: Ver producto - Agregar al carrito - Revisar opiniones - Comprar. Al identificar patrones de comportamiento previos a la compra, el resultado del modelo FP-Growth sería:

Regla obtenida

- Ver producto → Revisar opiniones → Comprar.
- Support = 0.35 | Confidence = 0.68 | Lift = 1.75.

Interpretación

- El 35% de los usuarios sigue ese patrón.
- Quienes revisan opiniones tienen 68% más probabilidad de comprar.
- El lift confirma que las reseñas influyen positivamente en la conversión.

Recomendación

- Destacar reseñas visibles.
- Priorizar testimonios en productos clave.
- Diseñar recomendaciones basadas en navegación real.

+

EVALUACIÓN DE RESULTADOS:
**MÉTRICAS COMO PRECISIÓN,
RECALL, SILHOUETTE**


EVALUACIÓN DE RESULTADOS EN MINERÍA DE DATOS

- Tiene como finalidad **medir qué tan bien un modelo representa la realidad y si sus predicciones o agrupamientos son útiles para la toma de decisiones.**
- Las métricas permiten comparar algoritmos, validar su desempeño y seleccionar el modelo más adecuado según el objetivo del análisis (clasificar, detectar riesgos, segmentar, etc.).



EVALUACIÓN DE RESULTADOS EN MINERÍA DE DATOS

- En clasificación, se emplean métricas derivadas de la matriz de confusión, mientras que en clustering se utilizan indicadores de cohesión y separación de grupos.
- La correcta interpretación de estas métricas es esencial para evitar conclusiones erróneas o decisiones basadas en resultados poco confiables.
- Las métricas permiten lo siguiente:
 - **Validar que el modelo funciona correctamente antes de implementarlo.**
 - **Comparar diferentes algoritmos.**
 - **Reducir errores.**
 - **Respaldar el análisis con criterios objetivos y técnicos.**



+ 01. PRECISIÓN

Mide la proporción de predicciones positivas que realmente fueron correctas. Indica qué tan exactas fueron las predicciones positivas del modelo.

Fórmula:

$$\text{Precisión} = \frac{\text{Verdaderos Positivos}}{\text{Verdaderos Positivos} + \text{Falsos Positivos}}$$

Interpretación:

- **Alta precisión:** pocas clasificaciones incorrectas como “positivas”.
- **Baja precisión:** el modelo comete muchos falsos positivos.



+ 01. PRECISIÓN

Ejemplo:

- Un modelo identifica transacciones sospechosas de fraude:
 - Predijo 50 transacciones como fraude.
 - 40 realmente eran fraude (VP).
 - 10 no lo eran (FP).

$$\text{Precisión} = \frac{40}{40 + 10} = 0.8 \cong 80\%$$

- El resultado nos indica que el 80% de las alertas generadas por el sistema fueron correctas.
- Esto es útil en contextos en los que es costoso acusar erróneamente (finanzas, aprobación crediticia o auditoría).



+ 02. RECALL

Mide la capacidad del modelo para detectar correctamente los casos positivos reales. Indica cuántos casos positivos fueron encontrados entre todos los existentes.

Fórmula:

$$\text{Recall} = \frac{\text{Verdaderos Positivos}}{\text{Verdaderos Positivos} + \text{Falsos Negativos}}$$

Interpretación:

- **Alto recall:** el modelo casi no deja pasar casos positivos sin detectar.
- **Bajo recall:** muchos positivos reales no fueron identificados.



+ 02. RECALL

Ejemplo:

- En un modelo de detección de clientes con alto riesgo de abandono (churn):
 - Existían 60 clientes que realmente iban a abandonar.
 - El modelo detectó 45 (VP).
 - No detectó 15 (FN).

$$Recall = \frac{45}{45 + 15} = 0.75 \cong 75\%$$

- El modelo detecta al 75% de los clientes en riesgo, lo cual es valioso para campañas de retención.



RELACIÓN PRECISIÓN-RECALL (BALANCE Y DECISIÓN)

- En muchos problemas existe un trade-off:
 - Si se aumenta la precisión, puede disminuir el recall.
 - Si se aumenta el recall, puede bajar la precisión.
- Por ejemplo, en fraude bancario, se prioriza precisión (evitar falsas acusaciones). En detección de riesgo o salud, se prioriza recall (no dejar pasar casos reales). Por ello, en la práctica también se utiliza la métrica F1-score, que combina ambas para evaluar el equilibrio del modelo.



+ 03. SILHOUETTE

- La métrica silhouette evalúa la calidad de los grupos en un modelo de clustering. Mide simultáneamente:
 - **Cohesión:** qué tan cerca están los puntos dentro del mismo grupo.
 - **Separación:** qué tan lejos están respecto a otros grupos.
- Su valor varía entre -1 y 1 :
 - **Cerca de $+1$:** clusters bien definidos.
 - **Cerca de 0 :** grupos poco claros o solapados.
 - **Negativo:** mala asignación de puntos.



+ 03. SILHOUETTE

- Para cada observación se calcula:
 1. Distancia promedio al resto del grupo propio (a).
 2. Distancia promedio al grupo vecino más cercano (b).
 3. Se aplica:

$$Silhouette = \frac{b - a}{\max(a, b)}$$


- Luego se obtiene el promedio general del modelo.



+ 03. SILHOUETTE

Ejemplo:

- En una segmentación de clientes con k-means, donde:
 - **Grupo A:** clientes frecuentes de alto gasto.
 - **Grupo B:** clientes esporádicos de bajo gasto.
- Si el resultado general silhouette es de 0.72, entonces podemos concluir que la segmentación es consistente y los clientes están bien diferenciados entre sí, por lo que es útil para diseñar estrategias comerciales diferenciadas.



+

APLICACIONES PRÁCTICAS:
SEGMENTACIÓN DE CLIENTES

SEGMENTACIÓN DE CLIENTES

Es el proceso analítico mediante el cual se agrupan clientes en conjuntos homogéneos según características similares de:

- **Comportamiento.**
- **Consumo.**
- **Preferencias.**
- **Valor económico.**



SEGMENTACIÓN DE CLIENTES

- Se apoya principalmente en **técnicas de clustering y análisis de patrones**, lo que permite transformar datos dispersos en perfiles comerciales útiles para la toma de decisiones estratégicas.
- El objetivo central es formar grupos y comprender cómo y por qué los clientes se comportan de manera diferente para diseñar estrategias diferenciadas.



TIPOS COMUNES DE SEGMENTACIÓN

Entre los más utilizados en entornos empresariales se encuentran los siguientes:

Demográfica	Geográfica	Psicográfica	Conductual	Basada en valor (RFM)
Edad. Género. Nivel socioeconómico.	País. Ciudad. Zona comercial.	Estilo de vida. Motivaciones. Preferencias.	Frecuencia de compra. Monto gastado. Tipo de producto adquirido.	Recencia. Frecuencia. Monto de compra.

PROCESO DE SEGMENTACIÓN DE CLIENTES

- 01** **DEFINICIÓN DEL OBJETIVO ANALÍTICO**
Ejemplo: aumentar retención, optimizar campañas o priorizar clientes rentables.
- 02** **SELECCIÓN Y PREPARACIÓN DE VARIABLES**
Frecuencia de compra, ticket promedio, canal de compra, recencia, categoría de productos, etc.
- 03** **APLICACIÓN DE TÉCNICAS DE CLUSTERING**
K-means, clustering jerárquico o RFM combinado con reglas de asociación.
- 04** **INTERPRETACIÓN Y PERFILAMIENTO DE SEGMENTOS**
Se describen los grupos con etiquetas comprensibles. Por ejemplo: “Clientes frecuentes de alto valor”, “Clientes esporádicos sensibles al precio”.
- 05** **DISEÑO DE ACCIONES COMERCIALES DIFERENCIADAS**
Campañas personalizadas, cross-selling, retención, mejora de experiencia.
- 06** **MONITOREO Y ACTUALIZACIÓN PERIÓDICA**
Los segmentos evolucionan conforme cambian hábitos de consumo.



EJEMPLO: MARKETING Y RETAIL

- Una cadena de supermercados aplica k-means con variables: frecuencia de compra, monto promedio, categorías más consumidas. Para el estudio se obtienen tres segmentos:
 - Clientes “premium recurrentes”
 - Clientes “ocasionales de bajo gasto”
 - Clientes “promocionales sensibles al precio”
- Para este caso se recomienda diseñar campañas diferenciadas: fidelización para clientes premium y cupones selectivos para clientes promocionales para mejorar la efectividad de campañas y retorno de inversión.



IMPORTANCIA PROFESIONAL

La segmentación de clientes es clave porque:



Permite personalizar estrategias comerciales y mejorar la experiencia del cliente.



Optimiza la asignación de recursos en marketing y ventas.



Contribuye a la retención de clientes rentables y al incremento del valor de vida del cliente (CLV).




Apoya la toma de decisiones estratégicas mediante el uso responsable y analítico de los datos.

+

IMPLEMENTACIÓN: USO DE
HERRAMIENTAS ESPECÍFICAS

IMPLEMENTACIÓN EN MINERÍA DE DATOS

- Consiste en **llevar los algoritmos y modelos analíticos a entornos reales de trabajo**, utilizando herramientas de software que permiten ejecutar, validar, visualizar e integrar los resultados en los procesos organizacionales.
- Su finalidad no es solo “aplicar un algoritmo”, sino también operacionalizar el análisis para apoyar las decisiones que se tomarán.



HERRAMIENTAS EN IMPLEMENTACIÓN EN MINERÍA DE DATOS

- Las herramientas de implementación combinan lo siguiente:
 - **Funciones de carga de datos.**
 - **Preprocesamiento.**
 - **Modelado, evaluación y despliegue de resultados.**
- Esto facilita que se pase del enfoque teórico al uso práctico y aplicado de la analítica.




HERRAMIENTAS MÁS UTILIZADAS EN ENTORNOS EDUCATIVOS Y EMPRESARIALES

La elección de la herramienta depende del propósito del análisis, el nivel técnico del usuario y el entorno institucional.

Python	R	Excel	Power BI / Tableau	RapidMiner
Lenguaje flexible para modelado, prototipado y automatización de procesos analíticos.	Orientado a análisis estadístico, visualización y minería de datos aplicada.	Útil para ejercicios iniciales, tabulación, cálculos básicos y validación de resultados.	Permiten integrar resultados del modelo con dashboards e informes gerenciales.	Entorno gráfico “drag-and-drop” que facilita flujos analíticos sin necesidad de programar.

PROCESO GENERAL DE IMPLEMENTACIÓN EN HERRAMIENTAS DE MINERÍA DE DATOS



PROCESO GENERAL DE IMPLEMENTACIÓN EN HERRAMIENTAS DE MINERÍA DE DATOS

4 **EJECUCIÓN DEL MODELO Y PARAMETRIZACIÓN**
Definición de k, métricas, criterios de distancia o hiperparámetros según la técnica utilizada.

5 **EVALUACIÓN DE RESULTADOS**
Uso de métricas como precisión, recall, F1, silhouette, soporte y confianza según el tipo de modelo.

6 **INTERPRETACIÓN Y DOCUMENTACIÓN**
Perfilamiento de segmentos, reglas o patrones, y explicación de resultados para usuarios no técnicos.

7 **DESPLIEGUE O USO APLICADO**
Integración en reportes, dashboards, campañas, políticas de riesgo o decisiones operativas.


EJEMPLOS

EJEMPLO 1: SEGMENTACIÓN EN MARKETING CON PYTHON (K-MEANS)

- Una empresa analiza frecuencia de compra, monto y recencia.
- Se ejecuta k-means en Python, se evalúa con silhouette y se identifican tres segmentos de clientes.
- Resultado: campañas diferenciadas y aumento de efectividad comercial.

EJEMPLO 2: CLASIFICACIÓN DE RIESGO EN EXCEL + POWER BI

- Se entrena un modelo simple en R o Python, y los resultados se integran a un dashboard gerencial en Power BI.
- Resultado: apoyo visual para decisiones de crédito y control de cartera.

A collection of white line-art icons on a purple background. At the top left is a stack of three papers. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A box with 'Q' and 'A' sections, each containing three horizontal lines. To the left of the Q&A box is another cloud icon. At the bottom left is a notepad with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + La minería de datos y sus algoritmos representan un pilar fundamental en la gestión moderna de la información, ya que permiten descubrir patrones ocultos que fortalecen la toma de decisiones estratégicas en empresas y organizaciones.
- + Su aplicación en áreas como administración, finanzas, marketing y negocios internacionales genera ventajas competitivas basadas en conocimiento y análisis cuantitativo.
- + El dominio de técnicas como clasificación, clustering, reglas de asociación y evaluación de modelos contribuye al desarrollo de profesionales capaces de interpretar datos de manera crítica, diseñar soluciones analíticas y aplicar herramientas tecnológicas en escenarios reales. Esto fortalece el perfil profesional orientado a la analítica y la inteligencia de negocios.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Domínguez Castro, S. (2024). *Uso de las reglas de asociación en minería de datos: creación de una aplicación para clasificación y predicción*. Universidad de Salamanca.
- + Ortega Candel, J. M. (2023). *Big data, machine learning y data science en Python*. Grupo Editorial RA-MA.
- + Velasco Rebolledo, J. (2023). *Machine Learning: Implementar en Python con Scikit-learn*. Ediciones Díaz de Santos.



ISIL+