

+ TEMA 09

INTRODUCCIÓN A

R Y PYTHON

- Instalación: R, Python, entornos virtuales
- Configuración: RStudio, Jupyter Notebook, IDE
- Bibliotecas: pandas, scikit-learn, dplyr, tidyr
- Gestión de paquetes: CRAN, PIP, Conda
- Flujo de trabajo: importar datos, explorar datasets





+ INTRODUCCIÓN **DE LA SESIÓN**

- + R y Python se han consolidado como los lenguajes más utilizados en análisis de datos, estadística aplicada y minería de datos por su potencia, flexibilidad y ecosistemas de librerías especializadas. Ambos permiten transformar datos en información útil para la toma de decisiones empresariales y académicas.
- + En entornos profesionales, estos lenguajes facilitan tareas como limpieza de datos, modelación estadística, segmentación de clientes y elaboración de reportes automatizados. Su uso se extiende en banca, marketing, logística, comercio exterior y análisis financiero.
- + Ambos lenguajes ofrecen bibliotecas y funciones que permiten desde análisis básicos hasta modelado avanzado de datos.




+

INSTALACIÓN: R, PYTHON,
ENTORNOS VIRTUALES


PREPARACIÓN DEL ENTORNO LOCAL

- Preparar un entorno local **implica instalar en tu computadora todo lo necesario para programar y ejecutar código en R o Python**, sin depender de internet o servicios en la nube.
- Esto es importante porque permite lo siguiente:
 - **Practicar sin conexión.**
 - **Tener mayor control del entorno.**
 - **Mejorar el rendimiento y privacidad.**



PREPARACIÓN DEL ENTORNO LOCAL

- Es importante considerar tanto el software como el hardware, ya que eso influirá en **la fluidez del trabajo con análisis de datos y proyectos más avanzados.**



REQUISITOS DE HARDWARE

Lo necesario depende de si se trabaja con análisis básico o con big data/machine learning.

Procesador (CPU)	✓ Mínimo: Intel i5 / Ryzen 5 de última generación. ✓ Recomendado: i7 / Ryzen 7 o superior, especialmente para cálculos estadísticos grandes y entrenamiento de modelos. ✓ R y Python usan varios núcleos en ciertas librerías (ejemplo: numpy, pandas).
Memoria RAM	✓ Mínimo: 8 GB para análisis básicos. ✓ Recomendado: 16 GB o más si trabajas con grandes conjuntos de datos (Excel, R y Python cargan datos en memoria).
Sistema operativo	✓ Windows 10/11, macOS o Linux. ✓ Linux es el más estable y ligero para entornos de datos, pero Windows es más usado en entornos educativos y empresariales.
Tarjeta gráfica (GPU)	✓ No esencial para estadística básica. ✓ Importante si usarás machine learning o deep learning en Python (TensorFlow, PyTorch): NVIDIA con soporte CUDA
Almacenamiento (disco)	✓ Recomendado: 512 GB o más, con SSD NVMe.

REQUISITOS DE SOFTWARE


Aquí se busca que tanto R como Python estén listos para desarrollo y análisis.

Para R	✓ Instalar R: desde CRAN. ✓ RStudio IDE: entorno recomendado para trabajar con proyectos de R. ✓ Paquetes básicos: tidyverse, dplyr, ggplot2, readxl, shiny, caret. ✓ Administrador de dependencias: renv o packrat (para aislar entornos).
Para Python	✓ Instalar Python (3.9+ recomendado). Mejor con Anaconda/Miniconda, que facilita librerías científicas y entornos virtuales. ✓ IDE recomendados: Jupyter Notebook, JupyterLab, VS Code, PyCharm. ✓ Paquetes esenciales para análisis: • Manipulación de datos: numpy, pandas. • Visualización: matplotlib, seaborn, plotly. • Estadística avanzada: scipy, statsmodels. • Machine Learning: scikit-learn, xgboost, tensorflow/pytorch (si aplica).
Configuración común para ambos	✓ Compatibilidad Excel/CSV: ambos deben poder leer/escribir archivos de uso frecuente. ✓ Drivers y librerías de BD: si se usará SQL, instalar conectores (ej. RMySQL, pyodbc).

INSTALACIÓN DE R Y RSTUDIO

- 01 **INSTALAR R**
Acceder a <https://cran.r-project.org/> y descargar la versión adecuada para tu sistema operativo (Windows, macOS o Linux).
- 02 **INSTALAR RSTUDIO**
Descargar desde <https://posit.co/download/rstudio-desktop/>, que ofrece una interfaz amigable para programar en R.
- 03 **VERIFICACIÓN**
Al abrir RStudio, deberías ver una consola activa lista para ejecutar comandos en R.





CÓMO INSTALAR R Y RSTUDIO

 <https://www.youtube.com/watch?v=hbgzW3Cvda4>

INSTALACIÓN DE PYTHON

La opción recomendada es instalar el paquete Anaconda (Incluye Python y herramientas como Jupyter Notebook) desde: <https://www.anaconda.com/download>


Pasos

- 01  Descargar **Anaconda** según tu sistema operativo.
- 02  Instalar y abrir **Anaconda Navigator**.
- 03  Crear un nuevo entorno si se desea y **lanzar Jupyter Notebook o Spyder**.

Alternativas

- Instalar Python puro desde <https://www.python.org/>
- Usar editores como VS Code o Thonny.





CÓMO INSTALAR PYTHON EN WINDOWS 10/11 + VS CODE

 <https://www.youtube.com/watch?v=QvQgKagWKYk>

COMPARACIÓN PRÁCTICA R VS. PYTHON (INSTALACIÓN Y USO EN ANÁLISIS DE DATOS)

Aspecto	R	Python
Instalación básica	Descarga desde CRAN . Requiere instalar R y, opcionalmente, RStudio como IDE.	Descarga desde Python.org o mediante Anaconda (muy usado en ciencia de datos). IDE comunes: Jupyter, VS Code, PyCharm.
Facilidad de inicio	RStudio ofrece un entorno intuitivo, diseñado específicamente para análisis estadístico y gráficos.	Jupyter Notebook permite trabajar de manera interactiva con datos, pero requiere instalar librerías adicionales.
Paquetes principales para análisis de datos	Tidyverse, dplyr, ggplot2, readr, caret.	Pandas, numpy, matplotlib, seaborn, scikit-learn.
Visualización de datos	Muy potente con ggplot2, plotly y librerías del ecosistema R.	Versátil con matplotlib, seaborn, plotly, bokeh.
Estadística aplicada	Amplia variedad de funciones estadísticas nativas y paquetes especializados.	Menor enfoque nativo en estadística, pero con librerías (statsmodels, scipy) se iguala a R.
Curva de aprendizaje	Ideal para quienes se centran en estadística y no en programación. Sintaxis más rígida, pero orientada a análisis.	Más flexible y fácil de integrar con otras áreas (IA, web, automatización). Requiere aprender más programación.

COMPARACIÓN PRÁCTICA R VS. PYTHON (INSTALACIÓN Y USO EN ANÁLISIS DE DATOS)

Aspecto	R	Python
Reproducibilidad	Muy usado en entornos académicos y de investigación. Markdown y RMarkdown permiten reportes automáticos.	Excelente integración con notebooks interactivos (Jupyter) y frameworks para producción.
Escalabilidad	Menos eficiente en manejo de grandes volúmenes de datos (se apoya en extensiones como data.table).	Escalable, soporta grandes datasets y se integra bien con big data y machine learning.
Comunidad y soporte	Comunidad fuerte en estadística y bioinformática. Mucha documentación académica.	Comunidad más amplia y generalista. Gran soporte en ciencia de datos, IA y desarrollo de software.
Uso recomendado	Cuando el análisis es principalmente estadístico y orientado a investigación académica.	Cuando se requiere combinar análisis de datos con machine learning, IA o aplicaciones prácticas en producción.

ENTORNOS VIRTUALES

- Un entorno virtual es **una instancia aislada del lenguaje (principalmente en Python)** que contiene su propio conjunto de librerías, dependencias y versiones de paquetes para un proyecto específico.
- Esto evita que las configuraciones globales del sistema interfieran con otros proyectos y permite que cada análisis de datos se ejecute bajo condiciones controladas y reproducibles.
- Funciona como una “caja independiente” donde **el proyecto almacena exactamente las herramientas que necesita**, sin afectar ni depender de otros trabajos desarrollados en el mismo equipo.




+

CONFIGURACIÓN: RSTUDIO
JUPYTER NOTEBOOK, IDE


CONFIGURACIÓN DEL ENTORNO DE TRABAJO

- Consiste en preparar las herramientas que permiten escribir, ejecutar, documentar y gestionar código de manera eficiente.
- En análisis de datos, las plataformas más utilizadas son:
 - **RStudio para el desarrollo con R.**
 - **Jupyter Notebook para el trabajo interactivo con Python.**
 - **IDE generales (VS Code, PyCharm, Spyder) para proyectos estructurados o de mayor escala.**



CONFIGURACIÓN DE RSTUDIO

- RStudio es un IDE (Integrated Development Environment) diseñado específicamente para trabajar con el lenguaje R.
- Es decir, es un entorno que integra en una misma herramienta lo siguiente:
 - Editor de scripts (para escribir código).
 - Consola (para ejecutar instrucciones).
 - Visor de objetos y variables.
 - Panel de gráficos, archivos y paquetes.
 - Herramientas para reportes y proyectos reproducibles.



CONFIGURACIÓN DE RSTUDIO

Se utiliza ampliamente en:



INSTALACIÓN Y PROCESO DE CONFIGURACIÓN

1

Instalar R (obligatorio antes de RStudio).

2


Instalar y ejecutar Rstudio.

3

Verificar paneles principales:

- **Editor (script):** donde se escribe el código.
- **Consola:** donde se ejecutan las instrucciones.
- **Environment / History:** lista de variables y objetos.
- **Plots / Files / Packages / Help:** gráficos, archivos y paquetes.

INSTALACIÓN Y PROCESO DE CONFIGURACIÓN




CONFIGURACIÓN DE JUPYTER NOTEBOOK

- Jupyter Notebook es una herramienta interactiva utilizada en análisis de datos, programación y ciencia de datos que permite combinar en un mismo documento lo siguiente:
 - **Código ejecutable.**
 - **Resultados del código.**
 - **Texto explicativo.**
 - **Tablas y gráficos.**
 - **Fórmulas y visualizaciones.**
- Estos documentos se organizan en celdas, lo que permite ejecutar el código paso a paso y analizar resultados de manera progresiva.



CONFIGURACIÓN DE JUPYTER NOTEBOOK

Es ampliamente utilizado en:



INSTALAR JUPYTER CON ANACONDA

Es la forma más sencilla y recomendada para estudiantes y principiantes.

- 01  Descargar Anaconda desde su página oficial: <https://www.anaconda.com/download>.
- 02  Instalar aceptando opciones por defecto.
- 03  Abrir Anaconda Navigator.
- 04  Hacer clic en Jupyter Notebook + Launch.

Jupyter se abrirá automáticamente en el navegador.



INSTALAR JUPYTER CON PIP (PYTHON ESTÁNDAR)

- 01 Verificar Python instalado:
`python --version`
- 02 Crear entorno virtual:
`python -m venv entorno`
 - Con windows: `entorno\Scripts\activate`
 - Con MAC: `source entorno/bin/activate`
- 03 Instalar Jupyter.
- 04 Iniciar Jupyter Notebook.

Se abrirá en el navegador mostrando tus carpetas y archivos.



PROCESO DE CONFIGURACIÓN

1

Crear un cuaderno de trabajo

- Clic en New → Python 3 Notebook.
- Aparecerá un archivo con extensión .ipynb.

2

Reconocer sus partes

- Celdas de código: donde se escribe y ejecuta el programa.
- Celdas de texto (Markdown): para explicaciones y notas.
- Barra de herramientas: ejecutar, agregar o borrar celdas.


3

Probar ejecución básica

4

Configuraciones recomendadas

- Guardar el notebook con un nombre claro del proyecto.
- Crear carpetas de trabajo organizadas.
- Instalar bibliotecas necesarias.



CÓMO INSTALAR JUPYTER NOTEBOOKS Y PYTHON (CON PIP)

 <https://www.youtube.com/watch?v=6j6L3feh1p4>

CONFIGURACIÓN DE IDE

- Un IDE (Integrated Development Environment) es un **entorno de desarrollo integrado que reúne en una sola herramienta todo lo necesario para programar y trabajar con proyectos de software** o análisis de datos.
- **VS Code** es un IDE multilenguaje ampliamente utilizado para Python, R y análisis de datos.




+

BIBLIOTECAS: PANDAS,
SCIKIT-LEARN, DPLYR, TIDYR

¿QUÉ ES UNA BIBLIOTECA DE ESTADÍSTICA?

- También llamada paquete o módulo, es un conjunto de funciones ya programadas que facilitan el análisis estadístico. Permite reutilizar herramientas especializadas sin tener que escribir todo el código desde cero.
- Se usa por lo siguiente:
 - **Ahorra tiempo.**
 - **Facilita la programación de cálculos complejos.**
 - **Permite realizar desde análisis descriptivos hasta modelos avanzados (regresión, series de tiempo, etc.).**



¿QUÉ ES UNA BIBLIOTECA DE ESTADÍSTICA?

Una biblioteca de estadísticas recopila, organiza y pone a disposición datos sobre diversos aspectos de su funcionamiento, como lo siguiente:

Uso de la biblioteca	Colecciones	Demografía de los usuarios	Servicios	Recursos financieros
Número de visitantes, préstamos de libros, acceso a recursos electrónicos, asistencia a programas, etc.	Tamaño de la colección, número de títulos, formato de los documentos, etc.	Edad, género, nivel educativo, etc.	Tipos de servicios ofrecidos, número de usuarios atendidos, etc.	Presupuesto asignado, gastos operativos, etc.

BIBLIOTECAS ESTADÍSTICAS EN R


R fue diseñado específicamente para el análisis estadístico. Por tanto, muchas funciones estadísticas ya vienen integradas, pero también existen paquetes muy potentes que amplían su funcionalidad.

Biblioteca (R)	Funcionalidad clave
dplyr	Manipulación y transformación de datos mediante una gramática clara (filtrar, seleccionar, agrupar, resumir y crear variables).
tidyr	Organización y reestructuración de datos (tablas largas y anchas, separación y unión de columnas).
ggplot2	Creación de gráficos estadísticos basados en la gramática de los gráficos.
readr	Importación rápida de archivos de texto y CSV con manejo eficiente de tipos de datos.
tibble	Estructura moderna de data frames, más segura y legible.
stringr	Manejo y procesamiento de cadenas de texto de forma consistente.
lubridate	Manipulación y análisis de fechas y tiempos.
forcats	Manipulación de variables categóricas (factores) de forma eficiente.

INSTALACIÓN DE UNA BIBLIOTECA EN R

- 01  Abrir el entorno de trabajo (Rstudio).
- 02 
 - En la Consola escribir el comando de instalación:
`install.packages("nombre_del_paquete")`
 - Ejemplo: `install.packages("dplyr")`
- 03  Cargar la biblioteca instalada. Instalar no es lo mismo que cargar. Para usarla en un script o sesión debes activarla con:
`library("nombre_del_paquete")`





INSTALAR Y CARGAR LIBRERÍAS EN RSTUDIO

 <https://www.youtube.com/watch?v=4a7LWzv13ls>

BIBLIOTECAS ESTADÍSTICAS EN PYTHON

Python, aunque no nació para estadísticas, se ha convertido en una potente herramienta gracias a sus bibliotecas.

Biblioteca (Python)	Funcionalidad clave
Pandas	Manipulación y análisis de datos en forma de tablas (DataFrames): limpieza, filtrado, agregación y carga de archivos CSV/Excel/SQL.
Scikit-learn	Implementación de algoritmos de machine learning: clasificación, regresión, clustering, reducción de dimensión y validación de modelos.
NumPy	Cálculo numérico y manejo de arreglos/matrices de alto rendimiento; base científica de pandas y scikit-learn.
Matplotlib	Creación de gráficos básicos y personalizados para visualización de datos.
Seaborn	Visualización estadística de alto nivel basada en Matplotlib, con gráficos más intuitivos y estéticos.
SciPy	Funciones científicas y matemáticas avanzadas: optimización, estadística, señales y álgebra lineal.


INSTALACIÓN DE BIBLIOTECAS EN PYTHON USANDO JUPYTER NOTEBOOK

Método 1: instalar desde una celda del Notebook.

- En una celda escribe: *!pip install nombre_biblioteca*
- Ejemplo: *!pip install pandas*

Método 2: usar conda (si utilizas Anaconda):

- *conda install nombre_biblioteca*
- Ejemplo: *conda install numpy*
- Úsalo cuando la biblioteca tiene dependencias científicas (SciPy, TensorFlow, etc.).



```
script.py x
1 import seaborn as sns
2 import matplotlib.pyplot as plt
3 sns.set_theme(style="whitegrid")
4
5 # Load the example diamonds dataset
6 diamonds = sns.load_dataset("diamonds")
7
8 f, ax = plt.subplots(figsize=(6.5, 6.5))
9 sns.despine(f, left=True, bottom=True)
10 clarity_ranking = [
11     "I1", "SI2", "SI1", "VS2", "VS1", "VVS2", "VVS1", "IF"]
12
13 sns.scatterplot(x="carat", y="price",
14                 hue="clarity", size="depth",
15                 palette="ch:r=.2,d=.3_r",
16                 hue_order=clarity_ranking,
17                 sizes=(1, 8), linewidth=0,
18                 data=diamonds, ax=ax)
19
20 plt.show()
21
```

20:11 Py

Console

INSTALACIÓN DE BIBLIOTECAS EN PYTHON USANDO JUPYTER NOTEBOOK


Método 3: instalar en el entorno correcto.

- Si Jupyter no reconoce una librería, instálala dentro del mismo entorno del kernel:

```
import sys  
!{sys.executable} -m pip install  
nombre_biblioteca
```

- Ejemplo:


```
import sys  
!{sys.executable} -m pip install matplotlib
```
- Este método evita el error común:
ModuleNotFoundError: No module named 'xxx'



INSTALACIÓN DE BIBLIOTECAS EN PYTHON USANDO VISUAL STUDIO CODE (VS CODE)

- 01 ● Abrir la terminal en VS Code: terminal + new terminal.
- 02 ●
 - Se habilitará un comando en la terminal y se deberá colocar: ***pip install nombre_biblioteca***
 - Ejemplo: ***pip install seaborn***





INSTALAR LIBRERÍAS DE PYTHON CON PIP EN VISUAL STUDIO



<https://www.youtube.com/watch?v=SWIIQboGGCQ>

¿CUÁNDO USAR CADA BIBLIOTECA?


Tarea	R	Python
Gráficos detallados	ggplot2	seaborn, matplotlib
Regresión lineal/múltiple	lm, car, stats	statsmodels
Pruebas t, chi-cuadrado, ANOVA	t.test, chisq.test, aov	scipy.stats
Limpieza y transformación de datos	dplyr, tidyr	pandas

+

GESTIÓN DE PAQUETES:
CRAN, PIP, CONDA

GESTIÓN DE PAQUETES

- Es un componente fundamental en R y Python, ya que **permite instalar, actualizar, organizar y administrar bibliotecas** que amplían las capacidades de ambos lenguajes.
- Sin gestores de paquetes, el analista tendría que instalar manualmente cada función o dependencia, lo cual sería poco práctico y propenso a errores.
- En entornos profesionales, dominar estas herramientas asegura proyectos reproducibles, ordenados y compatibles con otros equipos de trabajo.



GESTIÓN DE PAQUETES

- Un paquete o biblioteca es un **conjunto de funciones diseñadas para resolver tareas específicas**, como análisis estadístico, manipulación de datos, visualización, econometría o machine learning.
- Los gestores de paquetes (CRAN en R; pip y conda en Python) permiten acceder a miles de herramientas desarrolladas por la comunidad científica y tecnológica. Esto garantiza eficiencia y productividad en proyectos de análisis de datos empresariales y académicos.



CRAN (COMPREHENSIVE R ARCHIVE NETWORK)

- Es el repositorio oficial de paquetes para R. **Alberga miles de bibliotecas revisadas y validadas por la comunidad académica**, lo que garantiza calidad metodológica y confiabilidad estadística.
- Muchos paquetes de CRAN son utilizados en investigación, análisis financiero, economía aplicada, marketing analytics y gestión de negocios.



CRAN (COMPREHENSIVE R ARCHIVE NETWORK)

Su importancia radica en lo siguiente:

- + **Centraliza y organiza paquetes oficiales de R.**
- + **Mantiene compatibilidad entre versiones del lenguaje.**
- + **Asegura estándares académicos y científicos.**
- + **Facilita la instalación y actualización de herramientas.**

CRAN es especialmente valorado en ámbitos como econometría, estudios de mercado, series de tiempo financieras y análisis de comportamiento empresarial, en que la rigurosidad estadística es imprescindible.



INSTALACIÓN Y CONFIGURACIÓN DE PAQUETES EN R DESDE CRAN

- 01  Abrir Rstudio.
- 02  Instalar un paquete desde CRAN:
`install.packages("dplyr")`
- 03  Cargar el paquete *`library(dplyr)`*
- 04  Especificar un repositorio (opcional, recomendable en laboratorios):
`install.packages("tidyr", repos = "https://cloud.r-project.org")`


Actualizar paquetes: *`update.packages()`*



PIP (PYTHON PACKAGE INSTALLER)

- Es el **gestor de paquetes oficial de Python** y permite instalar, actualizar y desinstalar bibliotecas desde PyPI (Python Package Index).
- Es la herramienta más utilizada en proyectos de análisis de datos, ciencia de datos, automatización y machine learning.

PIP Install Requests



PIP: CARACTERÍSTICAS PRINCIPALES

- + Es liviano, rápido y fácil de usar.
- + Instala bibliotecas y sus dependencias automáticamente.
- + Es ideal para proyectos pequeños, educativos o personales.
- + Trabaja muy bien dentro de entornos virtuales.



¿EN QUÉ ÁREAS SE UTILIZA PIP?

Es ampliamente utilizado en:



INSTALACIÓN Y USO DE PIP

- 01  Verificar pip: `pip --version`
- 02  Instalar una biblioteca: `pip install pandas`
- 03  Actualizar una biblioteca: `pip install --upgrade pandas`
- 04  Listar paquetes instalados: `pip list`
- 05  Usar pip dentro del entorno correcto:
`python -m pip install scikit-learn`

Este método evita errores cuando existen múltiples versiones de Python.



CONDA

- Es un **gestor de paquetes y de entornos virtuales al mismo tiempo**. Forma parte de la distribución Anaconda, muy utilizada en ciencia de datos y análisis profesional.
- Su principal ventaja es que puede instalar paquetes con dependencias complejas (por ejemplo, NumPy, TensorFlow o bibliotecas científicas que requieren componentes del sistema).




IMPORTANCIA DE CONDA EN EL ENTORNO PROFESIONAL

- + **Facilita la instalación en equipos institucionales.**
- + **Asegura entornos estables y reproducibles.**
- + **Es ampliamente usado en empresas y laboratorios.**
- + **Permite separar proyectos por versiones y dependencias.**



INSTALACIÓN Y USO DE CONDA

- 01  Verificar instalación: `conda --version`
- 02  Crear un entorno: `conda create --name data_env python=3.11`
- 03  Activar el entorno: `conda activate data_env`
- 04  Instalar un paquete: `conda install numpy`
- 05  Instalar desde un canal alternativo (cuando se requiere): `conda install -c conda-forge matplotlib`
- 06  Listar paquetes del entorno: `conda list`



DIFERENCIAS CLAVE ENTRE CRAN, PIP Y CONDA


HERRAMIENTA	LENGUAJE	FUNCIÓN PRINCIPAL	FORTALEZAS
CRAN	R	Repositorio oficial de paquetes	Rigor académico y estadístico
PIP	Python	Instalación de bibliotecas	Ligero, rápido y estándar
Conda	Python	Gestión de paquetes + entornos	Ideal para proyectos científicos complejos

+

FLUJO DE TRABAJO: IMPORTAR
DATOS, EXPLORAR DATASETS

FLUJO DE TRABAJO EN ANÁLISIS DE DATOS

- Describe la secuencia de actividades que un analista realiza **desde la carga de la información hasta la comprensión inicial del dataset.**
- Este proceso es fundamental porque permite validar la calidad de los datos antes de aplicar técnicas estadísticas, minería de datos o modelamiento predictivo.
- Una correcta exploración inicial reduce errores, mejora la interpretación de resultados y fortalece la toma de decisiones basada en evidencia.



IMPORTAR DATOS

Proceso mediante el cual se conecta el lenguaje de programación con la fuente de información. Puede provenir de lo siguiente:

ARCHIVOS LOCALES (CSV, EXCEL, TXT)

Corresponden a archivos almacenados en la computadora o en una carpeta del equipo, desde donde el programa lee y carga los datos directamente al entorno de análisis.

BASES DE DATOS EMPRESARIALES

Son sistemas centralizados que almacenan grandes volúmenes de información institucional. El programa se conecta mediante credenciales o consultas para extraer los datos necesarios.

PLATAFORMAS WEB O API

Permiten obtener datos desde servicios en línea o aplicaciones digitales mediante solicitudes automáticas, lo que facilita el acceso a información actualizada en tiempo real.

SISTEMAS TRANSACCIONALES

Son sistemas operativos de una empresa (ventas, contabilidad, logística) desde los cuales se extraen datos generados por procesos diarios para analizarlos y apoyar la toma de decisiones.

EXPLORAR DATASETS

¿En qué consiste?



Revisar la estructura de los datos

Implica observar cómo están organizadas las columnas y filas, así como el formato general del dataset para comprender su forma y contenido.



Identificar el tamaño del dataset

Consiste en determinar cuántos registros y variables tiene la base de datos, lo cual ayuda a dimensionar el alcance del análisis.



Analizar tipos de variables

Significa verificar si los datos son numéricos, categóricos, fechas o texto, para elegir los métodos estadísticos adecuados.




Detectar valores faltantes o atípicos

Permite identificar datos incompletos o inusuales que podrían afectar la calidad del análisis y requieren tratamiento previo.



Observar patrones generales

Consiste en explorar tendencias, comportamientos o relaciones iniciales entre variables antes de aplicar técnicas estadísticas más avanzadas.

A collection of white line-art icons on a purple background. At the top left is a stack of three papers. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + R y Python son herramientas fundamentales para el análisis estadístico y la minería de datos en contextos empresariales y académicos. Su integración con bibliotecas especializadas y entornos de desarrollo facilita la automatización, visualización y modelación de información relevante para la toma de decisiones estratégicas.
- + El dominio de su instalación, configuración, gestión de paquetes y flujo de trabajo analítico fortalece las competencias profesionales de los estudiantes, preparándolos para enfrentar retos reales en administración, finanzas, marketing, comercio exterior y ciencia de datos dentro de organizaciones modernas.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Fernández-Avilés, G., & Montero, J. M. (2024). *Fundamentos de ciencia de datos con R*. McGraw-Hill Interamericana de España.
- + Holguín Londoño, G. A., Moreno Gallón, D. A., & Holguín Londoño, M. (2024). *Introducción a la ciencia y análisis de datos con Python: una visión empresarial*. Universidad Tecnológica de Pereira.
- + Ortega Candel, J. M. (2022). *Big data, machine learning y data science en Python*. RA-MA.
- + Toro López, F. J. (2022). *Ciencia de los datos con Python*. Ecoe Ediciones.



ISIL+