

+ TEMA 10

ANÁLISIS ESTADÍSTICO EN R

- Manipulación de datos: filtrado, agrupación con dplyr
- Visualización: gráficos con ggplot2, personalización
- Pruebas estadísticas: t-test, correlaciones en R
- Automatización: scripts reutilizables en R
- Reportes: generación de informes estadísticos





+ INTRODUCCIÓN **DE LA SESIÓN**

- + El lenguaje R se ha consolidado como una de las herramientas más potentes para el análisis estadístico y la ciencia de datos. Su ecosistema de paquetes especializados permite realizar procesos de manipulación, visualización y modelado de datos de manera eficiente y reproducible. Por ello, R es ampliamente utilizado en empresas, instituciones públicas, consultoras y equipos de investigación.
- + R facilita la toma de decisiones basadas en evidencia y permite transformar datos crudos en información relevante. Desde análisis financieros y estudios de mercado, hasta evaluación de indicadores empresariales, R contribuye a mejorar la precisión y confiabilidad del análisis estadístico.



+

MANIPULACIÓN DE DATOS:
FILTRADO, AGRUPACIÓN
CON DPLYR

¿QUÉ ES LA MANIPULACIÓN DE DATOS?

- Es el proceso mediante el cual se organiza, transforma, limpia y resume la información antes de aplicar análisis estadísticos o construir modelos.
- En R, el paquete **dplyr** permite realizar estas tareas de forma intuitiva, rápida y estructurada, con el uso de una “gramática de datos” basada en verbos que representan acciones analíticas.



USO DE DPLYR


- El uso de dplyr es clave por lo siguiente:
 - Reduce errores manuales típicos de hojas de cálculo.
 - Acelera análisis repetitivos y reportes periódicos.
 - Facilita la trazabilidad del proceso analítico.
 - Permite trabajar con grandes volúmenes de datos.



FUNCIONES MÁS IMPORTANTES


- **filter():** filtra filas según condiciones.
- **select():** selecciona columnas relevantes.
- **mutate():** crea nuevas variables o indicadores.
- **arrange():** ordena registros.
- **summarise():** calcula estadísticas resumen.
- **group_by():** agrupa datos para análisis comparativo.

Estas funciones permiten construir procesos claros, reproducibles y profesionales, lo cual es esencial en entornos empresariales y académicos.



FLUJO DE TRABAJO TÍPICO

- 01  Importar los datos.
- 02  Seleccionar variables relevantes.
- 03  Filtrar registros según criterios.
- 04  Crear nuevas variables.
- 05  Agrupar información.
- 06  Calcular resúmenes estadísticos.
- 07  Interpretar resultados en el contexto profesional.



EJEMPLO 1: ANÁLISIS DE VENTAS POR REGIÓN

- Una empresa desea conocer el promedio de ventas mensuales por región: del norte, sur y centro.
- Para ello, solo se va a considerar las ventas mayores a 500 unidades, teniendo los siguientes datos:

Región	Norte	Norte	Sur	Sur	Centro	Centro
Venta	520	610	480	750	900	430

+ PROGRAMACIÓN EN R

- Base de datos simulada:

```
library(dplyr)

ventas <- data.frame(
  region = c("Norte", "Norte", "Sur", "Sur", "Centro", "Centro"),
  ventas = c(520, 610, 480, 750, 900, 430)
)
```

- Resultado inicial esperado:

	region	ventas
1	Norte	520
2	Norte	610
3	Sur	480
4	Sur	750
5	Centro	900
6	Centro	430

+ PROGRAMACIÓN EN R

- **Paso 1:** filtrar ventas mayores a 500.

```
ventas_filtradas <- ventas %>%  
  filter(ventas > 500)  
ventas_filtradas  
)  
ventas
```

- **Resultado:**

```
region ventas  
1 Norte 520  
2 Norte 610  
3 Sur 750  
4 Centro 900
```

- **Nota:** se excluyen registros con bajo nivel de ventas. Ahora, el análisis se enfoca en segmentos de alto desempeño.

+ PROGRAMACIÓN EN R

- **Paso 2:** agrupar y calcular promedio por región.

```
resumen_region <- ventas_filtradas %>%  
  group_by(region) %>%  
  summarise(promedio_ventas = mean(ventas))  
resumen_region
```

- Resultado:

```
# A tibble: 3 x 2  
  region promedio_ventas  
  <fct>         <dbl>  
1 Norte          565  
2 Sur            750  
3 Centro         900
```

- Se observa lo siguiente: la región centro presenta el mayor promedio de ventas, la región sur mantiene un buen desempeño y la región norte requiere estrategias de fortalecimiento comercial.

EJEMPLO 2: CÁLCULO DE GASTO PROMEDIO POR ÁREA

- El área financiera necesita conocer el gasto promedio de 3 de sus departamentos, considerando solo los gastos superiores a 1,000.
- Para ello, solo se va a considerar las ventas mayores a 500 unidades, teniendo los siguientes datos:

Área	Logística	Logística	RR. HH.	RR. HH.	Comercial	Comercial
Gasto	1,200	1,800	900	1,600	2,100	950

+ PROGRAMACIÓN EN R

- Datos:

```
gastos <- data.frame(  
  area = c("Logística","Logística","RRHH","RRHH","Comercial","Comercial"),  
  gasto = c(1200, 1800, 900, 1600, 2100, 950)  
)  
gastos
```

- **Paso 1:** filtrar gastos relevantes.

```
gastos_filtrados <- gastos %>%  
  filter(gasto > 1000)  
gastos_filtrados
```

+ PROGRAMACIÓN EN R

- Resultado:

	area	gasto
1	Logística	1200
2	Logística	1800
3	RRHH	1600
4	Comercial	2100

- **Paso 2:** agrupar y resumir.

```
resumen_gasto <- gastos_filtrados %>%  
  group_by(area) %>%  
  summarise(gasto_promedio = mean(gasto))  
resumen_gasto
```

+ PROGRAMACIÓN EN R

- Resultado:

```
# A tibble: 3 x 2
  area      gasto_promedio
  <fct>      <dbl>
1 Logística    1500
2 RRHH         1600
3 Comercial    2100
```

Interpretación de resultados:

- Comercial es el área con mayor gasto promedio (requiere revisión presupuestal).
- RR. HH. mantiene un gasto estable y controlado.
- Logística muestra gasto medio (puede optimizar procesos).

DIFERENCIAS CLAVE: FILTRADO VS. AGRUPACIÓN

Concepto	¿Qué hace?	¿Para qué sirve?
<code>filter()</code>	Selecciona filas según condiciones.	Enfocar el análisis en datos relevantes.
<code>group_by() + summarise()</code>	Agrupar y calcular indicadores.	Comparar resultados entre categorías o segmentos.

+

VISUALIZACIÓN:
**GRÁFICOS CON GGLOT2,
PERSONALIZACIÓN**


VISUALIZACIÓN DE DATOS

- Es el **proceso mediante el cual la información numérica se representa gráficamente** para facilitar su comprensión, análisis e interpretación.
- En el análisis estadístico, los gráficos permiten **identificar patrones, tendencias, diferencias y relaciones entre variables** que no siempre son evidentes en tablas de datos.
- En R, el paquete ggplot2 es uno de los más utilizados para la visualización de datos. Está basado en la **gramática de los gráficos**, lo que significa que los gráficos se construyen por capas, combinando datos, variables estéticas y geometrías de manera estructurada y flexible.



USO DE GGLOT2

- Es fundamental por lo siguiente:
 - Permite crear gráficos claros, profesionales y personalizables.
 - Facilita la comunicación de resultados a públicos no técnicos.
 - Es ampliamente utilizado en el ámbito empresarial y académico.
 - Permite estandarizar visualizaciones para reportes y presentaciones ejecutivas.
- En diversas áreas profesionales, los gráficos son esenciales para sustentar decisiones estratégicas basadas en datos.



CARACTERÍSTICAS Y VENTAJAS DE GGLOT2

+ CONSTRUCCIÓN POR CAPAS (LAYERS)

Los gráficos se crean agregando capas sucesivas (datos, geometrías y estilos), lo que permite modificar o ampliar el gráfico sin rehacerlo desde cero.

+ GRAMÁTICA DE LOS GRÁFICOS

Ggplot2 se basa en reglas claras que separan datos, variables y formas gráficas para facilitar la comprensión del proceso de visualización.

+ INTEGRACIÓN DIRECTA CON DATA FRAMES

Trabaja de forma natural con data frames, especialmente aquellos procesados con dplyr, lo que agiliza el flujo de análisis de datos.

+ ALTA PERSONALIZACIÓN VISUAL

Permite ajustar títulos, etiquetas, colores, escalas y temas para adaptar los gráficos a informes académicos o ejecutivos.



CARACTERÍSTICAS Y VENTAJAS DE GGLOT2

+ CONSISTENCIA Y ESTÉTICA PROFESIONAL

Los gráficos generados mantienen un estilo visual coherente y ordenado, ideal para presentaciones y reportes empresariales.

+ REPRESENTACIÓN DE DISTINTOS TIPOS DE DATOS

Soporta gráficos de barras, líneas, dispersión, cajas y muchos otros, adaptándose a datos categóricos y numéricos.

+ ESCALABILIDAD Y REUTILIZACIÓN DEL CÓDIGO

El mismo código puede aplicarse a distintos conjuntos de datos, lo que favorece la automatización y la reproducibilidad.

+ AMPLIO RESPALDO DE LA COMUNIDAD

Cuenta con abundante documentación, ejemplos y extensiones. Esto facilita el aprendizaje y la resolución de problemas reales.



PROCESO DE DESARROLLO DE UN GRÁFICO CON GGLOT2

El desarrollo de un gráfico en ggplot2 debe seguir una estructura lógica y ordenada para crear gráficos claros, correctos y fáciles de interpretar en contextos académicos y profesionales.

01 CARGAR EL PAQUETE GGLOT2

- Antes de crear cualquier gráfico, es necesario cargar el paquete ggplot2 en la sesión de R: ***library(ggplot2)***.
- Este paso habilita todas las funciones gráficas de ggplot2; sin él, R no reconoce los comandos ***ggplot()*** ni ***geom_*()***.

02 DEFINIR EL CONJUNTO DE DATOS

- El gráfico debe basarse en un conjunto de datos estructurado, generalmente un data frame, donde cada columna representa una variable y cada fila una observación.
- Ejemplo:

```
datos <- data.frame(  
  producto = c("A", "B", "C"),  
  ventas = c(2500, 3200, 2800)  
)
```

PROCESO DE DESARROLLO DE UN GRÁFICO CON GGPLOT2

03 ESPECIFICAR LAS VARIABLES ESTÉTICAS (AES)

- Las estéticas (aes) indican qué variables del conjunto de datos se asignan a los ejes, colores, tamaños u otras propiedades visuales del gráfico. Por ejemplo:
`ggplot(data = datos, aes(x = producto, y = ventas))`

04 ELEGIR EL TIPO DE GRÁFICO (GEOM_)

- Las geometrías (geom_) determinan la forma visual del gráfico, como barras, líneas o puntos.
- Cada tipo de gráfico se selecciona según el objetivo del análisis. Por ejemplo:
**`ggplot(data = datos, aes(x = producto, y = ventas)) +
geom_bar(stat = "identity")`**

05 PERSONALIZAR TÍTULOS, EJES Y ESTILOS

- La personalización mejora la claridad y presentación del gráfico, incorporando títulos, etiquetas y estilos visuales adecuados para reportes y presentaciones. Por ejemplo:

```
ggplot(data = datos, aes(x = producto, y = ventas)) +  
  geom_bar(stat = "identity") +  
  labs(  
    title = "Ventas por Producto",  
    x = "Producto",  
    y = "Ventas (S/.)"  
  ) +  
  theme_minimal()
```


EJEMPLO 1: VENTAS MENSUALES

- Una empresa desea analizar la evolución de sus ventas mensuales para identificar tendencias y apoyar decisiones comerciales.
- Los datos que se registran son los siguientes:

Mes	Enero	Febrero	Marzo	Abril	Mayo
Ventas	12,000	13,500	12,800	15,000	16,500

- A través de comandos, buscaremos que R muestre un gráfico de líneas con puntos marcando cada mes para observar visualmente el crecimiento y variaciones de las ventas a lo largo del tiempo.

+ PROGRAMACIÓN EN R

- Nota: solo la primera vez debe instalarse ggplot2: *install.packages("ggplot2")*

```
# PASO 0: instalar ggplot2 (solo 1 vez)
install.packages("ggplot2")

# PASO 1: cargar la librería
library(ggplot2)

# PASO 2: crear el conjunto de datos
ventas <- data.frame(
  mes = c("Enero", "Febrero", "Marzo", "Abril", "Mayo"),
  monto = c(12000, 13500, 12800, 15000, 16500)
)

# PASO 3: corregir el orden de los meses
# (convertir a factor con niveles)
ventas$mes <- factor(
  ventas$mes,
  levels = c("Enero", "Febrero", "Marzo", "Abril", "Mayo")
)
```

+ PROGRAMACIÓN EN R

- Nota: la variable mes es de tipo texto (character). Cuando ggplot2 recibe una variable categórica como texto, ordena alfabéticamente, no cronológicamente. Por ese motivo, se ha agregado los comandos que corrige el orden correcto de los meses (paso 3).


```
# PASO 4: verificar datos (opcional)
```

```
print(ventas)
```

```
# PASO 5: crear el gráfico
```

```
ggplot(data = ventas, aes(x = mes, y = monto, group = 1)) +  
  geom_line() +  
  geom_point() +  
  labs(  
    title = "Evolución de Ventas Mensuales",  
    x = "Mes",  
    y = "Ventas (S/.)"  
  ) +  
  theme_minimal()
```

RESULTADO EN RSTUDIO



El gráfico permite identificar una tendencia creciente en las ventas, especialmente a partir de marzo. Esto sugiere que las estrategias comerciales implementadas podrían estar dando resultados positivos, información clave para la toma de decisiones gerenciales.

EJEMPLO 2: COMPARACIÓN DE VENTAS POR REGIÓN

- Una empresa comercial desea evaluar el desempeño de ventas por región geográfica, con el fin de apoyar decisiones estratégicas de marketing y asignación de recursos. La gerencia necesita identificar qué regiones generan mayores ingresos y cuáles requieren acciones correctivas, como campañas promocionales, ajustes de precios o fortalecimiento del canal de ventas.
- Para ello, se dispone del total de ventas acumuladas por región durante un periodo determinado. A partir de esta información, se construirá un gráfico de barras que permita comparar visualmente el rendimiento regional.

Región	Norte	Sur	Este	Oeste
Ventas	45,000	38,000	42,000	50,000

+ PROGRAMACIÓN EN R

En los comandos:

- `fill = region` → asigna un color distinto a cada región.
- `geom_text()` → agrega el valor numérico sobre la barra.
- `vjust = -0.5` → posiciona el texto ligeramente encima.

```
# PASO 1: cargar la librería
```

```
library(ggplot2)
```


```
# PASO 2: crear el conjunto de datos
```

```
ventas_region <- data.frame(  
  region = c("Norte", "Sur", "Este", "Oeste"),  
  ventas = c(45000, 38000, 42000, 50000)  
)
```

+ PROGRAMACIÓN EN R

```
# PASO 3: crear el gráfico de barras
# con colores y etiquetas de valores
ggplot(data = ventas_region, aes(x = region, y = ventas, fill = region)) +
  geom_bar(stat = "identity") +
  geom_text(
    aes(label = ventas),
    vjust = -0.5
  ) +
  labs(
    title = "Comparación de Ventas por Región",
    x = "Región",
    y = "Ventas Totales ($/.)"
  ) +
  theme_minimal() +
  guides(fill = "none")
```

RESULTADO EN RSTUDIO



El gráfico permite identificar de forma inmediata que la región oeste lidera las ventas, seguida por la región norte. La región sur presenta el menor desempeño, lo que sugiere la necesidad de reforzar estrategias comerciales o promocionales en esa zona.

+

PRUEBAS ESTADÍSTICAS:
T-TEST,
CORRELACIONES EN R


PRUEBAS ESTADÍSTICAS

- Son procedimientos que **permiten analizar datos muestrales para sacar conclusiones sobre una población**, lo que reduce la incertidumbre en la toma de decisiones.
- Su objetivo principal es comprobar la hipótesis y determinar si los resultados observados son producto del azar o reflejan un efecto real.
- En el ámbito empresarial y profesional, las pruebas estadísticas aportan rigurosidad y respaldo cuantitativo, ya que evitan decisiones basadas únicamente en la intuición o la experiencia subjetiva.



T-TEST (PRUEBA T DE STUDENT)

- El **t-test es una prueba estadística fundamental para comparar las medias de uno o dos grupos de datos** y determinar si la diferencia observada es estadísticamente significativa o por azar.
- Es especialmente útil cuando se trabaja con muestras pequeñas y variables cuantitativas, bajo el supuesto de normalidad de los datos, condición particularmente relevante en tamaños muestrales reducidos.
- Permite comparar la media de una muestra con un valor conocido o las medias entre dos muestras independientes o pareadas, con el fin de contrastar y validar hipótesis científicas.




TIPOS DE T-TEST

Existen principalmente los siguientes:



¿POR QUÉ EL T-TEST ES CLAVE?



Es ampliamente utilizado en marketing (campañas), finanzas (rendimientos) y administración (productividad).

PROCESO DE DESARROLLO DEL T-TEST EN R

- 01** **DEFINIR EL PROBLEMA Y LOS GRUPOS A COMPARAR**
Se identifica qué medias se desean comparar y a qué grupos pertenecen los datos. Por ejemplo: comparar ventas promedio con estrategia tradicional vs. nueva estrategia.
- 02** **PLANTEAR HIPÓTESIS (NULA Y ALTERNATIVA)**
Se formula una hipótesis nula (no hay diferencia) y una alternativa (sí hay diferencia). Por ejemplo: H_0 : ventas tradicionales = ventas nuevas; H_1 : ventas tradicionales $\neq$ ventas nuevas.
- 03** **PREPARAR LOS DATOS**
Los datos se organizan en vectores numéricos o columnas de un data frame. Por ejemplo: `ventas_trad <- c(1200, 1300, 1250)` y `ventas_nueva <- c(1400, 1450, 1500)`.
- 04** **EJECUTAR LA PRUEBA EN R**
Se utiliza la función `t.test()` indicando los grupos a comparar.
Por ejemplo: `t.test(ventas_trad, ventas_nueva)`.
- 05** **INTERPRETAR EL VALOR P Y EL RESULTADO**
Se compara el valor p con 0.05 para aceptar o rechazar la hipótesis nula.
Por ejemplo: si $p < 0.05$, la diferencia de ventas es estadísticamente significativa.

EJEMPLO 1: COMPARACIÓN DE VENTAS POR ESTRATEGIA

- Una empresa comercial ha implementado una nueva estrategia de marketing digital y desea evaluar si ha generado un incremento significativo en las ventas promedio en comparación con la estrategia tradicional utilizada anteriormente.
- Para sustentar la decisión de adoptar la nueva estrategia de manera permanente, la gerencia solicita un análisis estadístico formal que permita determinar si la diferencia observada en ventas es estadísticamente significativa. Para ello, se utilizará una prueba t para dos muestras independientes, empleando R.

Observación	Estrategia tradicional	Nueva estrategia
1	1,200	1,400
2	1,300	1,450
3	1,250	1,500
4	1,280	1,480
5	1,270	1,420

+ PROGRAMACIÓN EN R

- Comando en R:

```
# Crear los datos de ventas
ventas_tradicional <- c(1200, 1300, 1250, 1280, 1270)
ventas_nueva <- c(1400, 1450, 1500, 1480, 1420)

# Ejecutar la prueba t de Student
t.test(ventas_tradicional, ventas_nueva)
```

- Resultado resumen:

```
Welch Two Sample t-test
data: ventas_tradicional and ventas_nueva
t = -7.5698, df = 7.9499, p-value = 6.706e-05
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -247.9438 -132.0562
sample estimates:
mean of x mean of y
 1260    1450
```


INTERPRETACIÓN DE RESULTADOS



- Media de ventas (estrategia tradicional): 1,260.
- Media de ventas (nueva estrategia): 1,450.

Esto indica que, en promedio, la nueva estrategia genera 190 unidades monetarias más en ventas.



- $t = -7.5698$ (el valor negativo indica que la media de la estrategia tradicional es menor que la de la nueva estrategia).
- $df = 7.9499$ (grados de libertad ajustados para el cálculo del estadístico t).



- $p\text{-value} = 6.706e-05$ (0.00006706).

Este valor es mucho menor que 0.05, lo que indica que la probabilidad de que la diferencia observada sea producto del azar es extremadamente baja.

Entonces, se rechaza la hipótesis nula, que planteaba que no existía diferencia entre las medias.

INTERPRETACIÓN DE RESULTADOS



- Intervalo: $[-247.94 ; -132.06]$.

Este intervalo no incluye el valor cero, lo que confirma que la diferencia entre las medias es estadísticamente significativa.


Además, indica que la nueva estrategia supera a la tradicional entre 132 y 248 unidades monetarias, con un 95% de confianza.



- Desde una perspectiva empresarial, los resultados evidencian que la nueva estrategia de marketing genera un incremento real y significativo en las ventas promedio. Esto respalda la decisión de implementar la nueva estrategia de forma permanente, así como considerar un mayor presupuesto o su replicación en otros mercados.
- El t-test confirma, con alta evidencia estadística, que la nueva estrategia es más efectiva que la tradicional en términos de ventas. Este tipo de análisis permite tomar decisiones gerenciales basadas en datos y no en suposiciones, lo que fortalece la gestión estratégica de la empresa.

ANÁLISIS DE CORRELACIÓN

- La correlación es una medida estadística que **permite identificar y cuantificar el grado y la dirección de la relación entre dos variables cuantitativas**. Indica si, cuando una variable aumenta, la otra también lo hace, disminuye o si no existe un patrón claro de relación entre ellas.
- Es importante destacar que la correlación no implica causalidad; es decir, que dos variables estén relacionadas no significa necesariamente que una sea causa de la otra.



COEFICIENTE DE CORRELACIÓN

Toma valores entre -1 y $+1$, y se interpreta de la siguiente manera:


- **-1 (correlación negativa perfecta):** cuando una variable aumenta, la otra disminuye de forma proporcional.
- **0 (sin correlación):** no existe una relación lineal observable entre las variables.
- **$+1$ (correlación positiva perfecta):** ambas variables aumentan o disminuyen juntas de manera proporcional.



IMPORTANCIA DE LA CORRELACIÓN

- **Identifica relaciones entre variables clave**, como ventas y gasto publicitario, ingresos y costos, o precio y demanda.
- **Apoya la formulación de estrategias** al reconocer qué variables se mueven conjuntamente y pueden ser gestionadas de manera integrada.
- **Detecta patrones y comportamientos en datos**, lo que facilita el análisis exploratorio previo a modelos más avanzados.

En síntesis, la correlación ayuda a transformar datos en información útil y reduce la incertidumbre en la toma de decisiones.



PROCESO DEL ANÁLISIS DE CORRELACIÓN EN R

- 01** **IDENTIFICAR LAS VARIABLES A ANALIZAR**
Seleccionar dos variables relevantes para el problema de estudio, como ventas y publicidad, precio y demanda, o riesgo y retorno.
- 02** **VERIFICAR QUE SEAN VARIABLES CUANTITATIVAS**
Confirmar que ambas variables estén medidas numéricamente, ya que la correlación se aplica únicamente a datos cuantitativos.
- 03** **EJECUTAR EL CÁLCULO DE CORRELACIÓN EN R**
Utilizar funciones estadísticas para obtener el coeficiente de correlación y evaluar la relación entre las variables.
- 04** **ANALIZAR EL COEFICIENTE DE CORRELACIÓN**
Evaluar la fuerza y dirección de la relación (positiva o negativa) y verificar si es estadísticamente significativa.
- 05** **INTERPRETAR EL RESULTADO EN SU CONTEXTO PROFESIONAL**
Traducir el resultado estadístico a conclusiones prácticas que apoyen la toma de decisiones empresariales o estratégicas.

EJEMPLO 2: INVERSIÓN EN PUBLICIDAD Y VENTAS

- Una empresa desea analizar si existe una relación entre la inversión mensual en publicidad y el nivel de ventas obtenidas. La gerencia necesita esta información para evaluar si el incremento del presupuesto publicitario está asociado a mayores ingresos por ventas y así respaldar decisiones estratégicas de marketing.
- Para ello, se dispone de información correspondiente a 6 meses, en la que se registra el monto invertido en publicidad y las ventas alcanzadas en cada periodo.

Mes	Inversión en publicidad (\$/ miles)	Ventas (\$/ miles)
Enero	10	120
Febrero	12	135
Marzo	15	160
Abril	18	180
Mayo	20	195
Junio	22	210

+ PROGRAMACIÓN EN R

- Comando en R:

```
# Crear el conjunto de datos
publicidad <- c(10, 12, 15, 18, 20, 22)
ventas <- c(120, 135, 160, 180, 195, 210)

# Calcular la correlación
cor.test(publicidad, ventas)
```

- Resultado resumen:

```
Pearson's product-moment correlation
data: publicidad and ventas
t = 68.842, df = 4, p-value = 2.668e-07
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.9959529 0.9999561
sample estimates:
      cor
0.9995783
```


INTERPRETACIÓN DE RESULTADOS



- Coeficiente de correlación (r): 0.9996.

Este valor es muy cercano a +1, lo que indica una relación positiva casi perfecta entre la inversión en publicidad y las ventas. A medida que aumenta la inversión publicitaria, las ventas también se incrementan de forma consistente.



- $t = 68.842$ (un valor t tan elevado refleja una relación extremadamente fuerte entre ambas variables).
- $df = 4$ (corresponde al número de grados de libertad del análisis, considerando el tamaño de la muestra).



- $p\text{-value} = 2.668e-07$ (0.0000002668).

Este valor es mucho menor que 0.05, lo que indica que la probabilidad de que esta relación se deba al azar es prácticamente nula.

Entonces, se rechaza la hipótesis nula, que establece que no existe correlación entre inversión en publicidad y ventas.

INTERPRETACIÓN DE RESULTADOS



- Intervalo: $[0.9959 ; 0.9999]$.

Este intervalo se encuentra completamente por encima de cero y muy próximo a 1, lo que confirma con un 95% de confianza que la relación entre ambas variables es positiva y muy fuerte.



- Desde una perspectiva empresarial y de marketing, los resultados evidencian que incrementar la inversión en publicidad está fuertemente asociado con un aumento en las ventas. Esto proporciona un respaldo estadístico sólido para justificar decisiones de asignación de presupuesto publicitario y estrategias de crecimiento comercial.
- Aunque la correlación es muy alta, no prueba causalidad directa. Sin embargo, en este contexto, el resultado es un indicador muy relevante para la toma de decisiones estratégicas y para estudios posteriores más avanzados, como modelos de regresión.

DIFERENCIAS CLAVE ENTRE T-TEST Y CORRELACIÓN

Aspecto	T-test	Correlación
Objetivo	Comparar medias.	Medir relación.
Tipo de variables	Cuantitativa vs. grupos.	Dos cuantitativas.
Resultado principal	P-value.	Coeficiente.
Uso típico	Comparaciones.	Asociaciones.

+

AUTOMATIZACIÓN: SCRIPTS
REUTILIZABLES EN R

AUTOMATIZACIÓN EN R

- Consiste en diseñar y ejecutar scripts (archivos .R) que **contienen un conjunto de instrucciones estadísticas que pueden ejecutarse de forma repetida, ordenada y automática.**
- Un script permite realizar tareas como limpieza de datos, análisis estadístico, generación de gráficos y reportes sin necesidad de rehacer manualmente cada paso.



AUTOMATIZACIÓN EN R


- En lugar de ejecutar comandos de manera aislada en la consola, el analista organiza todo el proceso en un archivo estructurado.
- Esto convierte el análisis en **un proceso reproducible**, en el que los mismos resultados pueden obtenerse nuevamente al ejecutar el script sobre los mismos datos o sobre datos actualizados.



¿POR QUÉ LA AUTOMATIZACIÓN ES CLAVE?

En entornos profesionales, la automatización es fundamental por lo siguiente:

- Ahorra tiempo en análisis repetitivos (reportes mensuales, análisis de ventas, indicadores financieros).
- Reduce errores humanos al evitar la repetición de procesos manuales.
- Garantiza consistencia, ya que siempre se aplican las mismas reglas de análisis.
- Facilita el trabajo en equipo, puesto que otros analistas pueden entender y reutilizar el script.
- Permite escalabilidad, adaptando el análisis a más datos o nuevos periodos.



CARACTERÍSTICAS DE UN SCRIPT REUTILIZABLE EN R

Estructura clara	Uso de funciones	Comentarios explicativos	Flexibilidad	Reproducibilidad
Carga de librerías, importación de datos, procesamiento, análisis y resultados.	Evita repetir código.	Facilitan la comprensión del proceso.	Permite cambiar datos de entrada sin modificar todo el código.	Garantiza que cualquier persona pueda obtener los mismos resultados.

PROCESO DE DESARROLLO DE UN SCRIPT AUTOMATIZADO EN R

- 01** **DEFINIR CLARAMENTE EL OBJETIVO DEL ANÁLISIS**

Antes de escribir cualquier línea de código, es fundamental identificar qué se desea analizar y para qué. El objetivo guía todo el desarrollo del script y evita análisis innecesarios. Por ejemplo: analizar la evolución mensual de las ventas, comparar el rendimiento de dos campañas publicitarias, calcular indicadores financieros de forma periódica.
- 02** **ORGANIZAR EL ENTORNO DE TRABAJO**

En este paso se prepara el entorno donde se ejecutará el script:

 - Carga de librerías necesarias (dplyr, ggplot2, etc.).
 - Definición del directorio de trabajo.
 - Verificación de versiones y dependencias.
- 03** **IMPORTAR Y COMPRENDER LOS DATOS**

Se cargan los datos desde archivos (Excel, CSV, bases de datos) o se reciben como entrada al script. En este paso se realiza lo siguiente:

 - Revisa la estructura de los datos.
 - Identifican tipos de variables (numéricas, categóricas, fechas).
 - Detectan posibles valores faltantes o errores.

PROCESO DE DESARROLLO DE UN SCRIPT AUTOMATIZADO EN R

04 LIMPIEZA Y PREPARACIÓN DE LOS DATOS

Antes del análisis estadístico, los datos deben ser depurados:

- Eliminación o imputación de valores faltantes.
- Filtrado de registros irrelevantes.
- Creación de nuevas variables necesarias para el análisis.

05 ENCAPSULAR TAREAS REPETITIVAS MEDIANTE FUNCIONES

Para lograr reutilización, las tareas que se repiten deben transformarse en funciones. Una función agrupa instrucciones bajo un mismo nombre y permite ejecutarlas con distintos datos.

06 EJECUTAR EL ANÁLISIS ESTADÍSTICO AUTOMÁTICAMENTE

Una vez preparados los datos y definidas las funciones, el script ejecuta:

- Cálculos estadísticos (promedios, pruebas, correlaciones).
- Resúmenes y tablas automáticas.
- Gráficos cuando sea necesario, definidos bajo un mismo nombre, lo que permite ejecutarlos con distintos datos.

Todo el análisis se realiza con una sola ejecución del script, sin intervención manual. Esto permite actualizar análisis rápidamente cuando llegan nuevos datos.

PROCESO DE DESARROLLO DE UN SCRIPT AUTOMATIZADO EN R

07 VALIDAR Y VERIFICAR LOS RESULTADOS

Antes de usar los resultados para tomar decisiones, es necesario:

- Revisar que los valores obtenidos sean coherentes.
- Comparar con periodos anteriores o valores esperados.
- Detectar posibles errores lógicos.

08 DOCUMENTAR EL SCRIPT Y LOS RESULTADOS

La documentación permite que otros analistas comprendan, reutilicen y mejoren el script, lo que favorece el trabajo colaborativo. Un buen script incluye comentarios explicativos en el código, nombres claros de variables y funciones, y una breve descripción del objetivo del análisis.

09 REUTILIZAR Y ESCALAR EL SCRIPT

Finalmente, el script puede:

- Usarse con nuevos datos (otros meses, años o áreas).
- Adaptarse a más variables o análisis adicionales.
- Integrarse en reportes o sistemas automáticos.

Este paso convierte al script en una herramienta estratégica, no solo en un análisis puntual.

EJEMPLO: AUTOMATIZACIÓN EN EL ÁREA DE MARKETING

- Una empresa realiza campañas mensuales de marketing digital (redes sociales, anuncios pagados y promociones online). La gerencia de marketing necesita evaluar periódicamente si la inversión realizada en publicidad está generando un impacto positivo en las ventas.
- Debido a que este análisis se realiza todos los meses, se decide crear un script automatizado en R que permita:
 - **Analizar los datos de inversión y ventas.**
 - **Calcular indicadores clave de forma automática.**
 - **Evaluar la relación entre inversión publicitaria y ventas.**
 - **Reutilizar el análisis con nuevos datos sin rehacer el proceso.**

EJEMPLO: AUTOMATIZACIÓN EN EL ÁREA DE MARKETING

Se dispone de la siguiente información mensual:

Mes	Inversión publicitaria (S/)	Ventas (S/)
Enero	5,000	45,000
Febrero	7,000	52,000
Marzo	6,500	50,000
Abril	8,000	61,000
Mayo	9,000	68,000

El objetivo del análisis es:

- Calcular el promedio de inversión y el de ventas.
- Medir la correlación entre inversión publicitaria y ventas.
- Automatizar el proceso mediante una función reutilizable en R.

+ PROGRAMACIÓN EN R

1. LIMPIAR EL ENTORNO DE TRABAJO

```
rm(list = ls())
```

2. CARGAR LIBRERÍAS NECESARIAS

```
library(dplyr)
```

3. CREACIÓN DEL CONJUNTO DE DATOS

(En un caso real, estos datos podrían importarse desde Excel o CSV)

```
marketing <- data.frame(  
  mes = c("Ene", "Feb", "Mar", "Abr", "May"),  
  inversion = c(5000, 7000, 6500, 8000, 9000),  
  ventas = c(45000, 52000, 50000, 61000, 68000)  
)
```

4. REVISIÓN INICIAL DE LOS DATOS

```
str(marketing)  
summary(marketing)
```

+ PROGRAMACIÓN EN R

5. DEFINICIÓN DE LA FUNCIÓN AUTOMATIZADA

Esta función puede reutilizarse con nuevos datos mensuales

```
analisis_marketing <- function(datos) {  
  
  resumen <- datos %>%  
    summarise(  
      inversion_promedio = mean(inversion),  
      ventas_promedio = mean(ventas),  
      correlacion_inversion_ventas = cor(inversion, ventas)  
    )  
  
  return(resumen)  
}
```

6. EJECUCIÓN DEL ANÁLISIS AUTOMATIZADO

```
resultado <- analisis_marketing(marketing)
```

7. VISUALIZACIÓN DEL RESULTADO

```
print(resultado)
```

+ PROGRAMACIÓN EN R

```
# 8. INTERPRETACIÓN AUTOMÁTICA (OPCIONAL)
if (resultado$correlacion_inversion_ventas > 0.8) {
  mensaje <- "Existe una relacion positiva y fuerte entre la inversion publicitaria y las ventas."
} else {
  mensaje <- "La relacion entre la inversion publicitaria y las ventas es debil o moderada."
}

print(mensaje)
```

- Resultado resumen:

```
summary(marketing)
  mes      inversion  ventas
Length:5      Min. :5000 Min. :45000
Class :character 1st Qu.:6500 1st Qu.:50000
Mode :character Median :7000 Median :52000
      Mean :7100 Mean :55200
      3rd Qu.:8000 3rd Qu.:61000
      Max. :9000 Max. :68000
inversion_promedio ventas_promedio correlacion_inversion_ventas
1          7100          55200          0.974391
```


Interpretación de Resultados:



- La inversión publicitaria presenta valores entre 5,000 y 9,000, con un promedio de 7,100. Esto indica que la empresa mantiene una inversión relativamente constante, con incrementos progresivos en algunos meses.
- La mediana de la inversión (7,000) es cercana al promedio, lo que sugiere que los datos no están fuertemente sesgados.



- Las ventas mensuales oscilan entre 45,000 y 68,000, con un promedio de 55,200, lo que refleja un crecimiento general alineado con el aumento de la inversión.
- El tercer cuartil de ventas (61,000) indica que el 75% de los meses analizados alcanzó ventas iguales o inferiores a ese valor, lo que muestra un desempeño comercial favorable en los últimos periodos.



- El resultado sugiere que la inversión en campañas de marketing digital está teniendo un impacto directo y significativo en el volumen de ventas. La alta correlación evidencia que la publicidad es un factor clave en el desempeño comercial de la empresa durante el periodo analizado.

+

REPORTES: GENERACIÓN DE
INFORMES ESTADÍSTICOS

INFORME ESTADÍSTICO

- Es un **documento estructurado que presenta de manera clara y ordenada los resultados de un análisis de datos**, en el cual combina texto explicativo, tablas, gráficos y conclusiones.
- Su objetivo principal es **comunicar los hallazgos del análisis para apoyar la toma de decisiones**.
- En R, la generación de reportes permite integrar el análisis estadístico con la presentación de resultados para evitar copiar y pegar resultados manualmente. Esto garantiza que el informe esté siempre alineado con los datos analizados.



IMPORTANCIA DE LOS REPORTES EN EL ÁMBITO PROFESIONAL

- Transforman resultados técnicos en información comprensible para directivos y clientes.
- Respaldan decisiones estratégicas con evidencia cuantitativa.
- Estandarizan la comunicación de resultados dentro de la organización.
- Permiten actualización automática cuando cambian los datos.
- Reducen errores al evitar la transcripción manual de resultados.




CARACTERÍSTICAS DE UN BUEN INFORME ESTADÍSTICO

Claridad	Estructura lógica	Reproducibilidad	Integración	Orientación a la decisión
Lenguaje sencillo y visualizaciones comprensibles.	Introducción, metodología, resultados e interpretación.	El mismo informe puede generarse nuevamente con nuevos datos.	Combina análisis, gráficos y conclusiones en un solo documento.	Los resultados deben responder a un problema real.

COMANDOS Y HERRAMIENTAS EN R PARA LA GENERACIÓN DE REPORTES ESTADÍSTICOS

Comando / Herramienta	Función principal
rmarkdown	Reportes dinámicos: herramienta principal en R para generar reportes automáticos que integran texto, código, tablas, gráficos y resultados estadísticos en un solo documento.
render()	Generar el reporte final: permite generar el informe final a partir de un archivo .Rmd sin intervención manual. Se crea automáticamente un archivo HTML, PDF o Word con los resultados del análisis.
kable()	Tablas claras: convierte data frames en tablas limpias y legibles, ideales para reportes. Facilita la presentación de resultados numéricos a públicos no técnicos.
ggplot2	Gráficos profesionales que se incrustan directamente en los informes.
cat()	Texto automático y dinámico que cambia automáticamente según los datos. Permiten insertar texto automático en el reporte usando resultados estadísticos.
summary()	Estadísticas descriptivas: genera un resumen rápido de variables numéricas y categóricas.
sink()	Exportar resultados: redirige la salida de R a un archivo de texto.

A collection of white line-art icons on a purple background. At the top left is a stack of three papers. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

- + El análisis estadístico en R integra herramientas de manipulación, visualización, pruebas estadísticas, automatización y generación de reportes que fortalecen el proceso de análisis de datos en contextos empresariales y académicos. Su enfoque reproducible y orientado a resultados lo convierte en una herramienta clave para la formación de profesionales competitivos.
- + El uso de R promueve el pensamiento analítico, la interpretación rigurosa de la información y la toma de decisiones sustentadas en evidencia. El dominio de estas herramientas prepara a los profesionales para enfrentar retos reales del mercado laboral, aportando valor a las organizaciones mediante el uso estratégico de los datos.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

+ BIBLIOGRAFÍA

- + Paredes Inilupu, D. (2024). *Data science con R: Análisis de datos y algoritmos de predicción con R* (2.ª ed., ed. digital). Leanpub.
- + Quispe Gutiérrez, A. M. (2023). *Análisis estadístico con R*. UTEC Press.
- + Salas Eljatib, C. (2021). *Análisis de datos con el programa estadístico R: Una introducción aplicada*. Ediciones Universidad Mayor.



ISIL+