

+ TEMA 14

RECOPILACIÓN Y ANÁLISIS DE DATOS

- Obtención de datos relevantes: datasets abiertos, API, bases internas
- Limpieza: manejo de datos faltantes, outliers
- Preprocesamiento: normalización, transformación
- Métodos estadísticos: pruebas, correlaciones
- Minería de datos: aplicación de algoritmos





+ INTRODUCCIÓN **DE LA SESIÓN**

- + La sesión 14 representa la fase central del proyecto integrador. Aquí los estudiantes deben convertir su diseño inicial en un proceso técnico real analizando los datos. Aprenderán a obtener su dataset, limpiarlo y dejarlo listo para análisis estadístico y algoritmos de minería de datos.
- + Esta sesión busca que cada estudiante aplique paso a paso técnicas profesionales de tratamiento de datos, utilizando R o Python según lo elegido.
- + Al finalizar, el estudiante tendrá un dataset limpio, transformado y analizado, listo para insertarlo en la presentación final de la sesión 15.



+

OBTENCIÓN DE DATOS RELEVANTES:
**DATASETS ABIERTOS, API,
BASES INTERNAS**

OBTENCIÓN DE DATOS RELEVANTES

- Los datos pueden obtenerse de fuentes abiertas como Kaggle, OpenData, plataformas gubernamentales o API.
- Es importante que la fuente sea confiable y que el conjunto de datos esté alineado con los objetivos del proyecto.
- Una vez descargado el dataset, se debe revisar su estructura inicial:
 - **Cantidad de registros.**
 - **Columnas disponibles.**
 - **Tipos de variables y posibles errores evidentes.**



APLICACIÓN AL PROYECTO

- Describir la fuente y su relevancia para el problema planteado.
- Cargar el dataset en R o Python, y visualizar las primeras filas.
- Identificar variables principales y detectar estructuras inusuales.

Ejemplo:

- Un dataset sobre compras online puede contener columnas como edad, monto gastado, frecuencia de compra, categoría de producto, etc.
- El estudiante debe revisar si las categorías están completas, si las edades tienen rangos razonables y si las fechas están en un formato legible.



+

LIMPIEZA:

MANEJO DE DATOS

FALTANTES, OUTLIERS

DATOS FALTANTES

- Pueden generar sesgos o impedir el funcionamiento de algunos modelos. **Primero deben identificarse y luego decidir si se eliminan o se reemplazan con valores apropiados** (media, mediana o moda).
- También es importante detectar valores extremos (outliers) porque pueden distorsionar análisis estadísticos y modelos predictivos.



APLICACIÓN AL PROYECTO

- Calcular cuántos datos faltantes existen por variable.
- Decidir qué estrategia aplicar y justificarse.
- Representar los datos mediante gráficos como boxplots para identificar outliers.

Ejemplo:

- Si la variable ingreso contiene un valor de “3,000,000” cuando la mayoría está entre 800 y 4,000, el estudiante debe evaluar si es un error o un caso válido.
- Si frecuencia de compra tiene 10% de datos vacíos, podría imputarse la mediana del grupo.



+

PREPROCESAMIENTO:
**NORMALIZACIÓN,
TRANSFORMACIÓN**

NORMALIZACIÓN Y TRANSFORMACIÓN

- Algunos algoritmos requieren que las variables estén en una misma escala. La **normalización** (escalar entre 0 y 1) o la **estandarización** (convertir a media 0 y desviación estándar 1) ayudan a mejorar el desempeño de los modelos.
- Además, las variables categóricas deben transformarse en valores numéricos mediante técnicas como **“dummies”** o **“one-hot encoding”**.



APLICACIÓN AL PROYECTO

- Escalar variables numéricas si usará algoritmos basados en distancia (k-means, KNN).
- Transformar categorías en columnas binarias.
- Crear nuevas variables útiles: mes, rango de edad, antigüedad, etc.

Ejemplo:

- Si el dataset tiene la columna género, debe convertirse en variables como `genero_femenino` y `genero_masculino`.
- Si se realiza un clustering con ingreso y gasto, ambos deben normalizarse para que un valor no domine al otro.



+

MÉTODOS ESTADÍSTICOS:
PRUEBAS, CORRELACIONES

MÉTODOS ESTADÍSTICOS

El análisis estadístico permite encontrar relaciones y diferencias entre variables.

PRUEBAS ESTADÍSTICAS

- Sirven para contrastar hipótesis planteadas en el proyecto.

CORRELACIONES

- Ayudan a entender si dos variables se mueven juntas.

APLICACIÓN AL PROYECTO

- **Calcular correlaciones entre variables clave.**
- **Aplicar al menos una prueba estadística (t-test, ANOVA, Chi-cuadrado).**
- **Interpretar resultados en lenguaje claro.**

Ejemplo:

- Si se analiza la intención de compra, el estudiante puede revisar si existe relación entre satisfacción y frecuencia de compra.
- Una prueba t podría mostrar si existe diferencia significativa en el gasto promedio entre dos grupos (por ejemplo, hombres y mujeres).




+

MINERÍA DE DATOS:
APLICACIÓN DE ALGORITMOS

MINERÍA DE DATOS

Permite descubrir patrones, segmentar poblaciones o predecir comportamientos.



APLICACIÓN AL PROYECTO

- **Elegir un algoritmo adecuado al objetivo (clasificar, predecir, agrupar).**
- **Entrenar el modelo con parte de los datos y validar resultados.**
- **Presentar métricas simples (accuracy, RMSE, silhouette) o gráficos generados.**

Ejemplo:

- Para segmentar clientes, se puede aplicar k-means y obtener grupos según gasto e ingreso.
- Para predecir si un cliente comprará el producto, un árbol de decisión puede mostrar qué factores influyen más.
- Para estimar cuántas ventas aporta una campaña, una regresión lineal es suficiente.



+ **CONCLUSIONES**



x



x



+ CONCLUSIONES

- + Al finalizar esta sesión, cada estudiante debe contar con un dataset limpio, transformado y analizado. Esto permite que las técnicas estadísticas y los algoritmos aplicados generen resultados confiables y útiles para la siguiente etapa del proyecto.
- + La sesión constituye la base analítica del trabajo final: a partir de los datos preparados y los modelos ejecutados, el estudiante podrá interpretar hallazgos y construir conclusiones sólidas para su presentación final.





x



x



+ BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Bruce, P., Bruce, A., & Gedeck, P. (2022). *Estadística práctica para ciencia de datos con R y Python* (2ª ed.). Marcombo.
- + Caballero, R., Martín, E., & Riesco, A. (2023). *Análisis y minería de textos con Python*. RC Libros.
- + Fernández-Avilés, G., & Montero, J. M. (Eds.). (2024). *Fundamentos de ciencia de datos con R*. Editorial Universidad de Granada.



ISIL+