

Diseño de soluciones IA: PROCESO DE APRENDIZAJE N° 002

Nombres: Carlos Enrique Gil Carrillo

Casos de Estudio: Clínica Privada y Banco Nacional

Pregunta 01 (10 puntos)

Contexto

La actividad describe un proyecto de una clínica privada que implementará IA para predecir enfermedades metabólicas. El equipo de ciencia de datos detecta problemas de calidad en el dataset, como valores imposibles, porcentajes mayores a 100%, registros duplicados y formatos de fecha inconsistentes.

También plantea un banco nacional que quiere mejorar campañas y modelos predictivos, pero enfrenta alta correlación entre variables financieras y la falacia de causalidad en un ejemplo de helados y accidentes.

Tipo de problema de calidad de datos

Tipo de Defecto	Ejemplo	Impacto en IA
Valores inválidos	Edad = 250 años, % > 100	Modelo aprende patrones imposibles, predicciones irreales
Datos incompletos	30% sin peso, 25% sin glucosa	Pérdida de información clínica, sesgo en entrenamiento
Formato inconsistente	Fechas: 01/02/2025 vs 2025-02-01	Imposibilita análisis temporal, correlaciones incorrectas
Duplicados	uan García" vs "juan garcia" vs "JUAN GARCIA	Infla importancia de patrones, duplica predicciones

Se trata de un problema de calidad de datos o "dirty data". Incluye múltiples defectos:

El impacto acumulado: **predicciones sesgadas, no confiables y potencialmente peligrosas en diagnóstico médico.**

2. Estrategia para tratar valores nulos en la variable "peso" cuando solo el 3 % de registros los tiene

Con solo 3% nulo, **imputar es mejor que eliminar** (clase 5, sección manejo de datos faltantes).

Paso 1: Evaluar el patrón

- **MCAR (Missing Completely At Random):** Nulo sin relación con otras variables → seguro imputar
- **MAR (Missing At Random):** Nulo depende de variables observadas → requiere cuidado
- **MNAR (Missing Not At Random):** Nulo relacionado con el valor mismo → riesgo de sesgo

En clínica, muchos pesos faltantes son MAR (pacientes en cuidados intensivos, sin protocolo completo).

Paso 2: Seleccionar método según distribución

Método	Cuándo Usarlo	Ejemplo en Clínica
Media	Distribución cercana a normal	3000 pacientes con peso medio=75kg
Mediana	Distribución sesgada o con outliers	Pesos con algunos pacientes muy obesos distorsionan media
Regresión	Correlación con edad/talla	Predecir peso faltante usando edad, talla, sexo del paciente
KNN	Múltiples variables correlacionadas	Usar 5 pacientes similares (edad, género, diabetes) para estimar peso

Paso 3: Validación

- Documentar qué registros fueron imputados
- Comparar distribución antes/después
- Verificar que no introduzca sesgo en diagnóstico

Por qué no eliminar:

- Perder 3% = 90 historias clínicas de 3000 pacientes
- Sesgo de selección: ¿quién falta? ¿pacientes graves? ¿urgencias?
- Modelo entrenado con dataset sesgado hace predicciones incorrectas

Pregunta 02 (10 puntos)

Contexto

Un banco nacional quiere mejorar sus campañas de marketing y modelos predictivos de riesgo crediticio. Tiene un dataset con 40 variables sobre clientes: edad, ingresos anuales, deuda total, historial de crédito, años de empleo, educación, número de dependientes, tipo de vivienda, etc.

Problema 1: Las 40 variables están altamente correlacionadas (edad con ingresos, ingresos con deuda, educación con ingresos, etc.). Esto hace que los modelos sean lentos y difíciles de interpretar.

Problema 2: Un analista dice: "He observado que en verano aumentan los consumidores de helados Y también aumentan los accidentes de tránsito. Por lo tanto, el consumo de helados causa accidentes." ¿Es correcto este razonamiento?

Las preguntas buscan evaluar si entiendes reducción de dimensionalidad y la diferencia entre correlación y causalidad.

#1. ¿Cuál es la técnica de dimensionalidad más adecuada?

Respuesta: PCA (Análisis de Componentes Principales)

Por qué PCA y no otra técnica

El banco tiene 40 variables muy correlacionadas (edad, ingresos, deuda, educación, etc.).

- No tienes etiquetas (no sabes quién es cliente bueno/malo)
- Quieres solo explorar y entender datos
- Ejemplo: El banco no hay etiquetas de riesgo, según el texto

El problema: Muchas variables dicen casi lo mismo.

- Si subes edad → suben ingresos
- Si suben ingresos → baja deuda
- Edad y educación están vinculadas

La solución: PCA agrupa estas variables en nuevas dimensiones que NO se repiten.

Ejemplo:

- Variable 1: Edad (50 años)
- Variable 2: Ingresos (\$100k)
- Variable 3: Años de experiencia (25 años)

Estas tres dicen algo parecido: qué tan "experimentado y establecido" es el cliente.

PCA las combina en 1 nueva variable: PC1 = "Madurez financiera"

Posibles 40 variables correlacionadas:

40 variables correlacionadas

↓ PCA

10 nuevas variables (componentes)

- PC1: Madurez financiera (35% de info)
- PC2: Estabilidad laboral (18% de info)
- PC3: Educación/formación (12% de info)
- ... 7 componentes más

↓

Total: 95% de la información original

Resultado

Antes	Despues
40 variables con redundancia	10 componentes sin redundancia
Lento de calcular	Rápido
Difícil de interpretar	Fácil: cada componente es claro

2. ¿Tienen razón al decir que helados causa accidentes?

Respuesta: NO. Es una falacia.

El error:

- Verano = + helados y + accidentes
- Conclusión incorrecta: "Helados causa accidentes"

La explicación correcta

La culpa no es de los helados. El culpable es el **verano (temperatura)**.

VERANO (la causa real)

- + calor → Gente quiere helados
- + calor → Gente sale más a la calle/auto
→ + viajes → + accidentes

Visualización

Época	Temperatura	Helados/día	Accidentes/día
Invierno	10°C	500	5
Verano	28°C	3000	25

Media de Helados ($\bar{X}$): $\bar{X} = (500 + 1500 + 3000 + 800) / 4 = 5800 / 4 = 1450$

Media de Accidentes ($\bar{Y}$): $\bar{Y} = (5 + 12 + 25 + 8) / 4 = 50 / 4 = 12.5$

Se ven correlacionados ($r=0.92$), pero **no están conectados**.

Preguntas para detectar si hay causalidad real

Pregunta	Respuesta
¿Hay mecanismo lógico?	NO. ¿Cómo el helado causa accidente? No hay lógica
¿Comparten otra causa?	Sí. Verano/temperatura explica ambas
¿Pasa sin helados?	Sí. En ciudades sin venta de helados hay accidentes igual
¿Es solo una observación?	Sí. No hay experimento que demuestre causalidad