

Curso: Diseño de Soluciones con Inteligencia Artificial (ISIL, 2026-1)
Docente: Omar David Visitación Romero
Tema: Caso de Negocio de E-commerce: Predicción de Re-compra y Segmentación de Clientes

Una empresa peruana de e-commerce de productos de cuidado personal enfrenta un desafío crítico: a pesar de incrementar inversión en campañas digitales, las ventas no crecen proporcionalmente con las visitas al sitio web. El área de marketing detectó alto abandono de carrito y necesita transformar sus datos en decisiones estratégicas.

PREGUNTA 1: Problemas del Dataset y Acciones de Limpieza, Protección y Preparación

1.1 Diagnóstico de Problemas Identificados

El dataset del caso presenta **múltiples deficiencias de calidad** que impiden su uso directo para análisis o modelado:
A. Problemas Estructurales y de Calidad

Problema	Descripción	Impacto
Registros incompletos	Campos vacíos o valores faltantes	Sesgo en análisis y predicciones
Clientes duplicados	Registros repetidos de la misma persona	Inflación de transacciones y falsa variabilidad
Formatos inconsistentes de fechas	Fechas en diferentes formatos (DD/MM/YYYY, YYYY-MM-DD, etc.)	Imposibilidad de ordenar, agrupar o comparar temporalmente
Distritos mal escritos	Errores de tipografía (“San Isidro”, “San isidro”, “SANISIDRO”)	El sistema los trata como ubicaciones diferentes
Correos electrónicos con errores	Correos duplicados, con espacios o caracteres inválidos	Imposibilidad de contactar o vincular registros

B. Impacto Directo en Soluciones de IA

- **Datos sucios generan predicciones erróneas:** Un modelo entrenado con registros duplicados o mal formateados aprenderá patrones falsos.
- **Pérdida de información:** Registros incompletos sesgan el modelo hacia segmentos específicos.
- **Falta de confiabilidad:** Los resultados no pueden ser confiables para tomar decisiones comerciales.

1.2 Plan de Limpieza y Preparación (Data Wrangling)

Siguiendo el estándar de **Tidy Data** (Wickham, 2014), aplicaremos un flujo estructurado:

Datos Crudos



- [1. Exploración y Diagnóstico]
- [2. Limpieza de Valores Faltantes]
- [3. Detección de Duplicados]
- [4. Normalización y Homogeneización]
- [5. Validación Ética y Legal]



Datos Listos para Análisis

Fase 1: Exploración y Diagnóstico

Acciones:

- 1. **Auditar el dataset completo**
 - Contar valores nulos por columna
 - Identificar patrones de ausencia (MCAR, MAR, MNAR)
 - Registrar dimensiones actuales (filas y columnas)
- 2. **Analizar distribuciones iniciales**
 - Histogramas de variables numéricas (edad, ingresos)
 - Frecuencias de variables categóricas (región, producto)
 - Detectar outliers iniciales

Ejemplo de salida esperada:

Dataset Original:

- Filas: 45,000 registros
- Columnas: 12 atributos
- Datos nulos: 8% de celdas vacías (principalmente en teléfono, ingresos)
- Duplicados potenciales: ~2% de registros repetidos (por correo)

Fase 2: Limpieza de Valores Faltantes

Estrategia según tipo de ausencia:

Variable	Tipo de Ausencia	Estrategia	Justificación
Teléfono	MAR (usuarios que omiten deliberadamente)	Eliminar si es <5% de registros; para segmentos críticos, marcar como “No disponible”	El teléfono no es obligatorio para comprar
Ingresos	MAR (correlación con educación/ocupación)	Imputación por KNN (3-5 vecinos similares en edad, región, historial de compra)	Predecir ingresos basado en comportamiento similar

Variable	Tipo de Ausencia	Estrategia	Justificación
Historial de compras (fechas)	MCAR (errores del sistema)	Forward Fill (propagar último valor conocido) para series temporales	Mantiene continuidad temporal sin sesgar

Fase 3: Detección y Eliminación de Duplicados

Acciones:

1. Identificar duplicados por clave única (correo + teléfono)

```
duplicados = df[df.duplicated(subset=['correo_electronico', 'telefono'], keep=False)]
print(f"Duplicados encontrados: {len(duplicados)}")
```

2. Resolver duplicados:

- Si tienen exactamente los mismos datos → Eliminar copia exacta
- Si tienen datos parcialmente diferentes → Investigar si es realmente el mismo cliente
- Si es mismo cliente con múltiples registros → Mantener registro más reciente, combinar historial

Ejemplo:

Registro 1: juan.perez@gmail.com, Tel: 987654321, Compra: 2026-04-20, Monto: \$150

Registro 2: juan.perez@gmail.com, Tel: 987654321, Compra: 2026-04-15, Monto: \$200

Decisión: Consolidar en un único registro con:

- Cliente: juan.perez@gmail.com
- Historial consolidado: [2026-04-15: \$200, 2026-04-20: \$150]
- Total gastado: \$350

Fase 4: Normalización y Homogeneización

A. Estandarizar Formatos de Texto

Campo	Problema	Solución
Distritos	"San Isidro", "san isidro", "SANISIDRO"	Convertir a mayúsculas + validar contra catálogo oficial INEI
Correos	Espacios en blanco, mayúsculas inconsistentes	.lower() + .strip() + validar formato

Campo	Problema	Solución
Nombres de clientes	Mayúsculas/minúsculas inconsistentes	Title Case (Juan Pérez)

B. Estandarizar Formatos de Fechas

```
# Convertir todas las fechas al formato ISO 8601 (YYYY-MM-DD)
df['fecha_compra'] = pd.to_datetime(df['fecha_compra'], errors='coerce')
```

```
# Detectar fechas inválidas (errores de coerce)
fechas_invalidas = df[df['fecha_compra'].isnull()].shape[0]
print(f"Fechas imposibles de convertir: {fechas_invalidas}")
```

C. Estandarizar Monedas y Valores Numéricos

- Convertir todos los montos a la misma moneda (soles peruanos)
- Establecer rango válido (ej: \$1-\$10,000 es creíble; \$0.01 o \$999,999 requieren revisión)

Fase 5: Validación Ética y Legal

A. Protección de Datos Personales (Ley 31814 Perú)

La ley requiere:

- 1. Anonimización y seudonimización**
 - Asignar IDs numéricos consecutivos en lugar de nombres completos
 - Eliminar información altamente identificable si no es necesaria
 - Ejemplo: guardar “cliente_12345” en lugar de “Juan Pérez, DNI 12345678”
- 2. Consentimiento explícito**
 - Verificar que los clientes autorizaron recopilar sus datos
 - Documentar fuente de datos (navegación web, correo, redes sociales)
- 3. Propósito limitado**
 - Datos recopilados para marketing → no pueden usarse para vigilancia
 - Datos de geolocalización → no pueden venderse a terceros sin consentimiento

B. Detección de Sesgos

- 1. Sesgo geográfico:** ¿Están sobre-representados ciertos distritos?

```
df['distrito'].value_counts(normalize=True)
```

- 2. Sesgo demográfico:** ¿Correlaciona la edad con la intención de compra?

```
df.groupby('edad')['compro_si_no'].mean() # Verificar desbalance
```

- 3. Sesgo temporal:** ¿Cambió el patrón de compra entre campañas?

```
df.groupby(pd.Grouper(key='fecha_compra', freq='M'))['monto'].sum()
```

C. Acciones Preventivas

- Documentar decisiones de limpieza: qué se cambió, por qué, quién autorizó
- Crear dataset “antes” y “después” para auditoría
- Incluir disclaimer: “Dataset procesado para análisis; no representa transacciones reales”

PREGUNTA 2: Tipos de Aprendizaje Automático Recomendados

2.1 Predicción de Re-compra: Aprendizaje SUPERVISADO

¿Por Qué Supervisado?

La empresa busca **predecir un resultado binario conocido**: “¿Este cliente re-comprará o no?”

- **Entrada (Features)**: histórico de compras, clics, canal, horarios, productos consultados, abandono de carrito
- **Salida (Target)**: Sí re-compra, NO re-compra
- Los datos históricos tienen **etiquetas conocidas** (sabemos quiénes re-compraron después de la primera compra)

Algoritmos Recomendados

Algoritmo	Descripción	Ventaja	Limitación
Regresión Logística	Modela probabilidad de evento binario	Interpretable, rápido, bajo riesgo de overfitting	Asume relación lineal
Random Forest	Ensemble de árboles de decisión	Captura relaciones no lineales, robusto a outliers	Caja negra, más difícil de explicar
XGBoost	Gradient boosting optimizado	Alto rendimiento, muy usado en competiciones	Requiere fine-tuning de hiperparámetros

Flujo Conceptual

1. Datos Históricos (2024-2026)
 - Cliente A: Compró 3 veces → Re-compra = Sí
 - Cliente B: Compró 1 vez, 6 meses sin actividad → Re-compra = NO
 - Cliente C: Compró 2 veces → Re-compra = Sí
2. Entrenar Modelo Supervisado
3. Extraer Features Clave:
 - Frecuencia de compra (# compras)
 - Monto promedio por transacción
 - Tiempo desde última compra
 - Abandono de carrito (sí/no)
 - Canal de ingreso (web, email, redes)
4. Generar Predicciones
5. Clientes Nuevos → Modelo predice: "85% probabilidad de re-compra"

Interpretación de Resultados

- El modelo entrega una **probabilidad** (0 a 1):
- **Probabilidad > 0.7** → Alta intención de re-compra → Contactar con oferta personalizada
- **Probabilidad 0.4-0.7** → Intención media → Enviar email educativo
- **Probabilidad < 0.4** → Baja intención → No contactar (evitar fatiga)

2.2 Segmentación de Clientes: Aprendizaje NO SUPERVISADO

¿Por qué No Supervisado?

La empresa necesita **descubrir grupos o patrones ocultos** en el comportamiento de clientes, sin una etiqueta predefinida.

- No sabemos a priori cuántos segmentos existen
- No tenemos etiquetas de "tipo de cliente"
- El objetivo es **agrupar clientes similares** por comportamiento

Algoritmos Recomendados

Algoritmo	Descripción	Uso Ideal
K-Means	Agrupar en K clusters por distancia mínima al centroide	Número de segmentos conocido o estimable
Hierarchical Clustering	Crea árbol de clusters anidados	Exploración: cuántos segmentos naturales hay
DBSCAN	Agrupar por densidad	Detectar outliers y clusters de forma irregular

Flujo Conceptual

Base de Clientes (sin etiquetas previas)

- Cliente 1: Compra frecuente, alto monto, poco abandono
- Cliente 2: Compra ocasional, monto bajo, mucho abandono
- Cliente 3: Compra frecuente, monto bajo, redes sociales
- └ ... (44,997 clientes más)



Aplicar K-Means (K=4)



Descubrir Segmentos Automáticamente:

- **Segmento A (VIP):** 2,000 clientes → Frecuencia alta, monto alto
- **Segmento B (Ocasional):** 15,000 clientes → Compra esporádica, abandono alto
- **Segmento C (Social Buyer):** 18,000 clientes → Llegan por redes, compran bajo ticket
- **Segmento D (En Riesgo):** 10,000 clientes → Compra antigua, sin actividad reciente



Estrategia de Negocio Diferenciada por Segmento

Caracterización de Segmentos

Segmento A (VIP) — 2,000 clientes - Compras: 5+ veces/año - Monto promedio: \$500-\$1,000 - Abandono de carrito: 5% - Acción recomendada: Programa de lealtad, ofertas exclusivas

Segmento B (Ocasional) — 15,000 clientes - Compras: 1-2 veces/año - Monto promedio: \$100-\$200 - Abandono: 40%+ - Acción recomendada: Correo de recordatorio, descuentos en checkout

Segmento C (Social Buyer) — 18,000 clientes - Canal principal: Redes sociales (Instagram, TikTok) - Compras: 2-3 veces/año, productos trending - Monto bajo: \$50-\$100 - Acción recomendada: Influencers, contenido visual, ofertas por tiempo limitado

Segmento D (En Riesgo) — 10,000 clientes - Última compra: hace 6-12 meses - Monto promedio (histórico): \$80-\$150 - Abandono creciente: 60% - Acción recomendada: Win-back campaign, encuesta para entender por qué abandonaron

2.3 Combinación: Supervisado + No Supervisado

Flujo Integrado:

Fase 1: NO SUPERVISADO (Segmentación)

- Crear 4 segmentos (VIP, Ocasional, Social Buyer, En Riesgo)

Fase 2: SUPERVISADO (Predicción por Segmento)

- Para cada segmento, entrenar modelo separado de recompra
- Segmento VIP: Modelo con umbral de 0.6 (menos exigente)
- Segmento En Riesgo: Modelo con umbral de 0.8 (muy exigente)

Resultado: Predicción contextual

"Cliente X pertenece a Ocasional + 72% de re-compra

→ Enviar email con descuento de 20% en próxima compra"

PREGUNTA 3: Por Qué Falló el Modelo y Procedimiento Correcto

3.1 Diagnóstico del Fracaso

El practicante cometió un **error fundamental en validación de modelos**: entrenar con **toda la base disponible sin separación de conjuntos**.

Problema 1: Sin Separación Entrenamiento-Validación-Prueba

Lo que el practicante hizo:

1. Base Completa (45,000 registros)
2. [Entrenar modelo con TODOS los datos]
3. [Evaluar en los MISMOS datos de entrenamiento]
4. Resultado: 95% de precisión (¡parece excelente!)
5. [Aplicar a clientes nuevos]

↓

Falla: Solo 35% de precisión (¡desastre!)

¿Por qué ocurre esto?

- El modelo **memorizó patrones específicos de los 45,000 registros** (overfitting)
- No aprendió **patrones generales** que funcionen con datos nuevos
- Es como memorizar respuestas del examen sin entender el tema

Problema 2: Métricas Infladas por Overfitting

- **Precisión con datos antiguos:** 95%
- **Precisión con clientes nuevos:** 35%
- **Diferencia:** -60 puntos = modelo completamente no confiable

Causa: El modelo generalizó mal porque nunca fue evaluado con datos “desconocidos”.

3.2 Procedimiento Correcto: Split Entrenamiento-Validación-Prueba

Paso 1: Dividir los Datos

Proporción recomendada:

- Dataset Original: 45,000 registros
 - Entrenamiento (60%): 27,000 registros
 - └ Usar SOLO para entrenar pesos del modelo
 - Validación (20%): 9,000 registros
 - └ Usar para ajustar hiperparámetros sin sesgar
 - Prueba (20%): 9,000 registros
 - └ Usar SOLO al final para reportar rendimiento real

Paso 2: Entrenar el Modelo

Usar SOLO conjunto de entrenamiento:

Resultado esperado: 90-95% (es normal que sea alto, son datos conocidos)

Paso 3: Validar y Ajustar Hiperparámetros

Resultado esperado: 75-85% (baja respecto a entrenamiento, pero realista)

Paso 4: Reportar Resultados FINALES con Conjunto de Prueba

Usar SOLO conjunto de prueba al final (una sola vez):

Resultado esperado: 70-80% (estimación real de rendimiento con datos nuevos)

3.3 Métricas de Evaluación Apropriadas

Para Predicción Binaria (Re-compra Sí/No)

Matriz de Confusión:

Predicción		Actual		
Re-compra	No Re-compra			
Actual Re-compra	TP	FN	← Falsos Negativos (costo: perder clientes)	
No Re-compra	FP	TN	← Falsos Positivos (costo: campañas ineficientes)	

TP = Verdaderos Positivos (correctamente predichos re-compra)
TN = Verdaderos Negativos (correctamente predichos no re-compra)
FP = Falsos Positivos (predijimos re-compra, pero no re-compraron)
FN = Falsos Negativos (predijimos no re-compra, pero sí re-compraron)

Métricas Derivadas:

Métrica	Fórmula	Interpretación
Precision	$TP / (TP + FP)$	De los que predijimos “recompra”, ¿cuántos realmente recompraron?
Recall (Sensibilidad)	$TP / (TP + FN)$	De los clientes que realmente recompraron, ¿cuántos identificamos?
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$	Balance entre Precision y Recall
Accuracy	$(TP + TN) / (TP + FP + TN + FN)$	Porcentaje total de predicciones correctas

En nuestro caso de negocio:

- **Recall alto (80%+):** Es crítico NO perder clientes que van a re-comprar
- **Precision (70%+):** Es aceptable contactar algunos clientes que finalmente no re-compren, pero no queremos gastos inútiles

Decisión: Usar **F1-Score** como métrica balanceada.

Validación Cruzada (K-Fold Cross-Validation)

Para mayor robustez, usar validación cruzada:

Divide los datos en 5 partes, entrena 5 veces (cada vez dejando una parte de lado), promedia resultados. Elimina suerte del split inicial.

3.4 Prevención: Checklist de Validación Correcta

- **Datos separados:** 60% entrenamiento, 20% validación, 20% prueba
- **Random seed:** Usar random_state=42 para reproducibilidad
- **Stratification:** Mantener proporciones de clases en cada split
- **Sin data leakage:** Conjuntos totalmente disjuntos, sin solapamiento

- **Métricas múltiples:** No confiar en una sola métrica (Accuracy, Precision, Recall, F1)
- **Monitoreo de overfitting:** Comparar precisión de entrenamiento vs. validación vs. prueba
- **Reporte final:** Usar SOLO conjunto de prueba para resultados finales, UNA SOLA VEZ

PREGUNTA 4: Métricas, Insights y Presentación a Gerencia

4.1 Definición de Métricas de Negocio

Las métricas técnicas de modelo no son suficientes. Necesitamos **traducir a lenguaje de negocio**.A. Métricas Clave de Abandono y Conversión

Métrica	Fórmula	Target Actual	Target Objetivo
Tasa de Conversión	$(\text{Compras} / \text{Visitas}) \times 100$	5%	8% (+60%)
Abandono de Carrito	$(\text{Carritos Abandonados} / \text{Carritos Abiertos}) \times 100$	70%	50% (-20pp)
Tasa de Recompra	$(\text{Clientes que compraron 2+ veces}) / \text{Total clientes}$	35%	50% (+15pp)
Ticket Promedio	Monto promedio por transacción	\$150	\$180 (+20%)
Lifetime Value (LTV)	Ingresos totales por cliente en su vida	\$450	\$600 (+33%)
ROI de Campañas	$(\text{Ingresos} - \text{Costo Campaña}) / \text{Costo Campaña}$	1.2x	2.0x

B. Métricas de Rendimiento del Modelo

Métrica	Valor	Interpretación
Precision (Recompra)	78%	De 100 clientes que predijimos “van a recomprar”, 78 efectivamente recompran
Recall (Recompra)	82%	De 100 clientes que realmente recompraron, nuestro modelo identificó 82

Métrica	Valor	Interpretación
F1-Score	0.80	Balance bueno entre precision y recall
AUC-ROC	0.85	Modelo discrimina bien entre recompra y no recompra

4.2 Insights Accionables

Insight 1: Segmentación Revela Patrones de Re-compra

Dato crudo: - 35% de clientes re-compran

Insight: - El 85% de las recompras proviene de 4 segmentos clave:

- **VIP (5% de clientes):** 95% tasa de recompra
- **Social Buyer (40% de clientes):** 60% tasa de recompra
- **Email Subscriber (30% de clientes):** 45% tasa de recompra
- **En Riesgo (25% de clientes):** 5% tasa de recompra

Recomendación: - Invertir 40% de presupuesto de marketing en VIP (máximo ROI) - Enfocar campañas en Social Buyer (volumen + crecimiento) - Pausar contactos a “En Riesgo” (ROI negativo)

Insight 2: Abandono de Carrito por Canal

Dato crudo: - 70% de abandono global de carrito

Insight por canal: - **Web:** 65% abandono (técnicamente controlable) - **Email:** 55% abandono (mejor diseño genera conversión) - **Redes Sociales:** 80% abandono (fricción de redirección a web)

Recomendación: - **Web:** Simplificar checkout a 2 pasos, ofrecer guest checkout - **Email:** A/B test en línea de asunto; test con urgencia temporal - **Redes Sociales:** Usar shoppable posts (no redirigir, vender en plataforma)

Insight 3: Impacto de Promociones

Dato crudo: - Inversión en campañas aumentó 50%, ventas solo 15%

Insight: - Código de promoción “SUMMER20” (descuento 20%) genera: - ROI: 3.2x (cada \$1 gastado = \$3.2 ingresos) - Ticket promedio: +35% (clientes gastan más cuando hay descuento) - Recompra posterior: +25% (clientes satisfechos vuelven)

- Campaña genérica sin código:
 - ROI: 0.9x (pérdida, aunque atraiga clicks)
 - Razón: conversión baja, sin urgencia, sin seguimiento

Recomendación: - Crear códigos temáticos (NAVIDAD, VERANO, BACK2SCHOOL) - Usar scarcity: "válido por 48 horas" - Implementar retargeting a clientes que abandonaron con código específico

4.3 Presentación a Gerencia: Estructura y Lenguaje

Estructura Recomendada: 4 Secciones

SECCIÓN 1: Situación Actual (El Problema)

Tono: Factual, sin jerga técnica

Contexto Actual:

- Inversión en marketing digital: +50% (2024 a 2026)
- Tráfico web: +48%
- Ventas: +15% ← DESPROPORCIONADO

¿Dónde se pierde dinero?

- 70% de clientes abandona carrito sin comprar
- 65% de clientes nunca re-compra

Costo de inacción:

- 45,000 clientes visitaron web
- 32,000 agregaron productos al carrito
- 10,000 compraron (22% conversión)
- Sólo 3,500 re-compraron (7.7% re-compra)

Oportunidad: El 93% de visitantes no genera ingresos recurrentes

SECCIÓN 2: Solución Propuesta

Tono: Claro, enfocado en beneficios, no en técnica

Enfoque de Tres Pilares:

1. SEGMENTACIÓN INTELIGENTE

Identificar 4 grupos de clientes (VIP, Ocasional, Social, En Riesgo)

Asignar presupuesto según ROI de cada segmento

└ Personalizar mensajes por grupo

2. PREDICCIÓN DE RE-COMPRA

Modelo de IA identifica "100 clientes más propensos a re=comprar"

Contactar con oferta personalizada ANTES de que olviden el producto

└ Aumentar re-compra de 35% a 50%

3. OPTIMIZACIÓN POR CANAL

Web: Simplificar checkout

Email: Urgencia + personalización

└ Redes: Vender sin redirigir

SECCIÓN 3: Resultados Proyectados

Tono: Números concretos, beneficio para el negocio

Escenario Base (Año 1):

- Conversión: 5% → 8% (+60%)
- Re-compra: 35% → 50% (+15pp)
- Ticket promedio: \$150 → \$180 (+20%)
- Ingresos anuales: \$6.75M → \$9.2M (+36%)

Inversión Requerida:

- Implementación de modelo de IA: \$15,000
- Herramientas de personalización: \$5,000/mes
- Recursos (1 Data Scientist + 1 Marketing Analyst): \$8,000/mes
- Total Año 1: \$123,000

ROI:

- Ingresos adicionales: \$9.2M - \$6.75M = \$2.45M
- Costo total: \$123,000
- ROI: $(\$2.45M - \$123K) / \$123K = 1,891\%$ ← EXCELENTE

SECCIÓN 4: Próximos Pasos

Tono: Accionable, con responsables y fechas

Plan de Implementación (3 Meses):

MES 1: PREPARACIÓN

Semana 1-2: Auditar y limpiar 45,000 registros de clientes

Semana 3-4: Entrenar modelo de predicción

Revisor: Data Science Team

MES 2: PILOTO

Segmentar clientes en 4 grupos automáticamente

Ejecutar "mini campaña" a 1,000 clientes VIP

Medir: tasa de apertura, clics, conversión

Revisor: Marketing Manager

MES 3: ESCALA

Aplicar modelo a base completa (45,000 clientes)

Ejecutar campañas personalizadas por segmento

Monitorear daily: conversión, ROI, retorno

Revisor: Gerencia General

Decisión Requerida Hoy:

- ☐ Aprobar presupuesto de \$123,000
- ☐ Asignar 1 Data Scientist + 1 Marketing Analyst
- ☐ Fecha de inicio: [Mes/Año]

4.4 Recomendaciones Finales para Reducir Abandono y Aumentar Ventas

Recomendación 1: Retargeting Dinámico

Problema: Cliente agrega \$200 a carrito, abandona, no regresa.

Solución: - Enviar email a las 2 horas: “Dejaste productos en tu carrito” - Incluir imagen del producto, precio, y botón directo - Ofrecer descuento de 10% si completa en 24h

Impacto esperado: Recuperar 15-20% de carritos abandonados = \$90K/año

Recomendación 2: Programa de Fidelización por Segmento

Para VIP (5% de clientes, 40% de ingresos): - Acceso anticipado a productos nuevos - Envíos gratis siempre - Soporte prioritario - Meta: Recompra de 95% → 99%

Para Social Buyer (40% de clientes, trending items): - Descuentos por volumen (“Compra 3, lleva 1 gratis”) - Sorteos mensuales en Instagram/TikTok - Meta: Recompra de 60% → 75%

Costo: 5% de ingresos VIP = \$180K/año

Beneficio: +4pp recompra = +\$400K ingresos = ROI 2.2x

Recomendación 3: A/B Testing Continuo

Prueba 1: Línea de asunto de email - Grupo A: “20% OFF en productos de cuidado personal” - Grupo B: “María, 20% OFF en lo que viste anteayer” - Medir: tasa de apertura, clics, conversión - Ganador se usa con 100% del base

Prueba 2: Urgencia temporal en web - Grupo A: Mostrar “40% clientes compraron en 48h” - Grupo B: Sin mensaje (control) - Esperar: incremento de conversión de 3-8%

Costo: Mínimo (usar herramientas existentes)

Beneficio: Mejora continua de 1-2% mensual en conversión

Recomendación 4: Integración con CRM

Objetivo: Unificar datos de clientes para personalización.

Datos a integrar: - Compras (qué, cuándo, cuánto) - Navegación (qué consultó, por cuánto tiempo) - Clicks en email (qué asuntos funcionan) - Redes sociales (qué intereses tiene)

Resultado: Crear “perfil único” que alimenta modelo de IA para recomendaciones cada vez más precisas.

4.5 Resumen Visual para Presentación

IMPACTO DEL MODELO DE IA

Métrica	Hoy	En 6 Meses	Cambio
Conversión	5%	8%	60%
Re-compra	35%	50%	+15pp
Abandono Carrito	70%	50%	-20pp
ngresos Mensuales	\$562K	\$767K	36%
Clientes Activos	10.000	15.000	50%

Inversión Requerida: \$123,000 (Año 1)
ROI: 1,891% ← Cada peso invertido genera \$18.91 de retorno

CONCLUSIÓN

La empresa tiene una **oportunidad clara** para transformar su base de datos en decisiones estratégicas. Con un enfoque estructurado en:

- 1. **Limpieza de datos** (eliminación de duplicados, normalización, protección ética)
- 2. **Machine Learning supervisado** (predicción de re-compra)
- 3. **Segmentación no supervisada** (agrupar clientes por comportamiento)
- 4. **Validación rigurosa** (split entrenamiento-validación-prueba)
- 5. **Comunicación clara** (insights accionables en lenguaje de negocio)

La empresa puede esperar: - **Incremento de 36% en ingresos** en 6 meses - **ROI de 1,891%** en el año 1 - **Base de clientes 50% más activa** y rentable

La clave: **Datos limpios + Modelo correcto + Ejecución disciplinada = Valor real de negocio**