

SOLUCIÓN ACTIVIDAD 4 — DISEÑO DE SOLUCIONES CON IA

Curso: Diseño de Soluciones con Inteligencia Artificial (ISIL, 2026-1)

Docente: Omar David Visitación Romero

Caso: SaludPlus Digital — Modelado y Evaluación de Soluciones de IA

Alumno: Carlos Gil Carrillo

Contexto del Caso

SaludPlus Digital administra una plataforma usada por clínicas, laboratorios y pacientes para registrar citas, resultados médicos y pagos. La empresa enfrenta tres problemas críticos:

- 1. **Pacientes que no asisten a sus citas** → pérdida de tiempo médico, espacios vacíos.
- 2. **Tiempos de espera impredecibles** → de 15 a 90 minutos sin explicación.
- 3. **Necesidad de segmentar pacientes** → campañas comerciales poco efectivas.

El equipo de datos tiene registros históricos con variables numéricas, categóricas y textos libres, pero con valores faltantes, categorías repetidas y registros extremos. Además, un modelo complejo probado recientemente funcionó bien con datos antiguos pero falló con nuevos (overfitting). Existe debate interno entre maximizar la precisión global versus otras métricas, y entre modelos interpretables versus de alto rendimiento.

PREGUNTA 1: Tipos de Problemas de Aprendizaje Automático y Criterios de Selección

1.1 Identificación de los Tres Problemas de ML(Machine Learning)

SaludPlus Digital presenta **tres tipos distintos de aprendizaje automático**, cada uno con un objetivo diferente:

Problema	Tipo de ML	Target (salida)	Datos de entrada (features)	Ejemplo concreto
Predecir inasistencia	Supervisado — Clasificación	Sí/No (binario)	Edad, especialidad, seguro, sede, historial de citas	“Paciente A tiene 78% de probabilidad de no asistir”
Estimar tiempo de espera	Supervisado — Regresión	Valor numérico continuo (minutos)	Hora del día, sede, médico asignado, pacientes en cola, tipo de seguro	“En Sede Surco a las 10am, el tiempo estimado es 35 minutos”
Segmentar pacientes	No supervisado — Clustering	Grupos sin etiqueta previa	Frecuencia de visitas, monto pagado, servicios consumidos, patrones de cita	“Grupo 1: pacientes frecuentes con seguro premium”

1.2 Problema 1: Predicción de Inasistencia (Clasificación Supervisada)

¿Por qué es clasificación supervisada?

- El target es **binario**: el paciente asiste (SÍ) o no asiste (NO).
- Tenemos **etiquetas históricas**: sabemos de registros pasados quiénes faltaron y quiénes asistieron.
- El modelo aprende de ejemplos conocidos para predecir casos nuevos.

Variables relevantes

Tipo	Variables	Ejemplo
Numéricas	Edad, días desde última cita, número de citas anteriores	Edad=45, Citas previas=3
Categóricas	Especialidad, tipo de seguro, sede	Cardiología, SIS, Surco
Derivadas	Tasa de inasistencia histórica, distancia a la sede, hora de la cita	40% inasistencias previas

Algoritmos candidatos

Algoritmo	Ventaja principal	Limitación principal	Cuándo usarlo
Regresión Logística	Interpretable, probabilidades calibradas	Asume relación lineal	Cuando el equipo médico exige explicabilidad
Random Forest	Captura interacciones complejas, robusto a outliers	Menos interpretable	Balance entre rendimiento y explicabilidad
XGBoost	Alto rendimiento, maneja datos desbalanceados	Requiere tuning, más lento	Cuando la prioridad es maximizar F1-Score
Árbol de Decisión	Fácil de explicar visualmente	Inestable, propenso a overfitting	Cuando se necesita un diagrama de decisión para el personal

Criterio de selección recomendado

Dado que **el área médica exige explicabilidad** y **el área comercial quiere resultados**, la recomendación es:

Opción principal: Random Forest

- Balance entre rendimiento y capacidad de explicar decisiones
- Permite calcular "feature importance" (qué variables más influyen)

Opción complementaria: Regresión Logística

- Para reportes médicos donde se necesita transparencia total
- Coeficientes directamente interpretables

El dilema de la inasistencia excesiva

El caso menciona que “si el sistema marca demasiados pacientes como ‘posible inasistencia’, el personal termina llamando innecesariamente”. Esto es un problema de Precision vs Recall:

Métrica	Significado	Consecuencia de optimizarla
Recall alto	Detectamos casi todos los que van a faltar	Pero llamamos a muchos que Sí iban a asistir (falsos positivos)
Precision alta	Cuando decimos “va a faltar”, casi siempre acertamos	Pero dejamos de detectar algunos que sí faltan (falsos negativos)

Decisión: Optimizar **F1-Score** (balance entre ambas) o usar un **umbral de probabilidad ajustable**

1.3 Problema 2: Estimación de Tiempo de Espera (Regresión Supervisada)

¿Por qué es regresión supervisada?

- El target es un **valor continuo**: número de minutos de espera.
- Tenemos **historiales con tiempos reales** registrados.
- El modelo aprenderá a estimar el tiempo para futuras citas.

Variables relevantes

Tipo	Variables	Impacto esperado
Temporales	Hora del día, día de la semana, mes	Horas pico = más espera
Operativas	Sede, médico, pacientes en cola, tipo de consulta	Médico popular = más cola
Del paciente	Tipo de seguro, especialidad, edad	Seguros públicos = más trámite

Algoritmos candidatos

Algoritmo	Ventaja	Limitación	Cuándo usarlo
Regresión Lineal	Interpretable, rápido	No captura relaciones no lineales	Primera aproximación, baseline
Random Forest Regressor	Captura interacciones, robusto	Menos interpretable	Datos con patrones complejos
Gradient Boosting (XGBoost Regressor)	Alto rendimiento	Requiere más datos y tuning	Cuando se necesita precisión máxima
Neural Network	Patrones muy complejos	Caja negra, requiere muchos datos	Solo si hay >10,000 registros limpios

Criterio de selección recomendado

Opción principal: Random Forest Regressor

- Maneja bien combinaciones de variables categóricas y numéricas
- Robusto a los outliers (pacientes con espera de 120+ min)
- Permite identificar qué factores más influyen en la espera

Baseline obligatorio: Regresión Lineal

- Para comparar y demostrar si un modelo complejo realmente aporta valor

Métrica de evaluación

Métrica	Fórmula	Interpretación
MAE (Mean Absolute Error)	Promedio de $ \text{predicho} - \text{real} $	"El modelo se equivoca en promedio X minutos"
RMSE (Root Mean Squared Error)	Raíz del error cuadrático promedio	Penaliza más los errores grandes
R²	Proporción de varianza explicada	1.0 = perfecto, 0.0 = no explica nada

Ejemplo de interpretación:

MAE = 12 minutos

- En promedio, la estimación se equivoca 12 minutos
- Si el modelo dice "espera 30 min", el real puede ser 18-42 min
- Útil para reorganizar turnos con margen de tolerancia

1.4 Problema 3: Segmentación de Pacientes (Clustering No Supervisado)

¿Por qué es clustering no supervisado?

- **No hay etiquetas previas:** no sabemos cuántos grupos ni qué tipo de pacientes existen.
- El objetivo es **descubrir patrones ocultos** en el comportamiento.
- El área comercial espera “descubrir segmentos útiles para futuras campañas”.

Variables relevantes

Tipo	Variables	Lo que captura
Frecuencia	Número de citas por año, periodicidad	Pacientes regulares vs esporádicos
Consumo	Monto pagado, servicios utilizados, tipo de seguro	Valor económico del paciente
Temporalidad	Días desde última cita, horarios preferidos	Actividad reciente y preferencias
Texto libre	Comentarios de encuestas	Satisfacción, quejas, sugerencias (requiere NLP)

Algoritmos candidatos

Algoritmo	Ventaja	Limitación	Cuándo usarlo
K-Means	Rápido, escalable, fácil de interpretar	Requiere definir K previamente	Cuando se puede estimar número de grupos
DBSCAN	Detecta outliers y clusters de forma irregular	Sensible a parámetros de densidad	Cuando los grupos no son esféricos
Hierarchical Clustering	Muestra árbol de relaciones (dendrograma)	Lento con muchos datos	Para exploración inicial
K-Means con Silhouette Score	Evalúa calidad del clustering automáticamente	Solo sugiere K, no resuelve todo	Para validar número óptimo de grupos

Criterio de selección recomendado

- Opción principal: K-Means con Silhouette Analysis
- Rápido para miles de registros
 - El dendrograma de Hierarchical puede sugerir K inicial
 - Silhouette Score valida si los grupos son coherentes

Procesamiento del texto libre:

- Aplicar NLP (TF-IDF + Sentiment Analysis) antes del clustering
- Extraer sentimiento como variable numérica adicional

Hallazgo esperado (ejemplo)

Cluster 1: "Pacientes Frecuentes Premium" (15%)
→ Seguro privado, citas cada 3 meses, alto consumo
→ Acción: Programa de lealtad, prioridad en citas

Cluster 2: "Pacientes Esporádicos" (35%)
→ Seguro público, 1-2 citas al año, bajo consumo
→ Acción: Campañas de prevención, recordatorios

Cluster 3: "Pacientes en Riesgo de Abandono" (25%)
→ Sin cita en los últimos 6 meses, quejas frecuentes
→ Acción: Llamada de seguimiento, encuesta de satisfacción

Cluster 4: "Pacientes de Urgencia" (25%)
→ Solo aparecen en emergencias, sin cita regular
→ Acción: Derivación a atención primaria, educación preventiva

1.5 Criterios Generales de Selección de Modelos

Más allá del tipo de problema, la selección debe considerar **tres ejes**:

Criterio	Preguntas clave	Impacto en SaludPlus
Naturaleza del problema	¿El target es categórico, continuo o no tiene etiqueta?	Define si es clasificación, regresión o clustering
Calidad y cantidad de datos	¿Cuántos registros hay? ¿Están limpios? ¿Hay etiquetas?	Con pocos datos, modelos simples superan a complejos
Requisitos del negocio	¿Se necesita explicabilidad? ¿Qué tan rápido debe responder?	El área médica pide interpretabilidad; la comercial pide rendimiento

Matriz de decisión final

Modelo	Clasificación (Inasistencia)	Regresión (Tiempo Espera)	Clustering (Segmentación)
Regresión Logística / Lineal	✓ Primera opción si importa explicar	✓ Baseline obligatorio	✗ No aplica
Random Forest	✓ Mejor balance rendimiento/ explicabilidad	✓ Opción principal	✗ No aplica
XGBoost	✓ Si hay suficientes datos (>5000)	✓ Si se necesita precisión máxima	✗ No aplica
K-Means	✗ No aplica	✗ No aplica	✓ Opción principal
DBSCAN	✗ No aplica	✗ No aplica	✓ Si hay outliers importantes

PREGUNTA 2: Evaluación del Desempeño antes de Implementar

2.1 El Problema del Caso: Overfitting

El caso describe que “el equipo técnico probó un modelo muy complejo que obtuvo buenos resultados en los datos antiguos. Sin embargo, cuando se aplicó a nuevos registros, el rendimiento bajó”.

Diagnóstico: Overfitting — el modelo memorizó los datos de entrenamiento en lugar de aprender patrones generales.

¿Qué pasó?

Datos antiguos (entrenamiento):	Precisión = 92%
Datos nuevos (prueba):	Precisión = 58%
Diferencia:	-34 puntos → OVERFITTING GRAVE

Causa probable: El modelo es demasiado complejo para la cantidad de datos, o fue evaluado en los mismos datos con los que se entrenó.

2.2 Procedimiento Correcto de Evaluación

Paso 1: Separar los datos correctamente

Nunca evaluar el modelo con los mismos datos usados para entrenar.

Dataset Original (registros históricos)

- Entrenamiento (60%): El modelo aprende aquí
 - └ Patrones, pesos, decisiones
- Validación (20%): Se ajustan hiperparámetros
 - └ Número de árboles, profundidad, umbral
- Prueba (20%): Evaluación FINAL
 - └ Se toca UNA SOLA VEZ al final

Código conceptual:

```
from sklearn.model_selection import train_test_split

# Separar prueba (20%) ANTES de cualquier cosa
X_temp, X_test, y_temp, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Separar entrenamiento (60%) y validación (20%)
X_train, X_val, y_train, y_val = train_test_split(
    X_temp, y_temp, test_size=0.25, random_state=42, stratify=y_temp
)

print(f"Entrenamiento: {X_train.shape[0]} registros")
print(f"Validación: {X_val.shape[0]} registros")
print(f"Prueba: {X_test.shape[0]} registros")
```

Paso 2: Métricas de evaluación por tipo de problema

A. Para Clasificación (Inasistencia Sí/No)

Matriz de Confusión:

Real \ Predicción

Asiste

No Asiste

Asiste (N)

TN (Verdadero Negativo)

FN (Falso Negativo)

No Asiste (S)

FP (Falso Positivo)

TP (Verdadero Positivo)

Interpretación

- **TN (Verdadero Negativo):** El paciente asistió y el modelo predijo que asistiría.
- **FP (Falso Positivo):** El paciente asistió, pero el modelo predijo que no asistiría. Se realiza una intervención o llamada innecesaria.
- **FN (Falso Negativo):** El paciente no asistió, pero el modelo predijo que sí asistiría. No se detecta la inasistencia.
- **TP (Verdadero Positivo):** El paciente no asistió y el modelo predijo correctamente que no asistiría.

Métricas derivadas:

Métrica	Fórmula	Qué mide	En SaludPlus
Accuracy	$(TP+TN)/(Total)$	% total de aciertos	 Engañosa si hay pocos inasistentes
Precision	$TP/(TP+FP)$	De los que marcamos como "faltan", ¿cuántos realmente faltaron?	Mide cuántas llamadas innecesarias hacemos
Recall	$TP/(TP+FN)$	De los que realmente faltaron, ¿cuántos detectamos?	Mide cuántos inasistentes se nos escapan
F1-Score	$2 \times (P \times R) / (P + R)$	Balance entre Precision y Recall	 Métrica principal recomendada

¿Por qué NO usar solo Accuracy?

Supongamos: 100 pacientes, 90 asisten, 10 faltan

Modelo malo: Predice "asiste" para TODOS

→ Accuracy = $90/100 = 90\%$ ← ¡Parece bueno pero no detecta NINGUNA inasistencia!

Modelo útil: Detecta 8 de 10 faltas

→ Accuracy = 82% ← Parece peor pero SÍ resuelve el problema

Aunque la exactitud es menor (**82 %**), este modelo resulta **más útil desde el punto de vista del negocio**, ya que identifica la mayoría de los pacientes que no asistirán a su cita, permitiendo realizar acciones preventivas como recordatorios o reprogramaciones.

¿Qué métricas son más adecuadas?

En problemas de predicción de inasistencias, es recomendable complementar la Accuracy con métricas que evalúen el desempeño sobre la clase minoritaria:

- **Precisión (Precision):** Indica qué porcentaje de las predicciones de "No Asiste" fueron correctas.
- **Recall (Sensibilidad):** Mide qué porcentaje de las inasistencias reales fueron detectadas por el modelo.

- **F1-Score:** Combina precisión y recall en una única métrica, siendo especialmente útil cuando las clases están desbalanceadas.
- **AUC-ROC:** Evalúa la capacidad del modelo para distinguir entre pacientes que asistirán y los que no asistirán, independientemente del umbral de clasificación.

Conclusión

En este estudio, **la Accuracy no se utiliza como única métrica de evaluación**, debido al desbalance existente entre las clases de asistencia e inasistencia. En su lugar, se priorizan métricas como el **F1-Score** y el **AUC-ROC**, ya que proporcionan una evaluación más representativa de la capacidad del modelo para detectar inasistencias, que constituye el objetivo principal del problema.

Métrica recomendada: F1-Score o **AUC-ROC** (mide la capacidad de discriminar entre asistencia y inasistencia).

B. Para Regresión (Tiempo de Espera)

Métrica	Fórmula	Interpretación
MAE	$(1/n) \times \sum \hat{y} - y $	Error promedio en minutos
RMSE	$\sqrt{(1/n) \times \sum (\hat{y} - y)^2}$	Penaliza errores grandes (una espera de 90 min estimada en 20 min es grave)
R²	$1 - (SS_{\text{res}} / SS_{\text{tot}})$	% de varianza explicada por el modelo

Criterio de aceptación:

MAE < 15 minutos → Aceptable para reorganizar turnos
MAE < 10 minutos → Excelente
MAE > 20 minutos → Insuficiente, necesita mejorar

C. Para Clustering (Segmentación)

Métrica	Qué mide	Rango
Silhouette Score	Qué tan similar es un paciente a su propio cluster vs. otros clusters	-1 a 1 (mayor = mejor)
Davies-Bouldin Index	Separación entre clusters	Menor = mejor
Inercia (K-Means)	Compacidad de los clusters	Menor = mejor (pero disminuye con más K)

Regla práctica:

Silhouette > 0.5 → Clusters bien definidos
Silhouette 0.25-0.5 → Clusters aceptables, revisar
Silhouette < 0.25 → Clusters débiles, reconsiderar K o variables

Paso 3: Validación Cruzada (K-Fold)

Para mayor confiabilidad, usar validación cruzada en lugar de un solo split:

```
from sklearn.model_selection import cross_val_score
from sklearn.ensemble import RandomForestClassifier
```

```
modelo = RandomForestClassifier(n_estimators=100, random_state=42)
```

```
# Validación cruzada de 5 pliegues
```

```
scores_f1 = cross_val_score(modelo, X_train, y_train, cv=5, scoring='f1')
scores_auc = cross_val_score(modelo, X_train, y_train, cv=5, scoring='roc_auc')
```

```
print(f"F1-Score promedio: {scores_f1.mean():.3f} (+/- {scores_f1.std():.3f})")
print(f"AUC-ROC promedio: {scores_auc.mean():.3f} (+/- {scores_auc.std():.3f})")
```

¿Por qué? Porque un solo split puede ser “afortunado” o “desafortunado”. Con 5 folds, entrenas y evalúas 5 veces con diferentes porciones, y promedias.

Paso 4: Validación con Datos Temporales (Time Series Split)

SaludPlus tiene registros históricos con componente temporal. El split aleatorio puede causar **data leakage** (usar datos del futuro para predecir el pasado).

```
from sklearn.model_selection import TimeSeriesSplit
```

```
# Para datos ordenados cronológicamente
```

```
tscv = TimeSeriesSplit(n_splits=5)
```

```
for train_idx, test_idx in tscv.split(X):
    X_train_cv, X_test_cv = X.iloc[train_idx], X.iloc[test_idx]
    y_train_cv, y_test_cv = y.iloc[train_idx], y.iloc[test_idx]
# Entrenar y evaluar
```

Regla: Si los datos tienen fecha, NUNCA hacer split aleatorio. Usar siempre TimeSeriesSplit.

2.3 El Debate: Accuracy Global vs. Otras Métricas

El caso menciona que “algunos directivos piden usar siempre el modelo con mayor porcentaje global de aciertos”. Esto es problemático:

Por qué Accuracy global no es suficiente

Situación	Accuracy del modelo	Problema oculto
95% de pacientes asisten, 5% faltan	Modelo que predice “todos asisten” = 95% accuracy	No detecta NINGUNA inasistencia
10% de pacientes son de alto riesgo	Modelo que identifica solo casos “fáciles” = 92% accuracy	Los casos críticos se escapan

La solución: Métricas por clase y análisis de errores

```
from sklearn.metrics import classification_report
```

Reporte detallado por clase

```
print(classification_report(y_test, y_pred,
                           target_names=['Asiste', 'No Asiste']))
```

Salida esperada:

Clase	Precisión (Precision)	Exhaustividad (Recall)	F1-Score	Soporte (Support)
Asiste	0.94	0.97	0.95	180
No Asiste	0.82	0.68	0.74	25
Accuracy	-	-	0.93	205
Promedio Macro (Macro Avg)	0.88	0.82	0.85	205
Promedio Ponderado (Weighted Avg)	0.93	0.93	0.92	205

Interpretación: - Accuracy global = 93% (parece excelente) - Pero Recall para “No Asiste” = 68% → se escapan 32% de inasistentes - F1 para “No Asiste” = 0.74 → aceptable pero mejorable

2.4 Criterios de Aceptación según Área

El caso menciona que cada área tiene necesidades distintas. La evaluación debe incluir **criterios por stakeholder**:

Área	Criterio principal	Métrica clave	Umbral mínimo
Médica	Explicabilidad	Coeficientes de Regresión Logística o Feature Importance de RF	Cada predicción debe poder justificarse con variables concretas

Área	Criterio principal	Métrica clave	Umbral mínimo
Comercial	Rendimiento en campañas masivas	F1-Score, AUC-ROC	F1 > 0.75, AUC > 0.80
Sistemas	Tiempo de respuesta	Latencia de predicción	< 200ms por predicción
Gerencia	Impacto de negocio	Reducción de inasistencias, ROI	Reducir inasistencias ≥ 20%

Framework de decisión multi-criterio

Evaluación Final = $w_1 \times \text{Explicabilidad} + w_2 \times \text{Rendimiento} + w_3 \times \text{Velocidad} + w_4 \times \text{ROI}$

Donde:

- $w_1 = 0.30$ (Médica exige explicabilidad)
- $w_2 = 0.30$ (Comercial quiere resultados)
- $w_3 = 0.15$ (Sistemas requiere velocidad)
- $w_4 = 0.25$ (Gerencia mide negocio)

2.5 Estrategia de Evaluación Recomendada para SaludPlus

Flujo completo de evaluación

EVALUACIÓN DE MODELOS

Evaluación de Modelos

1. Preparación de los datos

- Limpiar los valores faltantes mediante técnicas como:
 - K-Nearest Neighbors (KNN)
 - Media o mediana
- Codificar las variables categóricas utilizando **One-Hot Encoding**.
- Estandarizar las variables numéricas mediante:
 - Normalización Min-Max.
 - Estandarización Z-Score.
- Dividir el conjunto de datos en:
 - **60 %** para entrenamiento (Training).
 - **20 %** para validación (Validation).
 - **20 %** para pruebas (Testing).

2. Modelos candidatos

Modelos de clasificación

- Regresión Logística (Logistic Regression)
- Random Forest
- XGBoost

Modelos de regresión

- Regresión Lineal
- Random Forest Regressor
- XGBoost Regressor

Modelos de agrupamiento (Clustering)

- K-Means (K = 3, 4 y 5)
- DBSCAN

3. Evaluación en el conjunto de validación

- Aplicar **validación cruzada (Cross-Validation)** de **5 folds**.
- Evaluar el desempeño mediante métricas por clase, evitando depender únicamente de la exactitud (Accuracy).
- Analizar indicadores como:
 - Matriz de confusión.
 - Precisión (Precision).
 - Recall.
 - F1-Score.
 - Área bajo la curva ROC (AUC-ROC).
 - Error absoluto medio (MAE), cuando corresponda.

4. Evaluación en el conjunto de prueba

- Ejecutar la evaluación **una sola vez** sobre datos nunca vistos.
- Reportar la métrica final del modelo.
- Analizar los falsos positivos y falsos negativos.
- Evaluar el costo asociado a cada tipo de error.

5. Validación desde la perspectiva del negocio

Verificar que el modelo cumpla con los siguientes criterios:

- Reducir las inasistencias en al menos un **20 %**.
- Tiempo de respuesta inferior a **200 ms**.
- Que el personal médico pueda interpretar o explicar la predicción del modelo.
- Que el retorno de inversión (ROI) justifique la implementación.

6. Decisión final

Resultado Acción

Aprobado Implementar un piloto en producción.

Rechazado Ajustar hiperparámetros o recopilar más datos.

En revisión Cambiar el enfoque de modelado o seleccionar otro algoritmo.

2.6 Tabla Resumen: Qué Evaluar antes de Implementar

Aspecto a evaluar	Qué verificar	Herramienta	Criterio de aceptación
Overfitting	¿Accuracy de train >> test?	Comparar métricas train/val/test	Diferencia < 10 puntos
Generalización	¿Funciona con datos nuevos?	Validación cruzada (5-fold)	F1 promedio estable (std < 0.05)
Sesgo de clases	¿El modelo ignora la clase minoritaria?	Classification report por clase	Recall clase minoritaria > 60%
Velocidad	¿Responde a tiempo?	Benchmark de latencia	< 200ms por predicción
Explicabilidad	¿Se puede justificar cada predicción?	Feature importance, SHAP values	Cada variable tiene interpretabilidad clara
Robustez temporal	¿Funciona con datos de distintos meses?	Time Series Split	Performance estable en todos los folds temporales
Impacto de negocio	¿Resuelve el problema real?	A/B test piloto	Reducción de inasistencias ≥ 20% en 30 días

CONCLUSIÓN

SaludPlus Digital necesita **tres soluciones de ML distintas**, cada una con su tipo de problema y criterios de evaluación:

- 1. **Clasificación (inasistencia):** Random Forest con F1-Score como métrica principal, umbral ajustable según capacidad del personal, y explicabilidad garantizada con Feature Importance.
- 2. **Regresión (tiempo de espera):** Random Forest Regressor con MAE como métrica clave, baseline con Regresión Lineal para demostrar valor agregado del modelo complejo.
- 3. **Clustering (segmentación):** K-Means con Silhouette Score para validar calidad de grupos, texto libre procesado con NLP antes del clustering.

La evaluación debe ir más allá del accuracy global. Los directivos que piden “el modelo con más aciertos” están cayendo en una trampa estadística. La métrica correcta depende del problema de negocio: F1-Score para clasificación, MAE para regresión, Silhouette para clustering.

Antes de implementar: split correcto (60/20/20), validación cruzada, métricas por clase, análisis de costo de error, y un piloto controlado de al menos 30 días con medición de impacto real.

Machine Learning y Evaluación de Modelos

#	Fuente	Tipo	URL
1	Scikit-learn Documentation. <i>Model Evaluation</i>	Oficial	https://scikit-learn.org/stable/model_evaluation.html
2	Brownlee, J. (2018). <i>How to Configure the k-Fold Cross-Validation Procedure</i>	Académica	https://machinelearningmastery.com/k-fold-cross-validation/
3	Provost, F. & Fawcett, T. (2013). <i>Data Science for Business</i>	Académica	O'Reilly Media

Calidad de Datos y Preprocesamiento

#	Fuente	Tipo	URL
4	Wickham, H. (2014). <i>Tidy Data</i>	Académica	https://vita.had.co.nz/papers/tidy-data.html
5	Scikit-learn Documentation. <i>Imputation of Missing Values</i>	Oficial	https://scikit-learn.org/stable/modules/impute.html

Overfitting y Regularización

#	Fuente	Tipo	URL
6	Goodfellow, I. et al. (2016). <i>Deep Learning</i>	Académica	MIT Press
7	Hastie, T. et al. (2009). <i>The Elements of Statistical Learning</i>	Académica	Springer