

+ TEMA 02

IDEACIÓN

- Valor para el negocio
- Características de un problema adecuado para IA (tipos, limitaciones y riesgos)
- Técnicas para entender y formular problemas
- Taller de ideación de problemas (design thinking)





+ INTRODUCCIÓN **DE LA SESIÓN**

- + No todos los problemas pueden ni deben resolverse con inteligencia artificial.
- + El éxito de una solución IA depende en gran medida de cómo se formula el problema.
- + Una buena ideación permite alinear necesidades del usuario, objetivos del negocio y viabilidad técnica.
- + En esta sesión, aprenderemos a identificar y estructurar problemas adecuados para IA.



+

VALOR PARA
EL NEGOCIO

FORMULAR PROBLEMAS: DEL NEGOCIO A LA SOLUCIÓN DE IA

¿Cómo identificar oportunidades y evaluar su viabilidad?



No todo problema empresarial es un problema para IA. Pero, cuando lo es, puede generar valor exponencial.

VALOR ESTRATÉGICO DE LA IA EN ORGANIZACIONES

IA GENERATIVA



- Automatiza tareas creativas.
- Mejora decisiones.
- Eleva la experiencia del cliente

SECTORES CLAVE



- Marketing.
- Comunicación.
- Finanzas.
- Salud.
- Educación.
- Customer service.

ROI POTENTIAL



- Reducción de costos.
- Mejora de eficiencia.
- Generación de nuevas líneas de negocio.



Ejemplo: ChatGPT ha reducido tiempos de redacción de reportes financieros de horas a minutos.

¿CÓMO CREA VALOR LA IA EN LA EMPRESA?



GENERACIÓN DE CONTENIDO

- Herramientas como Jasper.ai, DALL·E y Midjourney generan textos publicitarios, imágenes y artículos en segundos.
- Impacto: optimización de recursos, presencia comunicativa constante, experimentación rápida.



SOPORTE DE DECISIONES

- Análisis automatizado de datos, reportes generativos, predicciones de demanda.
- Impacto: toma de decisiones más rápida y menos sesgada, democratización del acceso a datos.



EXPERIENCIA DEL CLIENTE

- Chatbots inteligentes, personalización, recomendaciones contextuales.
- Impacto: satisfacción, retención, ingresos recurrentes.

¿QUÉ PROYECTO DE IA ELEGIR PRIMERO?

Criterio de priorización

+ IMPACTO

¿Cuánto valor económico o eficiencia puede generar?

+ VIABILIDAD

¿Tenemos datos, recursos y tiempo suficientes?

+ RIESGO

¿Hay requisitos de confianza absoluta o salidas complejas?



Matriz de decisión: priorizar proyectos de alto impacto + viabilidad moderada + bajo riesgo.

¿Cuál es el problema en tu organización que satisface estos criterios?

+


CARACTERÍSTICAS DE UN PROBLEMA
**ADECUADO PARA IA (TIPOS,
LIMITACIONES Y RIESGOS)**

¿QUÉ TIPO DE PROBLEMA ES EL TUYO?

- 01** **MEJORA DE PROCESO EXISTENTE**
Optimizar rutas, mejorar ranking de recomendaciones, aumentar precisión de diagnósticos.
- 02** **COMPLETAR TRABAJO MANUAL**
Autocompletado de texto, análisis de sentimientos, diseño asistido.
- 03** **AUTOMATIZAR PROCESO MANUAL**
Clasificación de documentos, detección de fraude, atención automática a clientes.



Concepto clave: el data flywheel en cada ciclo genera más datos, lo que mejora iterativamente el modelo.



RIESGOS E IMPLICACIONES ÉTICAS DE UN PROYECTO DE IA

Sesgo algorítmico	Privacidad de datos	Interpretabilidad	Escalabilidad computacional	Mantenimiento en producción
El modelo hereda prejuicios del conjunto de entrenamiento.	Riesgo de exposición de datos personales o sensibles. Soluciones: federated learning, differential privacy.	Modelos complejos como deep learning son "cajas negras"; no se sabe por qué predicen qué. Solución: XAI (Explainable AI).	Entrenar modelos grandes requiere GPU/TPU costosas.	Los datos cambian, el modelo se degrada. Requiere monitoreo continuo.

DIFERENTES TIPOS DE IA, DIFERENTES LIMITACIONES

NARROW AI (IA ESTRECHA)

- Resuelve una tarea específica (chatbot, clasificador de imágenes).
- Limitación: no generaliza fuera de su dominio.

IA GENERATIVA

- Crea contenido nuevo (texto, imágenes).
- Limitación: puede generar contenido falso o sesgado ("alucinaciones").

MACHINE LEARNING

- Aprende patrones de datos etiquetados.
- Limitación: requiere muchos datos y ajuste fino de hiperparámetros.

DEEP LEARNING

- Redes neuronales profundas para tareas complejas.
- Limitación: alto costo computacional, falta de interpretabilidad.

+

TÉCNICAS PARA ENTENDER Y
FORMULAR PROBLEMAS

DESARROLLO DEL PLAN DE INVESTIGACIÓN

1

PLANTEAMIENTO DEL PROBLEMA

Definir objetivo, métricas, línea base.

2

RECOLECCIÓN Y ETIQUETADO DE DATOS

Reunir datos representativos y etiquetarlos correctamente.

3

ANÁLISIS EXPLORATORIO Y PROCESADO

Limpiar datos, tratar valores nulos, balancear clases.

4

EXTRACCIÓN DE CARACTERÍSTICAS

Vectorización de texto, selección de variables importantes.

DESARROLLO DEL PLAN DE INVESTIGACIÓN

5

MODELADO Y ENTRENAMIENTO
Elegir algoritmo, ajustar hiperparámetros (GridSearch).

6

EVALUACIÓN
Medir con métricas, comparar con línea base.

7

PUESTA DE PRODUCCIÓN
Integrar el modelo en sistema real.

8

MANTENIMIENTO Y MONITOREO
Detectar degradación, reentrenar según sea necesario.



¿QUÉ PROBLEMA VAMOS A RESOLVER?

- 01  Definir el problema con claridad: "Clasificar automáticamente incidencias de soporte técnico en 4 categorías" (no poner: "Mejorar el servicio").
- 02  Entender los datos: ¿qué variables tenemos?, ¿cuán complejos son?, ¿hay sesgos evidentes?
- 03  Establecer objetivos SMART: reducir tiempo de resolución de tickets en un 50%, mejorar satisfacción a 90%.
- 04  Definir línea base: si un empleado clasifica tickets manualmente con 85% de acierto, el modelo debe superarlo.
- 05  Preguntas clave: "¿Qué pasa si el modelo falla? ¿Cuál es el costo del error?".

RECOLECCIÓN Y ETIQUETADO DE DATOS

Se agrupan datos representativos y se marcan con reglas claras para que el modelo aprenda.


FLUJO

Fuentes → Muestreo → Guía de etiquetas → Etiquetado → QA → Dataset


RIESGO	CONTROL RÁPIDO
No representativo.	Muestreo por segmentos, casos raros.
Etiquetas inconsistentes.	Guidelines + ejemplos + revisión.
Data leakage.	Split train, val, test de inicio.

¿Qué se obtiene? Dataset, guía de etiquetado, reporte de calidad.

ESTABLECER LA LÍNEA BASE: TU PUNTO DE REFERENCIA

Línea base interna	Línea base externa	Línea base trivial	Importancia	Caso práctico
				
Desempeño humano en la tarea (ejemplo: un médico diagnostica correctamente en 92% de casos).	Benchmarks de la industria, soluciones existentes.	Un modelo que siempre predice la clase mayoritaria (ejemplo: si 80% de datos son positivos, un modelo "dummy" obtiene 80% de accuracy).	Sin línea base, no sabes si tu modelo es bueno o malo. Establécela al inicio.	En clasificación de incidencias, si el mejor desempeño humano es 85% F1, tu modelo debe alcanzar mínimo 87%.

MODELADO Y ENTRENAMIENTO



PREPARAR DATOS: DEL CAOS AL ORDEN

1

LIMPIEZA

Eliminar HTML, caracteres especiales, valores nulos.

2

NORMALIZACIÓN

Convertir variables a escala 0 -1, estandarizar formatos.

3

LEMATIZACIÓN

"Corriendo" → "correr";
reduce variabilidad sin perder significado (NLP).

4

ELIMINACIÓN DE STOP WORDS

Remover "el", "la", "de" que no aportan información (NLP).

5

VECTORIZACIÓN

Convertir texto en números (TF-IDF, Word2Vec, FastText).

6

REBALANCEO DE CLASES

Si 80% de datos son positivos y 20% negativos, usar SMOTE para generar sintéticos.

Insight: 80% del tiempo en un proyecto ML se invierte en datos, no en algoritmos.




MÉTRICAS DE EVALUACIÓN (PRECISIÓN, RECALL, F1-SCORE)

- 01 **Precisión:** de las predicciones positivas, ¿cuántas fueron correctas (importante cuando los falsos positivos son costosos)?
- 02 **Recall (sensibilidad):** de los casos reales positivos, ¿cuántos encontramos (importante cuando los falsos negativos son costosos)?
- 03 **F1-score:** media armónica de precisión y recall; equilibra ambos.
- 04 **Accuracy:** proporción general de aciertos (menos útil en datos desbalanceados).
- 05 **Matriz de confusión:** muestra falsos positivos, falsos negativos, verdaderos positivos y negativos.

PUESTA DE PRODUCCIÓN

Usuario/App → API Modelo vX → Preprocesado → Predicción → Logs → Dashboard.



Resultado: versionado + rollback + monitoreo mínimo.

+

TALLER DE
IDEACIÓN DE PROBLEMAS
(DESIGN THINKING)

DESIGN THINKING: METODOLOGÍA PARA FORMULAR PROBLEMAS

DESIGN THINKING	PRINCIPIO CLAVE	APLICADO EN IA
Metodología centrada en empatía, ideación rápida y validación iterativa.	“¿Resolvemos el problema correcto?” es más importante que “¿resolvemos bien el problema?”.	Entender la necesidad real del usuario antes de entrenar un modelo.
5 FASES		
Empatía → Definición → Ideación → Prototipado → Prueba		

+ FASE 01.

EMPATÍA - ENTENDER EL USUARIO Y SU CONTEXTO

ENTREVISTAS

- ¿Qué dolor siente el usuario? ¿Cuánto tiempo pierde? ¿Cuál es el impacto?

RAZONAMIENTO

- Ver cómo trabajan manualmente, identificar fricciones.

PREGUNTAS CLAVE

- "¿Cuántas incidencias clasificas diariamente (volumen)?"
- "¿Cuál es tu tasa de error (línea base)?"
- "¿Cuánto tiempo dedicas a clasificar (eficiencia)?"

RESULTADO

- Persona de usuario, sus objetivos, sus constraints.

+ FASE 02. DEFINICIÓN



DEFINICIÓN (FASE 2)

Sintetizar insights: "El equipo de soporte necesita clasificar 500 incidencias/día con <5% error".

Redactar problem statement: "¿Cómo podemos automatizar la clasificación de incidencias para reducir tiempo en 80%?".

+ FASE 03. IDEACIÓN



IDEACIÓN (FASE 3)

Brainstorm: machine Learning, reglas heurísticas, soporte híbrido (ML + humano).

Votar por viabilidad + impacto: ML es viable si hay datos etiquetados, alto impacto si reduce 80% de tiempo.

Resultado: conjunto de soluciones candidatas a prototipar.

+ FASE 04. PROTOTIPADO RÁPIDO

MVP (MÍNIMO PRODUCTO VIABLE)

No entrenes un modelo perfecto; haz un funcional rápido.

STACK MÍNIMO

Dataset pequeño (~500 ejemplos etiquetados) + algoritmo simple (Naive Bayes o SVM).

OBJETIVO

Validar que la idea es viable sin invertir meses de desarrollo.

CASO PRÁCTICO

En 1 semana, construir clasificador básico de incidencias con 80% F1-score.

MÉTRICAS DEL PROTOTIPO

Funciona bien en datos de prueba, pero aún necesita refinamiento.

+ FASE 05.

PRUEBA E ITERACIÓN

- **Testing con usuarios:** desplegar el prototipo a 10% de incidencias reales. Medir acierto real vs. esperado.
- **Feedback loop:** ¿el modelo comete errores predecibles? ¿Cuál es la fricción actual?
- **Iteración:**
 - Si accuracy es bajo, volver a fase 2 (redefinir problema, obtener más datos).
 - Si funciona, escalar: más datos, modelos más complejos (random forest, deep learning).
- **Mantenimiento:** una vez en producción, monitorear degradación del modelo. Reentrenar mensualmente si es necesario.
- **Data flywheel:** cada predicción genera datos que mejoran el modelo. Ciclo virtuoso.



CHECKLIST PARA INICIAR TU PROYECTO DE IA

✓ ANTES DE EMPEZAR:

- ¿He entrevistado usuarios? ¿Entiendo su dolor?
- ¿Tengo datos? ¿Están etiquetados? ¿Cuál es la calidad?
- ¿He establecido una métrica clara y una línea base?
- ¿El problema se ajusta a uno de los 3 arquetipos (mejora/complemento/automatización)?
- ¿He evaluado riesgos (sesgo, privacidad, escalabilidad)?
- ¿El ROI esperado justifica el esfuerzo?

✓ FASE INICIAL:

- Construir MVP en 1-2 semanas.
- Validar con usuarios reales.
- Documentar resultados y lecciones aprendidas.



CONCLUSIÓN: FORMULAR ES MAYOR A RESOLVER


- La mitad del éxito de un proyecto de IA es formular bien el problema; la otra mitad es resolverlo correctamente.
- Design thinking no es una metodología corporativa más: es una forma de pensar centrada en empatía + iteración rápida.
- Los mejores equipos de IA son interdisciplinarios
 - **Ingenieros.**
 - **Domain experts.**
 - **Usuarios finales.**





¿CUÁL ES EL
PROBLEMA EN TU
TRABAJO O
CARRERA QUE
PODRÍA
**BENEFICIARSE
DE UNA
SOLUCIÓN DE IA?**



A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + La ideación es una etapa crítica en el diseño de soluciones con IA.
- + El valor para el negocio debe guiar la formulación del problema.
- + No todos los problemas son aptos para IA: evaluar tipos, limitaciones y riesgos es esencial.
- + Las técnicas estructuradas y design thinking ayudan a reducir errores tempranos.
- + Un problema bien definido facilita el éxito del modelo IA en etapas posteriores.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Domínguez-Caiza, J. L. (2025). *El Reto de la Inteligencia Artificial ante la Investigación en Ciencias Sociales*. Revista Científica Hallazgos21, 10(1), 60-70.
- + Galarza-Sánchez, P. C., Boné-Andrade, M. F., & Pinargote-Bravo, V. J. (2023). *Aplicaciones de inteligencia artificial generativa en la transformación digital empresarial*. Revista Científica Ciencia y Método, 1(1), 28-41.
- + García, N. R. P., Parrales, E. M. B., Cantos, M. A. B., & Ponce, M. R. M. (2024). *Integración de la Inteligencia artificial en la formulación de proyectos: Oportunidades, desafíos y perspectivas futuras*. RECIAMUC, 8(1), 463-477.
- + Guillén, G. C. E., & Rodríguez, O. R. O. (2025). *Transformación metodológica en la era digital: el rol de la inteligencia artificial (IA) en el diseño de soluciones*. Cuadernos del Centro de Estudios en Diseño y Comunicación. Ensayos, (269), 105-116
- + Romero, Y. M., & Oltra, G. Y. (2025). *Design thinking e inteligencia artificial: dúo disruptivo para innovar en la formación docente del administrador*. Revista FACES, 7(2).



- + Satama, F. L. V., & Terán, G. A. F. (2023). *Inteligencia Artificial: El reto contemporáneo de la gestión empresarial*. Revista ComHumanitas, 14(1), 94-111.
- + Torres, M. S. C., Quinche, E. J. F., Aguiar, A. E. N., Peralta, D. J. C., Hidalgo, L. E. C., & Moreno, J. S. E. (2025). *Evaluación automatizada mediante inteligencia artificial: beneficios y limitaciones*. South Florida Journal of Development, 6(8), e5725-e5725.
- + Valverde Gómez, D. (2024). *Etapas de un proyecto de aprendizaje automático: Clasificación de incidencias*. Repositorio Institucional de la Universidad de La Laguna.



ISIL+