

+ TEMA 04

ANÁLISIS DE DATOS

- Datos estructurados y no estructurados
- Técnicas de limpieza o transformación
- Python y Excel para el análisis exploratorio
- Visualizador





+ INTRODUCCIÓN **DE LA SESIÓN**

- + Los datos son la base de cualquier solución de inteligencia artificial.
- + Antes de construir modelos, es necesario comprender, preparar y analizar los datos disponibles.
- + Un análisis de datos adecuado permite detectar problemas, patrones y oportunidades.
- + En esta sesión, abordaremos los tipos de datos, su limpieza y las herramientas para su análisis exploratorio.



+

DATOS ESTRUCTURADOS
Y NO ESTRUCTURADOS

¿QUÉ SON LOS DATOS?

Información en bruto que necesita procesamiento y análisis.



20% del tiempo es análisis y modelado.



80% del tiempo es procesamiento de datos.



Data wrangling, data munging, data cleaning son sinónimos.



Transformar datos en bruto en datos analizables.

TIPOS DE DATOS

1

DATOS ESTRUCTURADOS (10-15%)

Modelo rígido, bases de datos SQL, tablas con columnas definidas.

2

DATOS SEMIESTRUCTURADOS (5-10%)

JSON, XML. Estructura conocida pero flexible.

3


DATOS NO ESTRUCTURADOS (75-85%)

Multimedia, texto libre, imágenes. Requiere transformación.

DATOS ESTRUCTURADOS: PROPIEDADES



Campos y variables bien definidos.



Relaciones entre tablas (claves primarias / foráneas).



Restricciones de tipo, longitud, formato.



Consultables (queryables) mediante SQL.





Listos para análisis inmediato.

Ejemplo: dataset iris (150 registros, 4 atributos numéricos).

DATOS NO ESTRUCTURADOS: RETOS

Ejemplos comunes:

Imágenes	Texto	Audio	Redes sociales	Sensores IoT
				
Fotos, videos (sin metadata).	Tuits, correos, documentos (interpretación variable).	Podcast, grabaciones (requiere procesamiento).	Posts, comentarios (alto volumen, bajo valor).	Streams de datos en tiempo real.

DATA WRANGLING: TRANSFORMACIÓN

- El objetivo fundamental de esta fase es **convertir datos crudos en un formato que sea analizable**.
- Este proceso transforma los datos puros siguiendo una metodología que asegura que el resultado sea documentado y reproducible.
- Todo este procedimiento se rige bajo los **lineamientos de tidy data**, el estándar internacional aceptado para garantizar una limpieza y estructuración adecuada de la información.



TIDY DATA: NORMA DE ORO

Definición (Hadley Wickham, 2014): mapeo estándar entre significado y estructura.

01

Cada variable es una columna.

02

Cada observación es una fila.


03

Cada unidad observacional viene a ser una tabla.



Esto define **vocabulario y operadores** estándar para transformación.

¿DE DÓNDE VIENEN LOS DATOS?



+
TÉCNICAS DE LIMPIEZA
O TRANSFORMACIÓN

LIMPIEZA DE DATOS: NECESIDAD CRÍTICA

Datos incompletos o corruptos dan resultados que no son fiables.

- + **Identificación de datos faltantes (missing values).**
- + **Imputación o eliminación de registros incompletos.**
- + **Detección de outliers (valores atípicos).**



ESTRATEGIAS DE IMPUTACIÓN

5	3	?	7	4
5	3	5	5	4

↓

5	3	5	5	5
5	3	5	5	4

----- 5 -----


Reemplazo de valores faltantes por el valor central.
Es rápido y simple, pero reduce la variabilidad y puede sesgar la distribución.

MÉTODO 1: MEDIA/MEDIANA



Adecuado para series temporales. Consiste en propagar el último valor conocido hacia adelante o hacia atrás en la secuencia.


**MÉTODO 2:
FORWARD/BACKWARD FILL**



Métodos más sofisticados que predicen los valores faltantes a partir de vecinos cercanos o relaciones estadísticas entre variables.

MÉTODO 3: KNN/REGRESIÓN

TRANSFORMACIONES COMUNES




OUTLIERS: VALORES ATÍPICOS

¿Errores de medición o información valiosa?

Se consideran outliers los valores que se encuentran a más de ± 3 desviaciones estándar de la media, asumiendo una distribución aproximadamente normal.

MÉTODO 1: REGLA DE LAS 3 SIGMAS



Método 2: IQR (rango intercuartílico)

Se definen límites de normalidad como:

- Límite inferior: $Q1 - 1.5 \times IQR$.
- Límite superior: $Q3 + 1.5 \times IQR$.


Los valores fuera de estos rangos se consideran atípicos.

DISTRIBUCIONES: CLAVE DEL PROCESAMIENTO

1

GAUSSIANA (NORMAL)


Distribución simétrica alrededor de la media, con varianza bien definida.



2

EXPONENCIAL


Presenta un decaimiento rápido. Modela el tiempo entre eventos independientes.



3

UNIFORME


Todos los valores dentro del rango tienen la misma probabilidad.



4

SESGADA

Distribución asimétrica hacia la izquierda o la derecha, con colas pronunciadas.



+

PYTHON Y EXCEL PARA EL
ANÁLISIS EXPLORATORIO

PYTHON VS. EXCEL: ¿CUÁNDO USARLOS?

**Datasets pequeños
(inferiores a 100,000 filas)
dan visualización inmediata.**

**EXCEL: PARA EXPLORACIÓN
RÁPIDA**

**Escalable, reproducible,
automatizable. Pandas,
NumPy, Matplotlib.**

**PYTHON: PARA ANÁLISIS
PROFESIONAL**



💡 **Mejor práctica:** Excel para prototipo, Python para producción.

HERRAMIENTAS PYTHON: EL STACK DE DATOS

01

Pandas

Manipulación y análisis de datos (dataframes).

02

NumPy

Computación numérica (arrays eficientes).

03

Matplotlib

Visualización básica (gráficos estáticos).

04

Seaborn

Visualización avanzada (gráficos profesionales).

05

Scikit-learn

Machine learning.


PANDAS: CARGAR DATOS CSV

```
Python 3.14 (64-bit)
Python 3.14.2 (tags/v3.14.2:df79316, Dec 5 2025, 17:18:21) [MSC v.1944 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> import pandas as pd
... data = pd.read_csv('dataset.csv')
... print(data.shape) # (768, 9) → 768 filas, 9 columnas
... print(data.head()) # Ver primeras 5 filas
... print(data.dtypes) # Tipos de datos
... |
```


✓ También soporta **JSON**, **Excel**, **SQL databases**.

EDA: EXPLORACIÓN INICIAL

Pasos fundamentales:



ESTADÍSTICA DESCRIPTIVA: ENTENDER DATOS



- + **Media (mean):** promedio aritmético. Es sensible a valores atípicos.
- + **Mediana (median):** valor central de la distribución. Es robusta frente a outliers.
- + **Desviación estándar (standard deviation):** mide la dispersión de los datos alrededor de la media.
- + **Percentiles / cuartiles (Q1, Q2, Q3):** dividen la distribución en cuatro partes iguales.

ANÁLISIS DE CORRELACIONES



Pearson $r \in [-1, 1]$:

$r = 0.9$: correlación fuerte positiva.

$r = -0.8$: correlación fuerte negativa.

$r = 0$: sin correlación lineal.

Código: `corr_matrix = data.corr(method='pearson')`

+
VISUALIZADOR

VISUALIZACIÓN: EL PODER DE LAS GRÁFICAS


Un gráfico puede revelar lo que 1,000 números ocultan.

Información que brinda:

- **Detectar patrones** invisibles en datos crudos.
- **Identificar outliers** y anomalías.
- **Comunicar hallazgos** a no-técnicos.
- **Guiar decisiones** basadas en datos.



GRÁFICOS UNIVARIABLES: UNA VARIABLE




Muestra la distribución de frecuencias mediante barras agrupadas en intervalos.

HISTOGRAMA



Representa una curva suave que aproxima la distribución de los datos (gaussiana o sesgada).

DENSIDAD



Visualiza la mediana, los cuartiles (Q1 y Q3) y permite identificar valores atípicos de forma gráfica.

BOXPLOT

VISUALIZAR CON PYTHON



The image shows two screenshots of a Python 3.14.2 (64-bit) terminal window. The first screenshot shows the installation of Matplotlib and the execution of a histogram plot. The second screenshot shows the installation of Seaborn and the execution of a boxplot and a heatmap.

```
Python 3.14.2 (tags/v3.14.2:df79316, Dec 5 2025, 17:18:21) [MSC v.1944 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> # Matplotlib - Básico
... import matplotlib.pyplot as plt
... plt.hist(data['age'], bins=20)
... plt.show()
... |
```


```
Python 3.14.2 (tags/v3.14.2:df79316, Dec 5 2025, 17:18:21) [MSC v.1944 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> # Seaborn - Profesional
... import seaborn as sns
... sns.boxplot(data=data, x='class', y='age')
... sns.heatmap(data.corr())
... |
```

GRÁFICOS MULTIVARIABLES: MÚLTIPLES VARIABLES




Relaciona dos variables (X, Y)
y permite identificar
patrones, relaciones lineales y
clusters.

**SCATTER PLOT (DIAGRAMA DE
DISPERSIÓN)**



El color representa la
intensidad y el signo de la
correlación entre todos los
pares de variables.

**MATRIZ DE CORRELACIÓN
(HEATMAP)**



Matriz de gráficos de
dispersión que muestra todas
las combinaciones bivariadas
entre variables.

PAIRPLOT

DATASETS RECOMENDADOS PARA APRENDER

IRIS



150 observaciones,
4 atributos.
Clasificación de
especies de flores.

TITANIC



892 pasajeros.
Predicción de
supervivencia.

BOSTON
HOUSING



506 viviendas.
Regresión del
precio de casas.

PIMA DIABETES



768 mujeres.
Diagnóstico de
diabetes.

MNIST



70,000 imágenes
de dígitos
manuscritos.
Reconocimiento de
patrones.


✓ Disponibles en Kaggle y en el UCI Machine Learning Repository.

RESUMEN: CAMINO DEL ANALISTA DE DATOS

- 01 Entender tipos de datos (estructurados vs. no estructurados).
- 02 Limpiar y transformar en formato tidy data.
- 03 Analizar estadísticamente con Python/Pandas.
- 04 Visualizar hallazgos con gráficos profesionales.
- 05 Comunicar insights a stakeholders.



La ciencia de datos es 80% limpieza, 20% descubrimiento. ¡Domina la limpieza primero!

A collection of white line-art icons on a purple background. At the top left is a stack of three papers. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**



x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Côté, P. O., Nikanjam, A., Ahmed, N., Humeniuk, D., & Khomh, F. (2024). *Data cleaning and machine learning: a systematic literature review*. *Automated Software Engineering*, 31(2), 54.
- + DeAnda-Madrigal, G., Frizard-Aguilar, A., Ibarra-Delgado, R., Morfín-Alcalá, S., & González-Vázquez, S. N. (2025, julio). *Automatización del análisis de estados financieros con Python-Excel* [Trabajo de fin de grado]. Repositorio Institucional ITESO (REI).
- + Fabián, J. L. Q., Espinosa, A. P., Alonso, G. R., García, M. A. C., & Cornejo, M. A. (2024). *Explorando la Ciencia de Datos*. *Contactos, Revista de Educación en Ciencias e Ingeniería*, (137), 115-121.
- + Nasfi, R., De Tré, G., & Bronselaer, A. (2025). *Improving data cleaning by learning from unstructured textual data*. *IEEE Access*.



ISIL+