

+ TEMA 10

ELECCIÓN DEL MODELO CORRECTO

- Fundamentos y clasificación de los modelos de aprendizaje automático
- Principios y características de los modelos básicos (regresión lineal, árboles de decisión, entre otros)
- Criterios teóricos para la selección y adecuación de modelos a distintos tipos de datos y problemas





+ INTRODUCCIÓN **DE LA SESIÓN**

- + Existen múltiples modelos de aprendizaje automático, cada uno con fortalezas y limitaciones.
- + No hay un modelo “mejor” en todos los casos; la elección depende del problema y los datos.
- + Seleccionar adecuadamente un modelo impacta directamente en la calidad de los resultados.
- + En esta sesión, revisaremos criterios y fundamentos para elegir y comparar modelos básicos IA.



+

FUNDAMENTOS Y CLASIFICACIÓN
**DE LOS MODELOS DE
APRENDIZAJE AUTOMÁTICO**

INTRODUCCIÓN AL APRENDIZAJE AUTOMÁTICO

El aprendizaje automático (ML) es un subconjunto de la inteligencia artificial que permite a los sistemas aprender y mejorar automáticamente a partir de datos sin programación explícita.

Aprendizaje supervisado

- Aprende con datos etiquetados.
- Analogía: profesor corrige ejercicios.



Aprendizaje no supervisado

- Explora datos sin etiquetas.
- Analogía: agrupa patrones sin guía.



TIPOS DE APRENDIZAJE



APRENDIZAJE SUPERVISADO

- Entrena con datos etiquetados (se conocen las salidas).



APRENDIZAJE NO SUPERVISADO

- Explora datos sin etiquetas para descubrir patrones o grupos.



APRENDIZAJE POR REFUERZO

- Un agente aprueba mediante prueba y error, y recompensas.

TAREAS DE CLASIFICACIÓN Y REGRESIÓN



CLASIFICACIÓN

- Predecir etiquetas discretas (diagnóstico médico: enfermo/sano).
- Asigna cada instancia a una de varias clases.



REGRESIÓN

- Predecir valores continuos (estimar el precio de una casa dada su superficie).
- Ajusta una función para estimar resultados numéricos.



CLUSTERING

- Agrupar datos similares en categorías naturales sin etiquetas (segmentación de mercados).
- Útil para explorar estructuras en los datos.

MODELOS CAJA BLANCA VS. CAJA NEGRA

MODELOS CAJA BLANCA (INTERPRETABLES)

- Son transparentes por diseño; representan lógicas sencillas.
- Ejemplo: árboles de decisión, modelos lineales.
- Analogía: libro abierto (fácil de leer y entender).

MODELOS CAJA NEGRA

- Alta complejidad interna; su lógica no es evidente sin herramientas de explicación.
- Ejemplo: redes neuronales profundas, ensambles de modelos.
- Analogía: caja cerrada (solo ves la salida, no cómo se procesa la entrada).
- Criterio: en dominios de alto riesgo se suele preferir un modelo más simple y explicable.

CASO PRÁCTICO: DETECCIÓN DE FRAUDE

La IA puede procesar enormes volúmenes de transacciones financieras para detectar fraudes en tiempo real.

- 01 **Por ejemplo**, redes neuronales entrenadas con casos históricos de fraude identifican patrones inusuales que un auditor manual podría pasar por alto.
- 02 **Proceso**: se recopilan y limpian datos relevantes (montos, ubicaciones, historial de pagos).
- 03 **Luego**, se entrena un modelo supervisado con transacciones etiquetadas como “fraude” o “no fraude”.
- 04 **Resultado**: el modelo asigna a cada nueva transacción una probabilidad de fraude. Si supera un umbral, la transacción se marca para revisión. Esto automatiza la detección y reduce los errores humanos.



+


PRINCIPIOS Y CARACTERÍSTICAS DE
LOS

**MODELOS BÁSICOS (REGRESIÓN
LINEAL,
ÁRBOLES DE DECISIÓN, ENTRE OTROS)**

REGRESIÓN LINEAL

El modelo y su propósito

- Un modelo paramétrico que ajusta una línea recta a los datos: $y = mx + b$. Se entrena minimizando el error cuadrático medio (MSE) entre predicciones y valores reales.
- Útil cuando la relación entre variables es aproximadamente lineal (precio de vivienda vs. Área, por ejemplo).



REGRESIÓN LOGÍSTICA (CLASIFICACIÓN)

Derivado de la regresión lineal, utilizado para clasificación binaria.

ORIGEN Y USO

Predice la probabilidad de pertenecer a cada clase.

PREDICCIÓN DE PROBABILIDAD

Indican la influencia de cada variable en la probabilidad.

INTERPRETACIÓN DE COEFICIENTES



FUNCIÓN SIGMOIDE

Limita la salida entre 0 y 1, interpreta como probabilidad.

ENTRENAMIENTO

El modelo se entrena minimizando la log-pérdida (log-loss).

ÁRBOLES DE DECISIÓN

PARTICIÓN DE DATOS

- Modelos no paramétricos que particionan los datos mediante preguntas binarias.
- Cada nodo evalúa una condición (por ejemplo, “¿valor mayor que X?”) y se ramifica hasta llegar a una hoja donde se obtiene la predicción.

FLEXIBILIDAD Y REGLAS

- Pueden manejar variables categóricas y numéricas.
- Cada camino raíz-hoja equivale a una regla “si-entonces”.

REDES NEURONALES

INSPIRACIÓN BIOLÓGICA

Inspiradas en el cerebro, consisten en capas de neuronas artificiales conectadas.

CAPACIDAD DE MODELADO

Capaces de modelar relaciones muy complejas y no lineales; alta precisión en tareas difíciles (visión, lenguaje).

ESTRUCTURA Y FUNCIONAMIENTO

Cada neurona suma entradas ponderadas y aplica una función de activación (sigmoide, ReLU).

ENTRENAMIENTO

Se entrenan ajustando pesos (descenso por gradiente); requieren muchos datos y cómputo.

OTROS MODELOS BÁSICOS

K-NN

Clasifica una instancia según la mayoría de sus k vecinos más próximos. No requiere entrenamiento complejo.

NAIVE BAYES

Clasificador probabilístico asumiendo independencia entre características. Rápido y útil en texto (spam).

SVM

Encuentra un hiperplano que separa las clases maximizando el margen. Se puede usar con kernels para datos no lineales.


ENSAMBLES

Combinan varios modelos (random forest, boosting) para mejorar precisión. Sacrifica interpretabilidad.

+

CRITERIOS TEÓRICOS PARA LA
SELECCIÓN Y
**ADECUACIÓN DE MODELOS A
DISTINTOS
TIPOS DE DATOS Y PROBLEMAS**


COMPLEJIDAD VS. DATOS



ENTORNO DE POCOS DATOS

- Con pocos datos, conviene modelos simples para evitar sobreajuste.
- En general, los modelos paramétricos requieren menos muestras que los modelos no paramétricos para lograr una buena capacidad de generalización.


Transición por volumen
y complejidad



ENTORNO DE MUCHOS DATOS Y PATRONES COMPLEJOS

- Se pueden usar modelos sofisticados para capturar relaciones avanzadas.


TIPOS DE PROBLEMAS VS. VARIABLE



SOBREAJUSTE Y REGULARIZACIÓN

Sobreajuste (overfitting)

- Un modelo muy complejo puede aprender ruido en vez de patrones.
- Ejemplo: un árbol sin poda profunda memoriza los datos de entrenamiento.



Regularización

- Penaliza la complejidad para mejorar la generalización.
- Ejemplo: L1/L2 en regresión, poda en árboles.

Validación cruzada

- Clave para detectar sobreajuste midiendo el rendimiento en datos no vistos.

COMPENSACIÓN SESGO - VARIANZA



Modelos simples

- Suelen tener alto sesgo y baja varianza (subestimación).



Modelos complejos

- Tienen bajo sesgo y alta varianza (sobreajuste).



El objetivo es encontrar un punto medio: ni muy rígido ni muy adaptado al ruido.

LINEALIDAD DE LOS DATOS

- 1** **Lineal** Si la relación entre variables es lineal, un modelo lineal es apropiado.
- 2** **No lineal** Si hay patrones no muy lineales o interacciones, conviene usar modelos no paramétricos (árboles de decisión, SVM con kernel).
- 3** **Ejemplo** Predecir peso humano (relación casi lineal con la altura) vs. clasificar imágenes (relaciones complejas, usar CNN o árboles).

ESTRUCTURA DE LOS DATOS

Datos estructurados

La mayoría de los modelos tradicionales funcionan adecuadamente con este tipo de información organizada en tablas (filas y columnas).

Datos no estructurados

Requieren modelos especializados capaces de procesar texto, imágenes o audio.



Ejemplo

Para analizar sentimientos en redes sociales se emplean modelos de procesamiento de lenguaje natural, mientras que para predecir ventas de una tienda pueden utilizarse modelos de regresión o árboles de decisión basados en variables económicas.

ESCALA Y PREPROCESAMIENTO




- Algunos modelos (k-NN, SVM, redes neuronales) requieren que las variables estén normalizadas o escaladas.



- Modelos basados en árboles no se ven afectados por la escala.



- Variables categóricas: en regresión se codifican como dummies; en árboles se pueden usar directamente.




El preprocesamiento adecuado es clave para el rendimiento.

EVALUACIÓN Y MÉTRICAS

Utilizar métricas acorde al problema:

Regresión

Error cuadrático medio
(MSE).



MSE

Clasificación

Precisión, recall,
F1, AUC.

5	6	9
0	2	4
1	3	1

Precisión, recall, F1

Clustering

Coefficiente de
Silhouette.




Coefficiente . Silhouette

- Validar siempre con datos de prueba o validación cruzada.
- Analizar la matriz de confusión en clasificación para entender errores.

INTERPRETABILIDAD Y PRECISIÓN

No siempre el modelo más preciso es el más adecuado.



- **Recomendación:** valorar cuánto se necesita la transparencia frente a la ganancia en rendimiento.

PARSIMONIA Y REGULARIZACIÓN



- Si los modelos tienen rendimientos similares, elegir el más simple.



- Evitar incluir variables irrelevantes.
- Usar técnicas de selección o regularización para reducir la complejidad.



- **Consejo:** un modelo más simple con casi la misma precisión es generalmente mejor que uno muy complejo y difícil de interpretar.

DATOS DESBALANCEADOS



- + Cuando las clases están desigualmente representadas (por ejemplo, 1% fraude y 99% normal), la precisión global puede resultar engañosa.
- + Para corregirlo, se pueden aplicar técnicas como ponderación de clases, sobremuestreo (por ejemplo, SMOTE) o submuestreo.
- + Además, es recomendable utilizar métricas más adecuadas como recall o F1-score, que reflejan mejor el desempeño en la clase minoritaria.

RECURSOS COMPUTACIONALES

Técnicas como las redes neuronales profundas o las SVM con kernel pueden requerir gran capacidad de memoria y tiempo de procesamiento, e incluso el uso de GPU para su entrenamiento.

Modelos complejos

La regresión y los árboles de decisión suelen entrenarse más rápido y consumir menos recursos computacionales.

Modelos simples

- **Consideración:** Es importante evaluar el tiempo de entrenamiento e inferencia, especialmente si el sistema necesita respuestas en tiempo real o si el análisis puede realizarse de forma offline.


SELECCIÓN DE MODELO (PRUEBAS Y VALIDACIÓN)

- La selección de modelo implica probar varias alternativas de forma iterativa para identificar la que ofrece mejor desempeño.
- Es recomendable utilizar **validación cruzada** y técnicas de ajuste de hiperparámetros, como **grid search**, para comparar resultados de manera objetiva.
- Además, existen herramientas de **AutoML** que automatizan la prueba de múltiples combinaciones de modelos y parámetros, lo que optimiza el proceso de selección.



RECOMENDACIONES FINALES


- 01  Validar los supuestos de modelo antes de confiar en él.
- 02  Documentar las limitaciones (sesgos, datos faltantes).
- 03  No basarse solo en métricas cuantitativas; interpretar los resultados en conjunto con expertos del dominio.
- 04  Mantener un ciclo de retroalimentación para ajustar el modelo con nuevos datos.



RESUMEN Y CONCLUSIONES

- 01 **○ No existe un “mejor modelo” universal (teorema no free lunch).**
- 02 **○ La elección depende de los datos, el problema y los objetivos.**
- 03 **○ En la práctica se busca un compromiso: precisión, interpretabilidad, costo computacional y facilidad de implementación.**
- 04 **○ Aplicar siempre principios de ciencia de datos: limpieza y exploración inicial, validación rigurosa y ajuste iterativo del modelo.**
- 05 **○ La selección de modelos es tanto teórica como empírica.**



A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + La selección del modelo es una decisión estratégica en soluciones IA.
- + Comprender los fundamentos ayuda a evitar elecciones incorrectas.
- + Los modelos básicos ofrecen un buen equilibrio entre desempeño e interpretabilidad.
- + Comparar modelos permite elegir la mejor alternativa según el contexto.
- + Esta sesión prepara al estudiante para evaluar y validar modelos en la siguiente etapa.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Diez, J. J. R. (2023). *Aprendizaje automático en ciencia de datos*.
- + Fan, J., Li, R., Zhang, C. H., & Zou, H. (2020). *Statistical foundations of data science*. Chapman and Hall/CRC.
- + Razzaq, K., & Shah, M. (2025). *Machine learning and deep learning paradigms: From techniques to practical applications and research frontiers*. Computers, 14(3), 93
- + Sarker, I. H. (2021). *Machine learning: Algorithms, real-world applications and research directions*. SN computer science, 2(3), 160.



ISIL+