

+ TEMA 11

MÉTRICAS

- Precisión
- Exactitud
- Error promedio
- Discusión





+ INTRODUCCIÓN **DE LA SESIÓN**

- + Desarrollar un modelo no es suficiente; es necesario evaluar su desempeño.
- + Un modelo puede parecer correcto, pero no necesariamente generaliza bien.
- + La evaluación permite determinar si el modelo cumple con el objetivo del negocio.
- + En esta sesión, revisaremos métricas clave para validar modelos de IA.



+
PRECISIÓN

DEFINICIÓN FORMAL

- La precisión es la **proporción de instancias clasificadas como positivas que realmente pertenecen a la clase positiva**.
- Se calcula considerando los verdaderos positivos y los falsos positivos, y permite evaluar qué tan confiables son las predicciones positivas del modelo; es decir, indica qué porcentaje de los casos que el modelo predice como positivos son efectivamente correctos.



$$\text{Precisión} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

EJEMPLO NUMÉRICO

- Supongamos que se tiene 100 correos, de los cuales 30 son spam. Un modelo clasifica 25 como spam, con 20 correctos (TP = 20) y 5 erróneos (FP = 5).
- La precisión es $20/(20+5) = 0.80$ (80%).
- Interpretación: de todos los correos que el modelo etiquetó como “spam”, el 80% efectivamente correspondían a spam.



INTERPRETACIÓN PRÁCTICA

- En marketing, precisión indica la fiabilidad de la predicción positiva.

Ejemplo

Predicción de "el cliente responderá a la campaña" frente a los datos reales.

Una alta precisión significa que, cuando el modelo predice que un cliente responderá, generalmente acierta, lo que reduce falsos positivos y gastos innecesarios. Sin embargo, si la clase positiva es poco frecuente, la precisión por sí sola no es suficiente. Además, al ajustar el umbral de decisión, precisión y recall suelen comportarse de forma inversa: al aumentar una, disminuye la otra.

CÁLCULO EN PYTHON

Usando scikit-learn:

```
>>> from sklearn.metrics import precision_score  
... prec = precision_score(y_true, y_pred) # y_true, y_pred listas de 0/1
```

Esto calcula $TP/(TP+FP)$ automáticamente. En ejemplos didácticos, también se puede obtener manualmente.

```
>>> TP = sum((y_pred == 1) & (y_true == 1))  
... FP = sum((y_pred == 1) & (y_true == 0))  
... prec = TP / (TP + FP)
```

VENTAJAS Y LIMITACIONES



Ventajas

- **Penalización de errores costosos:** la precisión penaliza los falsos positivos.
- **Utilidad en contextos críticos:** es una métrica útil cuando el costo de un falso positivo es alto, como en casos de detección de spam o diagnósticos erróneos.
- **Visión complementaria:** se suele utilizar junto a la métrica de recall (exhaustividad) para obtener una visión completa del rendimiento del modelo.



Limitaciones

- **Riesgo en clases desbalanceadas:** en escenarios donde una clase es mucho más frecuente que la otra, un modelo trivial puede obtener una precisión engañosamente alta simplemente prediciendo siempre la clase mayoritaria.
- **Insuficiencia por sí sola:** debido a la limitación anterior, en escenarios desbalanceados se recomienda considerar también el F1-score para una evaluación más justa.

**+
EXACTITUD**

DEFINICIÓN FORMAL

La exactitud o accuracy es la **proporción de predicciones totales (positivas y negativas) correctas**.
En términos matemáticos:

$$\text{Exactitud} = \frac{\text{Acertos}}{\text{Total}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Donde:


TN son verdaderos negativos.

FN son falsos negativos.

Indica el porcentaje global de aciertos del modelo.

EJEMPLO NUMÉRICO

- Con los mismos 100 correos del ejemplo anterior: TP=20, TN=65, FP=5, FN=10 (30 spam, 70 legítimos).
- Entonces, **exactitud** = $(20+65)/100 = 0.85$ (85%).
- El modelo clasifica bien el 85% de los correos.



INTERPRETACIÓN PRÁCTICA

1

La **exactitud** es intuitiva (“% de aciertos totales”), pero engañosa si las clases están desequilibradas.




■ Legítimos 99%

✓ 99% Exactitud

2

Ejemplo: si solo el 1% son spam, un clasificador que marca todo como “no spam” tendrá 99% de exactitud (es inútil).



■ NO SPAM ■


99% Exactitud

3

Por eso, en problemas desequilibrados o con distinto costo de errores es mejor usar otras métricas.



CÓDIGO DE CÁLCULO EN PYTHON



```
Python 3.14 (64-bit) x + v
Python 3.14.2 (tags/v3.14.2:df79316, Dec 5 2025, 17:18:21) [MSC v.1944 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> from sklearn.metrics import accuracy_score
... acc = accuracy_score(y_true, y_pred)
... |
```

También se puede calcular con valores de la matriz de confusión: $(TP+TN)/(TP+TN+FP+FN)$.

VENTAJAS Y LIMITACIONES



Ventajas

- Es una métrica fácil de interpretar.
- Considera todos los aciertos y errores del modelo.
- Es adecuada cuando las clases están balanceadas y todos los errores tienen el mismo costo.



Limitaciones

- En conjuntos de datos desbalanceados puede resultar engañosa: un modelo trivial que ignore la clase minoritaria puede obtener una exactitud alta.
- No distingue entre tipos de error (falsos positivos y falsos negativos), aunque en muchos problemas estos tienen impactos distintos.

+
ERROR
PROMEDIO

DEFINICIÓN FORMAL

- En problemas de regresión (o predicción numérica), se usan métricas de error promedio. Dos de las más utilizadas son el **error medio absoluto (MAE)** y el **error cuadrático medio (MSE)**, que cuantifican la magnitud del error de predicción desde enfoques distintos.

- El MAE es:


$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |p_i - r_i|$$

- El MSE es:


$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (p_i - r_i)^2$$



MAE



MSE



RMSE

- Donde p_i es la predicción y r_i es el valor real. El RMSE es la raíz cuadrada del MSE y se expresa en las mismas unidades que la variable objetivo.

EJEMPLO NUMÉRICO

- Supongamos los valores reales [3, -0.5, 2, 7] y predichos [2.5, 0.0, 2, 8].
- Los errores son [-0.5, +0.5, 0, +1].
- El MAE = $(0.5+0.5+0+1)/4 = 0.5$.
- El MSE = $((0.5^2+0.5^2+0^2+1^2)/4) = (0.25+0.25+0+1)/4 = 0.375$.
- El RMSE = $\sqrt{0.375} \approx 0.612$.

Ejemplo en Python

```
>>> from sklearn.metrics import mean_absolute_error, mean_squared_error
... mae = mean_absolute_error(y_true, y_pred)
... mse = mean_squared_error(y_true, y_pred)
... |
```

INTERPRETACIÓN PRÁCTICA

MAE indica el error medio en unidades reales.

MSE penaliza más errores grandes.

Si un outlier tiene error grande, MSE crecerá mucho.

El RMSE devuelve ese valor al nivel original.

En el ejemplo de contratos de la industria, un $\text{RMSE} = 1,250$ dólares significaría que, en promedio, la predicción difiere $\pm 1,250$ dólares del valor real.

VENTAJAS Y LIMITACIONES



Ventajas

- El MAE es más robusto ante valores atípicos, ya que no amplifica los errores grandes.
- El MSE (y su raíz, RMSE) penaliza con mayor intensidad las desviaciones grandes, por lo que resulta útil cuando los errores altos tienen un costo significativo.



Limitaciones

- El MAE no distingue con mayor peso los errores grandes frente a los pequeños.
- El MSE es menos interpretable porque expresa el error en unidades al cuadrado; aunque el RMSE corrige la unidad, mantiene la penalización elevada de errores extremos.

ERROR DE CLASIFICACIÓN

**En tareas de
clasificación binaria...**

01


El error promedio suele expresarse como la tasa de error, calculada como uno menos la exactitud.

02

Por ejemplo, si la exactitud es 90%, la tasa de error es 10%. Esta métrica representa directamente la proporción de predicciones incorrectas realizadas por el modelo.

+
DISCUSIÓN

PRECISIÓN VS. RECALL VS. F1



Cuando al mejorar la precisión se degrada el recall, la métrica F1 actúa como un equilibrio entre ambas, ya que combina las dos en una sola medida y penaliza los desequilibrios significativos entre ellas.

BIAS-VARIANZA

> Sesgo (bias)

El sesgo es el error sistemático del modelo.

> Varianza

La varianza es la sensibilidad a los datos de entrenamiento.

Hay un trade-off: reducir el sesgo suele aumentar la varianza y viceversa. A continuación, se grafica la relación del error frente a la complejidad del modelo:

```
>>> graph LR
...   Sesgo[Modelo simple<br/>(Alto sesgo)] --> Falta[Underfitting]
...   Varianza[Modelo complejo<br/>(Alta varianza)] --> Exceso[Overfitting]
...   Sesgo --- Varianza
```


ELECCIÓN DE MÉTRICAS

Exactitud puede ser suficiente.

En regresión se usan MAE/MSE según sensibilidad a outliers. En clasificación, además de los dos mencionados, se considera AUC-ROC si se comparan resultados a varios umbrales.

DATOS BALANCEADOS

REGRESIÓN VS. CLASIFICACIÓN



CLASES DESEQUILIBRADAS

Enfatizar recall o precisión según importancia. En virus spam, quizá precisión.

COSTO DE ERRORES

Si FP cuesta más, optimizar precisión. Si FN cuesta más, optimizar recall.

RECOMENDACIONES

- 01 Visualizar la matriz de confusión para identificar con claridad los tipos de error (falsos positivos y falsos negativos).
- 02 Reportar múltiples métricas, por ejemplo: exactitud, precisión, recall y F1, para obtener una evaluación integral del modelo.
- 03 Si se comparan distintos modelos, aplicar validación cruzada para asegurar una comparación consistente y estadísticamente más confiable de las métricas.
- 04 Considerar siempre el contexto de negocio: determinar qué tipo de error es más costoso y ajustar el umbral de decisión y la métrica objetivo en función de ese impacto.



EJERCICIO PROPUESTO 1

- Un test médico clasifica a 100 pacientes. Existen 20 pacientes realmente enfermos. El modelo predice 25 como enfermos, de los cuales 18 son verdaderos positivos.
 - Calcular la precisión, recall y exactitud.
 - Solución: TP = 18, FP = 7, FN = 2 (porque 20 enfermos reales, 18 detectados, faltan 2), TN = 73.
-
- **Precisión:** $= 18/(18+7) = 0.72$ (72%).
 - **Recall:** $= 18/(18+2) = 0.90$ (90%).
 - **Exactitud:** $= (18+73)/100 = 0.91$ (91%).




EJERCICIO PROPUESTO 2

- Dados los valores reales [10, 15, 20, 30] y predichos [12, 14, 18, 33], calcular MAE y MRSE.
- Solución:
 - Errores: [2, 1, 2, 3].
 - $MAE = (2+1+2+3)/4 = 2.0$.
 - $MSE = (2^2+1^2+2^2+3^2)/4 = (4+1+4+9)/4 = 4.0$.
 - $RMSE = \sqrt{4.0} = 2.0$.
- En este caso $MAE = RMSE$ porque la media de los cuadrados se iguala.




EJERCICIO PROPUESTO 3

- ¿Qué métrica es más apropiada en un clasificador de publicidad online donde los clics son muy escasos?
- **Respuesta:** en este caso, la clase positiva es rara. Se recomienda optimizar recall: evita perder verdaderos clics.
- La precisión puede bajar si se intenta capturar todos los clics posibles, pero eso puede ser aceptable si perder clics reales es costoso.



APUNTES FINALES

Métrica	Fórmula resumida	¿Cuándo es útil?	Ventaja/desventaja
Exactitud	$(TP+TN)/total$	Clases balanceadas, tarea genérica.	Simple, pero engañosa en desequilibrio.
Precisión	$TP/(TP+FP)$	Minimizar falsos positivos.	Enfoca calidad de positivos; falla en clases minoritarias.
Recall	$TP/(TP+FN)$	Minimizar falsos negativos.	Crucial para evitar la pérdida de positivos; baja precisión al aumentar recall.
MAE	$(1/N)\sum p-r $	Busca error medio en unidades reales.	Robusto a outliers, pero valora errores grandes.
RMSE	$\sqrt{(\sum (p-r)^2)/N}$	Penalizar errores grandes.	Enfoca errores grandes; unidad cuadrática.

A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + La evaluación es una etapa esencial en el ciclo de vida de una solución IA.
- + Las métricas permiten medir objetivamente el desempeño del modelo.
- + La precisión, exactitud y error promedio deben interpretarse en contexto.
- + Validar el modelo asegura que la solución sea confiable antes de su despliegue.
- + Esta etapa prepara el camino para integrar y desplegar el modelo en una solución real.





x



x



+

BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Gajda, S., & Chlebus, M. (2022). *A probability-based models ranking approach: an alternative method of machine-learning model performance assessment*. *Sensors*, 22(17), 6361
- + Hernández, A. Z., Rosales, G. A. G., Santiago, H. J. J., & Lee, M. M. (2022). *Métricas de rendimiento para evaluar el aprendizaje automático en la clasificación de imágenes petroleras utilizando redes neuronales convolucionales*. *Ciencia Latina Revista Científica Multidisciplinar*, 6(5), 4624-4637.
- + Montiel, J., Ngo, H. A., Le-Nguyen, M. H., & Bifet, A. (2022, August). *Online clustering: Algorithms, evaluation, metrics, applications and benchmarking*. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (pp. 4808-4809).
- + Plevris, V., Solorzano, G., Bakas, N. P., & Ben Seghier, M. E. A. (2022). *Investigation of performance metrics in regression analysis and machine learning-based prediction models*.



ISIL+