

+ TEMA 13

DEMO

- Conceptos de despliegue de modelos y entornos de ejecución
- Principios del funcionamiento de un modelo en producción
- Herramientas de bajo código para la simulación y visualización de resultados (Streamlit, Google Colab, etc.)
- Diseño y estructura de una presentación interactiva (demo)





+ INTRODUCCIÓN **DE LA SESIÓN**

- + Después del prototipado, el siguiente paso es simular el funcionamiento real de la solución.
- + El despliegue permite que el modelo interactúe con usuarios.
- + No siempre es necesario un entorno complejo; existen herramientas de bajo código.
- + En esta sesión, abordaremos conceptos básicos de producción y desarrollo de un demo funcional.



+

CONCEPTOS DE DESPLIEGUE
DE MODELOS Y
ENTORNOS DE EJECUCIÓN

¿QUÉ SIGNIFICA “DESPLEGAR” UN MODELO ML/IA?

Despliegue



Es el proceso de pasar de un modelo entrenado a un modelo que genera predicciones reales dentro de un entorno utilizable, como una aplicación, una API, un proceso por lotes (batch) o un dispositivo edge.

Objetivo



El objetivo del despliegue no es solo que el modelo funcione, sino que opere de forma:

- Reproducible.
- Observable.
- Escalable.
- Gobernable.


Diferencia clave



Entrenamiento: se realiza generalmente en modo batch y en un entorno controlado.

Inferencia: ocurre en producción, puede ser online o near-real-time, y enfrenta condiciones impredecibles de uso y datos.

ENTORNOS TÍPICOS DE EJECUCIÓN (RUNTIME) PARA IA



¿QUÉ SIGNIFICA “DESPLEGAR” UN MODELO ML/IA?



API DE INFERENCIA

- Una app web o móvil consume predicciones vía red.



MICROSERVICIO EN CONTENEDORES

- El modelo funciona como un servicio escalable (usualmente mediante Docker/Kubernetes).



BATCH SCORING

- Predicciones por lotes para procesos no inmediatos como reportes o segmentaciones.



STREAMING INFERENCE

- Procesamiento de eventos en tiempo real, ideal para detección de fraude o recomendaciones instantáneas.






CRITERIOS DE SELECCIÓN

- La elección depende de la latencia requerida, el costo y la criticidad del sistema.

EMPAQUETADO DEL MODELO

En producción, el despliegue suele recuperar el artefacto desde un registro. Luego, se “empaqueta” con lo siguiente:



Resultado típico

Contenedor (Docker) o “model bundle”.

CONTENEDORES VS. SERVERLESS VS. EDGE

1

CONTENEDORES

- Control de dependencias y escalado.
- Útil para modelos pesados.
- Requiere orquestación/operación (kubernetes, etc.).



2

SERVERLESS

- Costo eficiente con tráfico intermitente.
- Límites de tiempo/memoria; no es ideal para modelos grandes.



3

EDGE

- Privacidad, offline, menor latencia.
- Constraints de CPU/RAM, actualización compleja.



ESTRATEGIAS DE RELEASE DE MODELOS: CANARY VS. BLUE-GREEN



Canary Release: se dirige una pequeña fracción del tráfico al nuevo modelo para evaluar su desempeño con métricas reales. Según los resultados, se decide promover el modelo o hacer rollback.

VS.



Blue-Green: existen dos entornos completos en paralelo. Cuando el nuevo modelo está listo, todo el tráfico se cambia al nuevo entorno, permitiendo rollback rápido si ocurre algún problema.

CLAVE: evitar que un modelo “defectuoso” impacte al 100% de usuarios.

INFRAESTRUCTURA COMO CÓDIGO Y REPRODUCIBILIDAD DEL DESPLIEGUE


Para que el despliegue sea repetible, la infraestructura se define como código.

¿Cómo se hace?

Definir recursos como balanceadores, cómputo y escalado mediante plantillas (por ejemplo, Terraform o CloudFormation).

Beneficio

Permite replicar despliegues por región o entorno (dev, stage, prod) con control de versiones.



REALIDAD INDUSTRIAL

- En producción existe “deuda técnica oculta”: recolección de datos, gestión de features, configuración, testing y monitoreo.
- Por ello, en la práctica se trabaja con pipelines end-to-end, no solo con la tarea de entrenar un modelo.



+

PRINCIPIOS DEL
**FUNCIONAMIENTO DE UN
MODELO EN PRODUCCIÓN**

DE POC A PRODUCCIÓN

- 01 ● Muchos proyectos de ML se quedan en prueba de concepto (PoC) y no llegan a producción.
- 02 ● Razones frecuentes
 - Integración compleja.
 - Operaciones manuales.
 - Falta de monitoreo.
 - Baja gobernanza.
- 03 ● MLOps surge para cerrar esta brecha mediante prácticas, cultura y automatización.

VERSIONADO TRIPLE: DATOS + CÓDIGO + MODELO

En producción pueden cambiar:

- Datos (nuevos patrones).
- Código (corrección de errores).
- Modelos (reentrenamiento).

MLOps

Enfatiza el versionado y la reproducibilidad para garantizar robustez.

¿Por qué es importante?

Sin esto, resolver incidentes se vuelve una “adivinanza”.



REGISTRO DE MODELOS (MODEL REGISTRY)

Un Model Registry actúa como la fuente oficial de modelos disponibles para despliegue. Debe almacenar lo siguiente:

- Versión.
- Métricas.
- Dataset / feature set.
- Fecha.
- Estado (staging / prod).
- Aprobaciones.

Integración con CI/CD

Si el modelo está registrado y validado, puede promoverse a producción.

CI/CD/CT: INTEGRACIÓN, DESPLIEGUE Y ENTRENAMIENTO CONTINUO

01

CI/CD tradicional: integra pruebas y despliegue automático de código.

02


En ML: se amplía para incluir modelos y pipelines de datos.

03


CT (Continuous Training): permite reentrenar automáticamente el modelo cuando llega nueva data relevante.

MONITOREO: DRIFT, MÉTRICAS Y “SALUD DEL MODELO”

El modelo puede degradarse por cambios en los datos, por lo que requiere monitoreo continuo.



DESAFÍOS OPERATIVOS REALES



ROLES MÍNIMOS EN UN EQUIPO MLOPS

1

Data scientist

Modelado y experimentación.

2

ML engineer

Empaquetado, serving, optimización de inferencia.

3

Data engineer

Pipelines de datos/feature store.

4

DevOps/Platform

Infraestructura, CI/CD, seguridad.

5

Product/QA

Definición de métricas, validación, pruebas.

6

Idea clave

El “modelo” es un producto vivo, no un entregable estático.


+

HERRAMIENTAS DE BAJO CÓDIGO PARA
LA

**SIMULACIÓN Y VISUALIZACIÓN DE
RESULTADOS
(STREAMLIT, GOOGLE COLAB, ETC.)**

¿QUÉ ES “BAJO CÓDIGO” EN IA APLICADA?

En IA, low-code/no-code suele cubrir:



Valor para universitarios: enfocarse en conceptos y validación antes que en infraestructura compleja.

GOOGLE COLAB: LABORATORIO RÁPIDO PARA PROTOTIPOS

Ideal para notebooks reproducibles, GPU puntual, compartir experimentos, demos rápidas.



STREAMLIT: DASHBOARD DE INFERENCIA EN MINUTOS

Convierte un script en una app web interactiva: inputs, sliders, tablas, gráficos.



¿Para qué es útil?

- Simuladores (what-if).
- Explicabilidad siempre (feature importance).
- Comparar versiones de modelo.
- Demos para público no técnico.

Buen patrón: “3 pestañas”

Para una estructura clara en tu dashboard, utiliza tres secciones principales:

- **Datos:** visualización y exploración del dataset.
- **Predicción:** interfaz interactiva para obtener resultados del modelo.
- **Métricas:** evaluación del rendimiento y precisión.

GRADIO: DEMOS RÁPIDOS DE IA Y BAJO CONSUMO

Caso relevante



Permite crear interfaces simples para inferencia sin requerir gran infraestructura.

¿Para qué es ideal?



- Clasificación de imágenes.
- Chatbots.
- Extracción de entidades.
- Reconocimiento.

En docencia



Permite mostrar el funcionamiento del modelo sin construir un frontend desde cero.

LOBE / AUTOML

Existen herramientas no-code / low-code para crear datasets, etiquetar datos y entrenar modelos.



VENTAJA


Mayor velocidad y accesibilidad para desarrollar soluciones de ML.



RIESGO

Pueden funcionar como “caja negra”. Por ello, se recomienda usarlas como guía y analizarlas con enfoque crítico.

ML-RAPID (PROTOTIPADO DE PRODUCTOS CON ML)



ROLES MÍNIMOS EN UN EQUIPO MLOPS

1

Entrenar un baseline en Colab con un dataset pequeño.

2

Exportar el artefacto del modelo y el pipeline (incluyendo preprocesamiento).

3

Crear una demo en Streamlit: entrada de texto, botón “predecir” y tabla de probabilidades.

4

Registrar versión y métricas (aunque sea manual) como simulación de MLOps.

5

Discusión: qué faltaría para producción real (monitoreo, detección de drift, seguridad).

+

DISEÑO Y ESTRUCTURA
**DE UNA PRESENTACIÓN
INTERACTIVA (DEMO)**

¿QUÉ ES UNA “DEMO INTERACTIVA” DE IA Y POR QUÉ IMPORTA?

Una demo interactiva no es un pitch; es evidencia funcional del valor del modelo.

Elementos clave

PROBLEMA

DATOS/ENTRADA

PREDICCIÓN/SALIDA

IMPACTO


LÍMITES/ERRORES

PRÓXIMOS PASOS

Principio

Permitir que el público interactúe con el modelo y observe cómo se comporta en la práctica.

ESTRUCTURA RECOMENDADA PARA UNA DEMO



GUION DE DEMO

Plantear una narrativa de producto, no una narrativa de algoritmo.

Evita: 10 diapositivas de teoría antes de mostrar el modelo.

Usa enfoque “antes/después”

Antes: proceso manual, lento o subjetivo.

Después: un asistente de IA que genera predicciones y explicaciones.

Métrica ancla

Tiempo ahorrado, errores reducidos, mayor consistencia y satisfacción del usuario.

HERRAMIENTAS IA PARA CONSTRUIR PRESENTACIONES

5 herramientas para PPT con IA

Beautiful.ai, Tome, Canva AI, SlidesAI y Gamma.

Criterios típicos

Generación automática, personalización, colaboración, compatibilidad móvil, integraciones y formatos de exportación.

Recomendación didáctica: elegir herramienta según el objetivo:

Rapidez

Control visual

Colaboración

RIESGOS DE “SLIDES BONITAS”

Alfabetización crítica en IA

En educación

- Se recomienda la alfabetización crítica. Usar IA, pero evaluar sesgos, simplificaciones y distorsiones.

Rol docente/ponente

- Mediador que guía el análisis, no solo “aprueba/rechaza” el contenido generado.

Regla práctica

- Si una slide es “muy linda”, exigir la evidencia y fuente que la respaldan.



DEMO JUNTO CON UI EVALUADA POR IA

**Modelo de deep learning
multiclase para evaluar diseños
de interfaces móviles durante el
prototipado de alta fidelidad.**

Caso de investigación

**Dataset de apps Android
basado en criterios de Material
Design.**

Datos

**El prototipo de UI se ingresa en
una interfaz, el modelo realiza
inferencia y genera una
evaluación automática del
diseño.**


Funcionamiento

**Puede ejecutarse con recursos
computacionales moderados.**

Ventaja

CHECKLIST FINAL

- + **Funcional:** la demo funciona sin depender de “magia” o intervenciones ocultas.
- + **Interactiva:** incluye al menos dos inputs distintos y casos límite.
- + **Transparente:** indica versión del modelo, datos utilizados, supuestos y limitaciones.
- + **Métricas:** presenta al menos una métrica técnica y una de experiencia de usuario.
- + **Segura:** no expone datos sensibles; mantiene logs mínimos y control de acceso si aplica.
- + **Puente a producción:** identifica qué faltaría para un MLOps real (automatización, monitoreo, etc.).

A collection of white line-art icons on a purple background. At the top left is a stack of three documents. Below it is a small 'x' icon. To the right of the 'x' is a cloud icon. Below the cloud is a Q&A icon consisting of two boxes, the top one labeled 'Q' and the bottom one labeled 'A', each with three horizontal lines representing text. To the left of the Q&A icon is another cloud icon. At the bottom left is a notepad icon with a pencil. To its right is a small 'x' icon. At the bottom right is a cloud icon.

+ **CONCLUSIONES**

+ CONCLUSIONES

- + El despliegue transforma un modelo académico en una solución funcional.
- + La demo es clave para validar y comunicar el valor del proyecto.
- + Comprender conceptos básicos de producción permite anticipar desafíos reales.
- + Las herramientas low-code facilitan la experimentación rápida.
- + Esta sesión prepara el terreno para la validación final con usuarios.





x



x



+ BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + De Silva, D., & Alahakoon, D. (2022). *An artificial intelligence life cycle: From conception to production*. Patterns, 3(6)
- Kreuzberger, D., Köhl, N., & Hirschl, S. (2023). *Machine learning operations (mlops): Overview, definition, and architecture*. IEEE access, 11, 31866-31879
- + Parimi, S. K., & Yarram, V. K. (2022). *AI-First Enterprise Architecture: Designing Intelligent Systems for a Global Scale*. The Computertech, 1-18.
- + Sánchez, O. V. G. (2025). *Herramientas de inteligencia artificial para el diseño de presentaciones en la educación superior: un análisis comparativo*. Revista de Investigación en Tecnologías de la Información: RITI, 13(29), 154-165
- + Sun, L., Zhou, Z., Wu, W., Zhang, Y., Zhang, R., & Xiang, W. (2020). *Developing a toolkit for prototyping machine learning-empowered products: the design and evaluation of ML-rapid*. International Journal of Design, 14(2), 35



ISIL+