

+ TEMA 02

IA: RIESGOS Y **LIMITACIONES**


- Alucinaciones y errores
- Sesgos y entrenamiento de modelos
- Riesgos de dependencia tecnológica
- Seguridad digital y privacidad





+ INTRODUCCIÓN **DEL TEMA**


- + En esta sesión, comprenderás los principales riesgos y limitaciones de la inteligencia artificial en el trabajo y la vida cotidiana.
- + Analizarás cuatro dimensiones clave: alucinaciones y errores, que explican por qué la IA puede generar información falsa; sesgos y entrenamiento, que muestran cómo los modelos pueden reproducir prejuicios; dependencia tecnológica, que revela la posible pérdida de habilidades humanas; y seguridad y privacidad, que advierte sobre el manejo de datos sensibles.
- + Asimismo, reflexionarás sobre por qué estas limitaciones son parte del funcionamiento mismo de la IA y cómo desarrollar un uso crítico, seguro y responsable para aprovechar sus beneficios sin comprometer tu criterio ni tu información.



+
ALUCINACIONES Y
ERRORES

¿QUÉ SON LAS ALUCINACIONES Y ERRORES EN IA?

- Las "**alucinaciones**" en inteligencia artificial son respuestas que el sistema genera con aparente confianza, pero que contienen **información falsa**, inventada o inexacta.
- A diferencia de un error humano consciente, **la IA no "sabe"** que está equivocada.



CARACTERÍSTICAS PRINCIPALES

1

Generación con confianza aparente

La IA presenta información falsa con el mismo **tono seguro** que usa para datos correctos, sin indicadores de incertidumbre.

2

Coherencia superficial

Las respuestas alucinadas suelen ser gramaticalmente correctas y contextualmente plausibles, lo que las hace **difíciles de detectar** sin verificación.

3

Invención de referencias

Los sistemas pueden crear **citas bibliográficas falsas**, nombres de estudios inexistentes o estadísticas inventadas que parecen legítimas.

4

Mezcla de información

Frecuentemente, **combinan datos reales con elementos falsos**, creando una narrativa que es parcialmente correcta, pero engañosa.

5

Amplificación de errores

Si se le pide profundizar en información incorrecta, los sistemas pueden **elaborar más detalles falsos**, construyendo sobre el error inicial.

6

Dependencia del contexto

La probabilidad de alucinaciones aumenta cuando **se solicita información muy específica**, técnica o sobre eventos recientes no presentes en los datos de entrenamiento.



ESTRATEGIA DE MITIGACIÓN

Adoptar prácticas específicas que **permitan un uso seguro**, ético y efectivo de la IA, y que ayuden a contrarrestar sus limitaciones inherentes.



- 01 Verificación cruzada obligatoria.
- 02 Escepticismo informado.
- 03 Conocimiento del dominio.
- 04 Solicitar fuentes.
- 05 Uso de IA como borrador.

+ 01.

EJEMPLO: RIESGO EN CONSULTORÍA EMPRESARIAL

- Una consultora en Lima elaboró un análisis de mercado para un cliente interesado en invertir en el sector turismo en Cusco.
- Para ello, utilizó IA generativa con el fin de obtener estadísticas sobre el flujo turístico y proyecciones postpandemia.



+ 01.

EJEMPLO: RIESGO EN CONSULTORÍA EMPRESARIAL


- Sin embargo, el sistema “alucinó” datos atribuidos al Mincetur, generando cifras que parecían plausibles, pero que eran totalmente falsas.
- El cliente tomó decisiones de inversión basándose en este análisis erróneo: abrió un local en una temporada inadecuada y en una ubicación poco estratégica. Como resultado, sufrió pérdidas significativas y presentó una demanda contra la consultora por negligencia profesional.



+ 02.

EJEMPLO: SECTOR FINANCIERO

- Interbank implementó un programa de capacitación para sus analistas financieros enfocado en comprender los límites de las herramientas de IA aplicadas al análisis de riesgo crediticio.
- Los analistas aprendieron que, cuando la IA genera proyecciones sobre sectores emergentes en Perú (como fintech o agroexportación), estas deben contrastarse con datos del BCRP y la SBS.
- Esto se debe a que el modelo puede “alucinar” tendencias basándose en patrones de otros mercados que no necesariamente se ajustan a la realidad peruana.





¿POR QUÉ ES
PARTICULARMENTE PELIGROSO
QUE LAS ALUCINACIONES DE
LA
IA SE PRESENTEN
CON TONO CONFIADO?



+

SESGOS Y ENTRENAMIENTO
DE MODELOS

¿QUÉ SON LOS SESGOS EN LA IA?

Son **distorsiones sistemáticas** en los outputs del modelo que reflejan, amplifican o introducen **prejuicios**, **estereotipos** o **preferencias injustas** hacia ciertos grupos, ideas o perspectivas.



CARACTERÍSTICAS PRINCIPALES

1

Sesgos de representación

Cuando ciertos grupos, regiones o perspectivas están **subrepresentados** en los datos de entrenamiento.

2

Sesgos históricos

Los datos reflejan injusticias y **desigualdades del pasado**.

3

Sesgos de confirmación

Los modelos pueden **reforzar estereotipos** existentes.

4

Sesgos geográficos y culturales

La mayoría de los grandes modelos están **entrenados** con **contenido** predominantemente **estadounidense** y **europeo**.

5

Sesgos temporales

Los modelos tienen una **"fotografía"** del mundo hasta su fecha de entrenamiento.

6


Sesgos de etiquetado

Las decisiones humanas sobre qué es **"correcto"** o **"apropiado"** durante el entrenamiento introducen valores específicos que pueden no ser universales.

+ 01.

EJEMPLO: RECLUTAMIENTO INCLUSIVO EN BCP

- El Banco de Crédito del Perú, al implementar herramientas de IA para el filtrado inicial de CV, realizó una auditoría de sesgos antes de su despliegue completo.
- El análisis reveló que el sistema favorecía a candidatos provenientes de determinadas universidades de Lima y penalizaba, de forma inconsciente, CV con nombres que el algoritmo asociaba a provincias o comunidades indígenas.



+ 02.

EJEMPLO: EXCLUSIÓN FINANCIERA DIGITAL

- Una fintech lanzó una app de préstamos rápidos basada en IA para la evaluación de riesgo.
- El modelo, entrenado principalmente con datos de usuarios urbanos con smartphones de gama alta y con acceso a historial crediticio formal, terminó rechazando de manera sistemática las solicitudes de personas de zonas rurales o periurbanas, trabajadores de la economía informal y personas mayores con menor alfabetización digital.



Solicita un préstamo
rápido y fácil

Bantra
Fintech


Con Bantra puedes solicitar préstamos personales en cualquier lugar, desde tu celular o computadora de manera fácil y rápida.

The advertisement features a man in a black shirt counting a large stack of 100 Euro banknotes. Below him are three circular icons: a red fingerprint, a blue fingerprint, and a red fingerprint. The background is dark blue.

PROCESO DE ENTRENAMIENTO Y SUS IMPLICACIONES

Para comprender los sesgos, es fundamental entender cómo se entrenan los modelos de IA:

- 01 **FASE 1: RECOPIACIÓN DE DATOS**
Los desarrolladores **recolectan** millones o billones de textos de internet, libros, artículos científicos, redes sociales, etc.
- 02 **FASE 2: PREPROCESAMIENTO**
Los datos **se limpian y organizan**. Las decisiones sobre qué eliminar o mantener introducen valores.
- 03 **FASE 3: ENTRENAMIENTO**
El modelo **aprende patrones** estadísticos de los datos.
- 04 **FASE 4: AJUSTE FINO**
Mediante **retroalimentación humana**, el modelo se afina.



EJEMPLO 1: EL CHATBOT DE SALUD CON VISIÓN LIMITADA

Fase 1: recopilación de datos

- Se entrena un modelo con una vasta colección de artículos médicos en inglés, publicados principalmente en revistas de Norteamérica y Europa, y foros de salud en línea de esos mismos países.

Fase 2: preprocesamiento

- Se filtran y eliminan los foros de salud considerados "poco fiables", que a menudo son los únicos que discuten remedios tradicionales o experiencias de pacientes en países en desarrollo.

Fase 3: entrenamiento

- El modelo aprende que los tratamientos "estándar" son los aprobados por la FDA (EE. UU.) y la EMA (Europa). Aprende a describir los síntomas basándose en cómo se presentan en poblaciones caucásicas.

Fase 4: ajuste fino

- Los médicos evaluadores, formados en el mismo paradigma occidental, refuerzan las respuestas que se adhieren a los protocolos que conocen, sin cuestionar la falta de perspectiva global.



ESTRATEGIA DE MITIGACIÓN

Conjunto de acciones proactivas, controles y salvaguardas implementados de forma sistemática para identificar, reducir y gestionar los riesgos y daños potenciales.



- 01  Auditoría de equidad.
- 02  Diversidad en datos.
- 03  Revisión humana crítica.
- 04  Transparencia.
- 05  Iteración y mejora.



¿CÓMO LOS
SESGOS
HISTÓRICOS EN
DATOS PUEDEN
PERPETUAR
INJUSTICIAS
SOCIALES CUANDO
SE UTILIZAN PARA
**ENTRENAR
MODELOS DE IA?**



+

RIESGOS DE DEPENDENCIA
TECNOLÓGICA

¿QUÉ ES LA DEPENDENCIA TECNOLÓGICA EN IA?

- Se refiere a la **erosión gradual de capacidades humanas** críticas cuando delegamos excesivamente tareas cognitivas, creativas o de toma de decisiones a sistemas automatizados.
- Es un fenómeno en el cual la conveniencia inmediata de la IA nos lleva a **subutilizar habilidades propias**. Esto crea una espiral donde, a medida que usamos menos ciertas capacidades, estas se atrofian, lo que aumenta aún más nuestra dependencia de la tecnología.



ATROFIA DE HABILIDADES COGNITIVAS

El uso constante de IA para redacción **reduce progresivamente** nuestra capacidad de estructurar argumentos, encontrar palabras precisas o expresar ideas complejas sin asistencia tecnológica.

EJEMPLO:

- + Un redactor publicitario que durante años ha usado IA para generar eslóganes y textos persuasivos recibe el brief de una campaña crucial y descubre que su mente está "en blanco".
- + Al intentar escribir sin ayuda, se da cuenta de que le cuesta enormemente encontrar metáforas originales, estructurar un argumento convincente desde cero o jugar con las palabras.
- + Su músculo creativo se ha debilitado por falta de uso.




PÉRDIDA DE CONOCIMIENTO TÁCITO

Cuando la IA realiza análisis o síntesis, perdemos el "aprendizaje en el proceso".

EJEMPLO:

- + Un equipo de analistas financieros automatiza completamente la generación de sus reportes trimestrales con una IA.
- + Con el tiempo, nadie en el equipo es capaz de explicar el "porqué" detrás de las tendencias que la IA señala.
- + Han perdido la comprensión intuitiva del mercado que se ganaba al pasar horas inmersos en los datos, cruzando variables manualmente y descubriendo conexiones sutiles por sí mismos.
- + El conocimiento se volvió superficial.



EROSIÓN DEL PENSAMIENTO CRÍTICO

Si aceptamos outputs de IA sin cuestionamiento, dejamos de ejercitar nuestra **capacidad de evaluar, cuestionar y validar información**, haciéndonos vulnerables a errores y manipulación.

EJEMPLO:

- + Un grupo de estudiantes usa una IA para investigar sobre un tema de debate complejo.
- + La IA genera un resumen aparentemente coherente, pero con un error factual clave y una omisión importante de una perspectiva contraria.
- + Como han dejado de cuestionar sistemáticamente las fuentes, todos los estudiantes integran la información errónea en sus presentaciones y son incapaces de defender sus posturas cuando un profesor señala las fallas.



DEPENDENCIA OPERACIONAL

Organizaciones que **integran** profundamente IA en **procesos críticos** pueden encontrarse paralizadas si la tecnología falla, sin protocolos manuales de respaldo o personal capaz de operar.

EJEMPLO:

- + Un call center implementa un sistema de IA que resuelve el 95% de las consultas técnicas de los clientes.
- + Un día, una actualización fallida colapsa el sistema durante 24 horas.
- + Los agentes humanos, que han perdido la práctica y no tienen acceso a las bases de conocimiento tradicionales, se ven sobrepasados.
- + No pueden resolver las consultas básicas, lo que genera una avalancha de quejas y daña la reputación de la empresa.



PÉRDIDA DE VENTAJA COMPETITIVA

Los profesionales que **dependen** completamente de herramientas disponibles para todos **pierden diferenciación**. El valor está en lo que aportas más allá de lo que la IA puede hacer.

EJEMPLO:

- + Dos arquitectos compiten por un proyecto. Ambos usan IA para generar renders y planos iniciales.
- + El arquitecto A solo presenta el output de la IA.
- + El arquitecto B, en cambio, utiliza la IA como base, pero añade un valor único: modifica el diseño basándose en su experiencia con la luz local, propone un material innovador que conoce de otros proyectos y explica el concepto estructural con una maestría que la IA no puede igualar.
- + El cliente elige al arquitecto B porque su valor humano es lo que marca la diferencia.



VULNERABILIDAD ANTE CAMBIOS TECNOLÓGICOS

Las personas que desarrollan sus capacidades profesionales basándose solo en el manejo de herramientas específicas de IA quedan expuestas a la **obsolescencia** cuando dichas herramientas se actualizan, cambian su funcionamiento o son reemplazadas por nuevas tecnologías.

EJEMPLO:

- + Un community manager ha construido su carrera siendo experto en una herramienta específica de IA que genera calendarios de contenido y copy para redes sociales.
- + Cuando la empresa dueña de la herramienta es comprada y la plataforma se vuelve obsoleta, es reemplazada por una nueva generación de asistentes con un funcionamiento radicalmente diferente.
- + Su "experticia" se vuelve irrelevante de la noche a la mañana, ya que no invirtió en desarrollar una estrategia de marketing sólida y adaptable, sino que solo dominó una herramienta concreta.



EL EQUILIBRIO APROPIADO: IA COMO HERRAMIENTA, NO COMO MULETA

La clave está en desarrollar una **relación saludable** con la IA:

PRIMERO DOMINA LOS FUNDAMENTOS HUMANOS

- Antes de usar IA para escribir, aprende a estructurar argumentos y expresarte claramente.
- Antes de utilizar IA para programar, entiende algoritmos y lógica computacional.

USA LA IA PARA AMPLIFICAR, NO REEMPLAZAR

- Usa IA para generar opciones que tú evalúas y seleccionas.
- Utiliza IA para acelerar tareas repetitivas mientras te enfocas en decisiones estratégicas.

MANTÉN LA PRÁCTICA REGULAR DE HABILIDADES

- Dedica tiempo a tareas sin asistencia de IA para mantener agudeza mental.
- Practica resolución de problemas "desde cero" regularmente.



¿CUÁL ES LA DIFERENCIA
ENTRE “USAR IA COMO
HERRAMIENTA” Y
**“SER DEPENDIENTE
DE LA IA”?**



+
SEGURIDAD DIGITAL
Y PRIVACIDAD

IMPLICANCIA DE LA SEGURIDAD Y PRIVACIDAD EN IA

Se refiere a los **riesgos asociados con el manejo de datos personales**, información sensible y propiedad intelectual cuando interactuamos con sistemas de IA.



CARACTERÍSTICAS PRINCIPALES

1

Persistencia de datos

Las conversaciones con sistemas de IA son típicamente **almacenadas** por los proveedores.

2

Uso para entrenamiento

Dependiendo de la configuración y del servicio utilizado, tus conversaciones pueden ser utilizadas para **entrenar versiones futuras**.

3

Falta de contexto de confidencialidad

Los modelos de IA no tienen concepto real de "**confidencial**" o "**privado**".

4

Vulnerabilidad a prompt injection

Atacantes pueden diseñar **prompts maliciosos** que manipulan el comportamiento de la IA.

5

Riesgos de fuga de información

Información sensible **compartida** con IA puede aparecer inadvertidamente en respuestas a otros usuarios.

6

Jurisdicción legal ambigua

Los datos procesados por IA pueden estar almacenados en servidores de múltiples países, creando **complejidad legal**.

MEJORES PRÁCTICAS DE SEGURIDAD Y PRIVACIDAD (PARA USO INDIVIDUAL)

Regla de oro de la privacidad

- Nunca compartas con la IA nada que no compartirías en una red social pública.
- Asume que lo que ingresas podría potencialmente hacerse público.

Anonimización

- Si necesitas ayuda con casos específicos, remueve toda información identificable: nombres, empresas, ubicaciones precisas, fechas específicas, números de documentos, etc.

Verificación de configuración

- Revisa configuraciones de privacidad de servicios de la IA que usas.

Uso de instancias privadas

- Para trabajo profesional sensible, considera servicios empresariales de IA con garantías contractuales de privacidad.

MEJORES PRÁCTICAS DE SEGURIDAD Y PRIVACIDAD (PARA ORGANIZACIONES)

Políticas claras

- Establecer y comunicar políticas de uso aceptable de IA, especificando qué tipo de información puede compartirse y cuál debe mantenerse restringida.

Capacitación regular

- Educar a empleados sobre riesgos de privacidad no solo una vez, sino como parte de capacitaciones continuas de seguridad de información.

Soluciones empresariales

- Implementar deployments privados de IA para uso interno, garantizando que los datos sensibles no salgan de la infraestructura corporativa.

Respuesta a incidentes

- Establecer protocolos claros para actuar ante casos en los que información sensible haya sido compartida inadvertidamente con sistemas de IA.

MARCO LEGAL RELEVANTE EN PERÚ

LEY N° 29733 — LEY DE
PROTECCIÓN DE
DATOS PERSONALES



Ley N.º 29733

Ley de Protección de Datos Personales.

LEY N°
31814



Ley N.º 31814

Ley que Promueve el Uso de la Inteligencia Artificial.

CÓDIGO DE
PROTECCIÓN
Y DEFENSA DEL
CONSUMIDOR


LEY N° 29571

Código de Protección y Defensa del Consumidor.



¿POR QUÉ COMPARTIR
INFORMACIÓN DE UN CASO
LEGAL REAL CON CHATGPT
PODRÍA VIOLAR LA
CONFIDENCIALIDAD ABOGADO-
CLIENTE, **INCLUSO SI NO
MENCIONAS EL
NOMBRE DEL
CLIENTE?**





Christian Lous Lange, Nobel de la Paz.



**“La tecnología es un sirviente útil,
pero un amo peligroso”.**

+ **CONCLUSIONES**



x



x



+ CONCLUSIONES

- + Los sistemas de inteligencia artificial pueden generar alucinaciones, contenido falso presentado con confianza, especialmente en temas técnicos, específicos o recientes.
- + Todo sistema de IA contiene sesgos derivados de sus datos de entrenamiento, que frecuentemente subrepresentan perspectivas latinoamericanas, contextos peruanos y realidades de mercados emergentes.
- + El uso irreflexivo de IA puede erosionar gradualmente habilidades cognitivas fundamentales: pensamiento crítico, creatividad, escritura, análisis.
- + Cada interacción con sistemas de IA implica compartir información que puede ser almacenada, procesada y potencialmente utilizada de maneras no previstas.





x



x



+ BIBLIOGRAFÍA **MÁS REFERENCIAS**

- + Akhtar, M. A. K., Kumar, M., & Nayyar, A. (2024). *Towards Ethical and Socially Responsible Explainable AI: Challenges and Opportunities*. Springer Cham.
<https://doi.org/10.1007/978-3-031-66489-2>
- + Bai, X., Wang, A., Sucholutsky, I., & Griffiths, T. L. (2025). *Explicitly unbiased large language models still form biased associations*. Proceedings of the National Academy of Sciences of the United States of America, 122(8), e2416228122. <https://doi.org/10.1073/pnas.2416228122>
- + Eubanks, V. (2018). *Automating inequality: How high-tech tools profile, police, and punish the poor*. St. Martin's Press.
<https://www.abebooks.com/9781250074317/Automating-Inequality-High-Tech-Tools-Profile-1250074312/plp>
- + Nemko Digital. (2025). AI regulation in Peru: Latin America emerging AI governance. <https://digital.nemko.com/regulations/ai-regulation-in-peru>



ISIL+